



# **Evolution of poverty in Bolivian communities between 2012 and 2022: A machine learning and remote sensing approach**

Bolivar, Osmar

August 2023

Online at <https://mpra.ub.uni-muenchen.de/118932/>  
MPRA Paper No. 118932, posted 21 Oct 2023 09:40 UTC

# Evolución de la pobreza en las comunidades de Bolivia entre 2012 y 2022: Un enfoque de machine learning y teledetección

Osmar Bolívar\*

Agosto 2023

## Resumen

Esta investigación tiene como objetivo pronosticar la incidencia de pobreza a nivel comunitario en Bolivia para el año 2022 empleando algoritmos de machine learning y teledetección, y contrastar estos pronósticos con los datos de 2012. Se procesaron datos censales de 2012 para crear un indicador de pobreza basado en Necesidades Básicas Insatisfechas (NBI) a nivel de comunidades y se seleccionaron 953 de estas comunidades como unidades de análisis. La generación de variables geoespaciales, el entrenamiento y validación de algoritmos de machine learning, y la posterior aplicación de estos modelos revelaron una disminución general de la pobreza, con aproximadamente el 50 % de las comunidades proyectadas por debajo del umbral del 42,5 % en 2022, indicando mejoras significativas desde 2012. Se observó una reducción diferencial de la pobreza, con un impacto más pronunciado en las comunidades con menores niveles de pobreza iniciales. Se vislumbraron disparidades regionales, con tasas de pobreza más bajas en áreas urbanas, subrayando la necesidad de abordar las desigualdades regionales. Además, se evidenció la eficacia de la metodología planteada en este estudio en comparación con investigaciones similares, resaltando la utilidad de esta metodología para predecir la pobreza a nivel comunitario.

**Keywords:** pobreza; machine learning; remote sensing

**JEL Codes:** C8; I3; I32; O31

---

\*Este Working Paper corresponde a un trabajo de investigación elaborado en el marco del Programa de Maestría en Economía Aplicada, de la Universidad Andina Simón Bolívar. Las opiniones y conclusiones realizadas por el autor no representan necesariamente la posición de las instituciones a las que está afiliado. Email: [osmar.jsmpf@gmail.com](mailto:osmar.jsmpf@gmail.com)

# 1. Introducción

Durante un extenso período de tiempo, los economistas han mostrado un afán por comprender la naturaleza y las causas de la pobreza. Un aspecto de suma importancia radica en su medición y la precisión con la cual se calcula este indicador. En el ámbito académico, se han realizado notables esfuerzos para abordar la medición de la pobreza; no obstante, su cuantificación es un proceso complejo y está sujeta a supuestos que incluyen la propia noción de pobreza, la elección del indicador de bienestar, la unidad de medida y otros aspectos relevantes.

Entre los trabajos pioneros que han contribuido a este campo, se destacan los de [Orshansky \(1969\)](#) y [Galbraith \(1998\)](#), quienes establecieron el primer umbral oficial de pobreza para Estados Unidos. Orshansky se basó en el costo de una cesta básica de alimentos para determinar este umbral, considerado como el nivel mínimo necesario para satisfacer las necesidades básicas de una familia. Además, desarrolló un método para medir la pobreza utilizando los ingresos monetarios de las familias, mediante la comparación de dichos ingresos con el umbral de pobreza, con el propósito de determinar si una familia era considerada pobre o no. Dentro de esta categoría, se pueden mencionar trabajos de destacados académicos como [Thon \(1979\)](#), [Foster et al. \(1984\)](#), [Kanbur \(1990\)](#) y [Jenkins y Lambert \(1997\)](#). Estas investigaciones sentaron las bases de las primeras medidas de pobreza, las cuales han sido ampliamente empleadas a nivel global y han contribuido significativamente a una mayor comprensión de la pobreza y sus posibles abordajes.

Sin embargo, [Atkinson \(1987\)](#) señaló que la medición de la pobreza es un tema complejo y que no existe una única forma correcta de cuantificarla. Por consiguiente, el autor propone un enfoque múltiple que tome en consideración diversas facetas de la pobreza, tales como la privación material, la exclusión social y la calidad de vida. Asimismo, Atkinson aborda el papel de los umbrales de pobreza, argumentando que deben establecerse teniendo en cuenta los costos de vida y deben actualizarse regularmente para reflejar cambios en los precios y en las condiciones económicas. Por último, el autor examina la relación entre la pobreza y la distribución del ingreso, y sugiere que la medición de la pobreza debe tomar en cuenta no solo la cantidad de ingreso disponible, sino también cómo se distribuye dicho ingreso entre los distintos grupos de la población.

Aunque el enfoque monetario ha sido considerado una medida sencilla para calcular la pobreza a través de los ingresos, ha recibido diversas críticas por no capturar adecuadamente las diferentes dimensiones de la pobreza. Ante la necesidad de contar con una medida multidimensional, han surgido trabajos de destacados investigadores como [Bourguignon y Chakravarty \(1999\)](#), [Tsui \(2002\)](#), [Bourguignon y Chakravarty \(2003\)](#), [Deutsch y Silber \(2005\)](#), [Duclos et al. \(2006\)](#), [Alkire y Foster \(2011a\)](#), [Alkire y Foster \(2011b\)](#), [Ravallion \(2011\)](#) y [Battiston et al. \(2013\)](#), quienes han aportado un indicador de carácter multidimensional. A diferencia de la medición tradicional de la pobreza, este enfoque abarca diversos factores, como los ingresos o el consumo, la educación, la salud, la vivienda, los servicios básicos, la seguridad alimentaria, los derechos y las capacidades, así como otros indicadores relacionados con el acceso a servicios financieros y transporte, entre otros.

La medida de pobreza multidimensional proporciona un análisis más completo y preciso de la pobreza en una sociedad determinada. Esta medida resulta útil para identificar grupos de personas que podrían ser particularmente vulnerables y requieren una atención y apoyo especiales. Según [Alkire y Foster \(2011b\)](#), el enfoque de medición de la pobreza multidimensional se basa en evaluar la pobreza a través de múltiples dimensiones, como la educación, la salud, la vivienda y el acceso a servicios básicos. Estas medidas multi-

dimensionales se pueden utilizar para obtener una imagen más completa de la pobreza, revelando quiénes son las personas pobres, cómo experimentan la pobreza y la amplia gama de desventajas que enfrentan.

La medición de la pobreza multidimensional se basa principalmente en datos recopilados a través de encuestas de hogares. Sin embargo, este enfoque presenta limitaciones en términos de calidad, frecuencia y cobertura de las encuestas. Aunque las encuestas proporcionan una amplia gama de indicadores y permiten comparaciones en el tiempo y entre grupos poblacionales debido a su representatividad y tamaño de muestra, su realización anual implica un alto costo para los institutos de estadística —más si son trimestrales o mensuales—, lo cual constituye una limitación. Además, la elección de diferentes dimensiones e indicadores en la medición de la pobreza multidimensional dificulta la comparabilidad de resultados entre países. Aunque este enfoque ofrece una visión completa de la pobreza, su costo y su falta de representación en áreas remotas o de difícil acceso son desafíos.

Algunos países han optado por utilizar imágenes satelitales para recopilar información sobre el acceso a servicios básicos y las condiciones de vida en áreas remotas. El uso de imágenes satelitales tiene ventajas en términos de rapidez y eficiencia para obtener información sobre áreas extensas y detectar patrones y tendencias a lo largo del tiempo. Sin embargo, la complejidad de los algoritmos y el procesamiento de grandes volúmenes de datos limitan su aplicación en muchos países en desarrollo. La estimación de la pobreza a través de imágenes satelitales y algoritmos de aprendizaje automático (i.e., machine learning) presenta múltiples ventajas en comparación con el enfoque multidimensional (Blumenstock, 2016; Jean et al., 2016; Martinez Jr, 2020; Piaggesi et al., 2019; Tang et al., 2018; Tingzon et al., 2019).

En países en desarrollo, donde la infraestructura es limitada y las encuestas tradicionales resultan costosas, las imágenes satelitales se convierten en una alternativa eficiente y económica para obtener información sobre el acceso a servicios básicos en áreas remotas. Además, permiten identificar áreas de intervención y evaluar el impacto de políticas públicas dirigidas a la reducción de la pobreza. Adicionalmente, este enfoque mejora la precisión de las estimaciones al integrar las imágenes satelitales y las encuestas socioeconómicas. En situaciones donde los datos de encuestas confiables son limitados o desactualizados, los responsables de la toma de decisiones a menudo se ven obligados a basar sus decisiones en información limitada. En estos casos, el uso de algoritmos de machine learning aplicados a imágenes satelitales de alta resolución ofrece una alternativa. Los estudios que se centran en la integración de datos provenientes de encuestas y satélites con la inteligencia artificial para crear mapas de pobreza extraen datos sobre vegetación, agua, topografía y otros, con lo que se logran estimaciones precisas y eficientes de la pobreza, así como la identificación de patrones y tendencias en su distribución.

Sin embargo, en América Latina, el uso generalizado de algoritmos de machine learning y técnicas de teledetección para estimar la pobreza se ve restringido por varias razones. Estas incluyen la falta de datos confiables y de calidad, limitaciones en la infraestructura tecnológica y de investigación, costos asociados a la implementación de estas técnicas, falta de expertos en estas áreas y, el contexto político y social en algunos países que dificulta la recolección de datos y la implementación de proyectos relacionados con la pobreza.<sup>1</sup>

En el caso de Bolivia, no existen precedentes de estudios que aborden la pobreza con base en algoritmos de machine learning y teledetección. Generalmente, en Bolivia la

---

<sup>1</sup>Cabe destacar que estas limitaciones no son aplicables a toda la región, y existen avances y esfuerzos en diversos países para superar estos desafíos.

pobreza se estima a través de diversas encuestas y/o censos realizados por el Instituto Nacional de Estadística (INE), siendo la Encuesta de Hogares (EH) la principal fuente de información para medir la pobreza. Sin embargo, las encuestas suelen ser costosas y requieren de mucha logística para su ejecución. Asimismo, los tamaños de muestra que se utilizan para estas encuestas son insuficientes para generar estadísticas de pobreza con desagregación espacial alta (e.g., por municipio o comunidad).

Es importante mencionar que en Bolivia no existen datos actuales sobre los niveles de pobreza a nivel de comunidades. La única manera de generar indicadores de pobreza por comunidad en Bolivia es mediante el procesamiento de la información del Censo Nacional de Población y Vivienda (CNPV), que fue realizado por última vez el año 2012. Es más, si bien los datos del CNPV 2012 están disponibles de manera irrestricta, éstos no fueron procesados por el INE para generar indicadores de pobreza por comunidad de acceso público.

Para otros países que enfrentan limitaciones similares a las expresadas en el anterior párrafo, existen estudios que han empezado a utilizar técnicas de machine learning como una solución alternativa para predecir y abordar la pobreza de manera eficiente y efectiva. Por ejemplo, [Min et al. \(2022\)](#) utilizan algoritmos de machine learning que combinan técnicas de preprocessamiento de datos, ingeniería de características y tres métodos de regresión diferentes. Recientemente, se han empezado a utilizar métodos alternativos para medir la pobreza con técnicas de machine learning y teledetección para aprovechar la información de imágenes satelitales, con el objetivo de predecir la pobreza en diferentes zonas o áreas, como son los estudios de [Jean et al. \(2016\)](#), [Hersh et al. \(2020\)](#) y [Zhongming et al. \(2021\)](#).

En esta investigación se sigue un enfoque similar al propuesto por los autores previamente mencionados, toda vez que es una alternativa ventajosa con costos bajos y que puede producir estimaciones más granulares geográficamente, en comparación con las encuestas que se suelen utilizar para la estimación de la pobreza. En específico, en este estudio el objetivo de investigación es pronosticar la incidencia de pobreza a nivel de comunidad en Bolivia para el año 2022, con base en la aplicación de algoritmos de machine learning y teledetección, y evaluar la evolución respecto a la situación observada en 2012. Para esto, se utilizan técnicas de teledetección que procesan la información de imágenes satelitales y, así, construir indicadores sobre las características de las comunidades de Bolivia, que posteriormente son los insumos —predictores— para entrenar algoritmos de machine learning que pronostiquen la pobreza con una precisión aceptable. Con los algoritmos entrenados y validados, se pronostica la incidencia de pobreza, según Necesidades Básicas Insatisfechas, por comunidad para el año 2022.

Esta investigación no solo contribuye al avance del conocimiento en la estimación de la pobreza a nivel comunitario, sino que también tiene el potencial de informar políticas económicas y sociales más efectivas y orientadas hacia un desarrollo económico inclusivo, así como fortalecer la resiliencia de las comunidades ante diversas adversidades exógenas mediante el fortalecimiento de las economías locales más vulnerables.

## 2. Metodología

En Bolivia, el Censo Nacional de Población y Vivienda (CNPV) de 2012 es la única fuente a partir de la cual se puede conocer la incidencia de pobreza y características socio-económicas de las comunidades. Si bien en años posteriores se encuentran determinados datos actualizados para algunas comunidades, éstos no permiten realizar estimaciones

sobre la incidencia de pobreza en la mayoría de las comunidades del país, ni aplicar un análisis temporal robusto.

Ante estas limitantes, la presente investigación plantea elaborar un marco metodológico para pronosticar la incidencia de pobreza a nivel de comunidad en Bolivia para el año 2022, con base en la aplicación de algoritmos de machine learning y el uso de teledetección para construir variables sobre las características de las comunidades, de tal manera que sean los insumos para el pronóstico de pobreza.

En las siguientes subsecciones se profundizan los aspectos metodológicos; empero, la metodología se resume en dos pasos:

1. Para los años 2012 y 2022, se generan variables sobre las características de las comunidades a partir del procesamiento de información de imágenes satelitales (i.e., teledetección).
2. Se entrena un algoritmo de machine learning que pronostica de manera adecuada la incidencia de pobreza a nivel de comunidad observada en el CNPV 2012, de tal manera que estos modelos validados son empleados para predecir la pobreza por comunidad en 2022. Tanto el entrenamiento como el pronóstico de estos algoritmos se realiza con las variables construidas en el Paso 1, que implica el procesamiento de información de imágenes satelitales.

## 2.1. Datos

Inicialmente, es importante aclarar que la teledetección es una técnica que emplea sensores (e.g., de satélites) para recopilar información sobre la superficie y la atmósfera de la Tierra a distancia. Este método ha demostrado ser una herramienta valiosa en diversos campos, incluyendo agricultura, silvicultura, geología y estudios ambientales, entre otros. La teledetección también se ha utilizado para generar indicadores socioeconómicos mediante el procesamiento de información satelital, que proporciona datos detallados y precisos sobre la distribución y las características de los asentamientos humanos, la infraestructura y las actividades económicas.

Este enfoque ha demostrado ser eficaz para monitorear la urbanización, el crecimiento de la población y el desarrollo económico, entre otros aspectos, permitiendo a los hace-dores de política e investigadores tomar decisiones informadas y desarrollar estrategias sostenibles. Por lo tanto, la aplicación de técnicas de teledetección en la generación de indicadores socioeconómicos podría convertirse en un instrumento esencial para comprender y gestionar las complejas interacciones entre las actividades humanas y el medio ambiente.

Los siguientes subtítulos explican la definición de la variable objetivo, las unidades de observación (i.e., comunidades de estudio) y las variables de caracterización de las comunidades.

### 2.1.1. Variable de pobreza

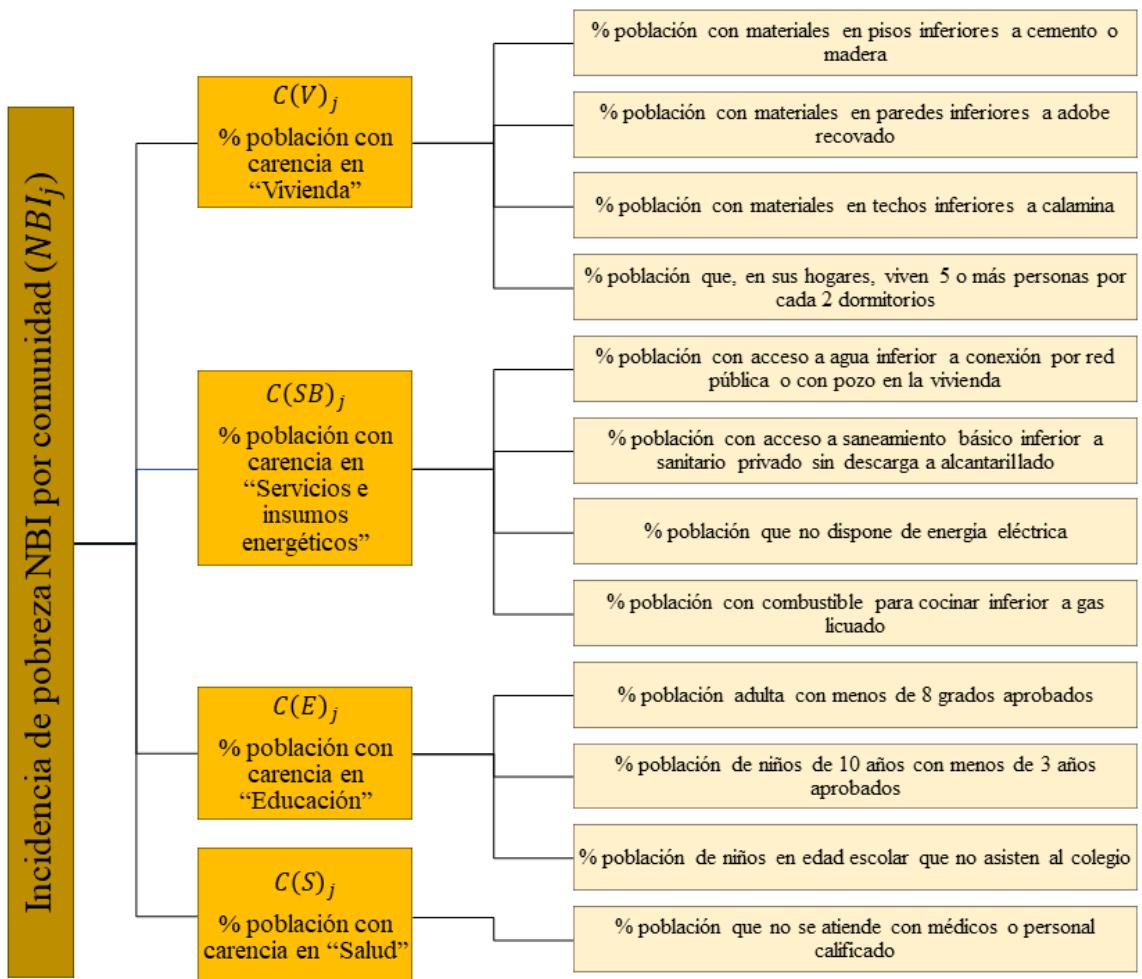
Es convencional utilizar datos censales para medir la pobreza con base en el método de Necesidades Básicas Insatisfechas (NBI), sobre todo si el análisis requiere una desagregación alta a nivel geográfico. Este método concibe la pobreza como necesidad y analiza las carencias de los bienes que permiten a un hogar satisfacer sus necesidades esenciales. Este método se caracteriza por identificar la pobreza de tipo estructural, debido a que las variables que lo conforman varían lentamente a lo largo del tiempo; no captura situaciones

de pobreza reciente o coyuntural puesto que no incorpora variables como el ingreso o el empleo que pueden ser muy volátiles.

Para Bolivia, a pesar de contar con los datos del CNPV 2012, no existe una publicación oficial con métricas sobre la pobreza por NBI a nivel de comunidad; en cambio, no es posible generar variables de pobreza monetaria o multidimensional para las comunidades porque no se cuenta con información que permita el cálculo con esa desagregación espacial.

Ante esta limitante, para este estudio se procesaron los datos socioeconómicos del CNPV 2012 siguiendo las directrices metodológicas de necesidades básicas insatisfechas ([INE, 2015](#)), con el objetivo de construir un indicador de pobreza por NBI que estima el porcentaje de la población con carencias (i.e., con necesidades básicas insatisfechas) para cada comunidad. La Figura 1 muestra una síntesis del indicador de incidencia de pobreza NBI por comunidad.

Figura 1: Indicador de pobreza NBI por comunidad



En concreto, la incidencia de pobreza ( $NBI_j$ ) en la comunidad  $j$  es el valor promedio de los porcentajes de carencia en los componentes que explican las NBI para esa comunidad:  $C(V)_j$ ,  $C(SB)_j$ ,  $C(E)_j$  y  $C(S)_j$ . Similarmente, la carencia en cada componente es definida como el valor promedio de las variables que las integran.

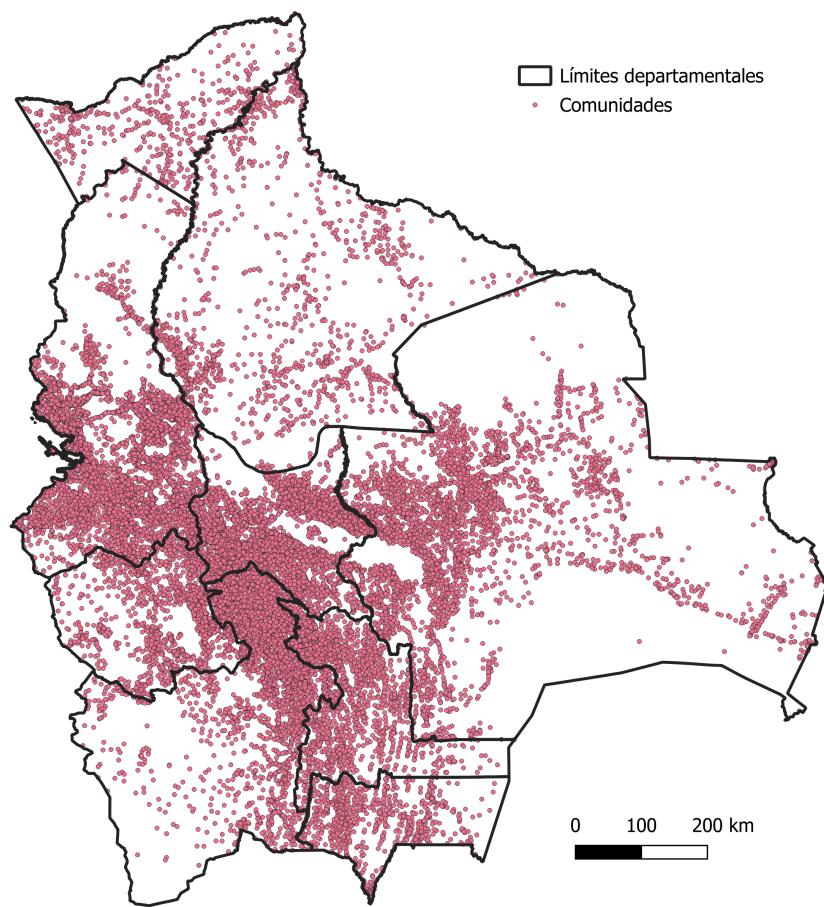
$$NBI_j = \frac{C(V)_j + C(SB)_j + C(E)_j + C(S)_j}{4} \quad (1)$$

Es importante aclarar que, en el marco de la metodología asumida, el indicador  $NBI_j$  muestra el porcentaje de la población, en una comunidad  $j$ , que es pobre porque vive en condiciones inferiores a las Normas Mínimas para satisfacer sus necesidades básicas. Es decir, este porcentaje de la población se encuentra en las categorías de pobreza moderada, indigencia o marginalidad, según los parámetros establecidos en la metodología de NBI.

### 2.1.2. Unidades de observación

El CNPV 2012 registra 19.420 comunidades en Bolivia; sin embargo, no se cuenta con una fuente oficial sobre los límites geográficos de estas comunidades.<sup>2</sup> Dado que, en esta propuesta de investigación, la información sobre características de las comunidades —potenciales predictores de la pobreza— se deriva del procesamiento de imágenes satelitales, es necesario establecer la extensión o concentración espacial de la población en las comunidades. Para delimitar la extensión de las comunidades se siguió el siguiente procedimiento:

Figura 2: Geo-referencia en puntos de las comunidades de Bolivia



Fuente: Elaboración propia con datos del INE e IGM.

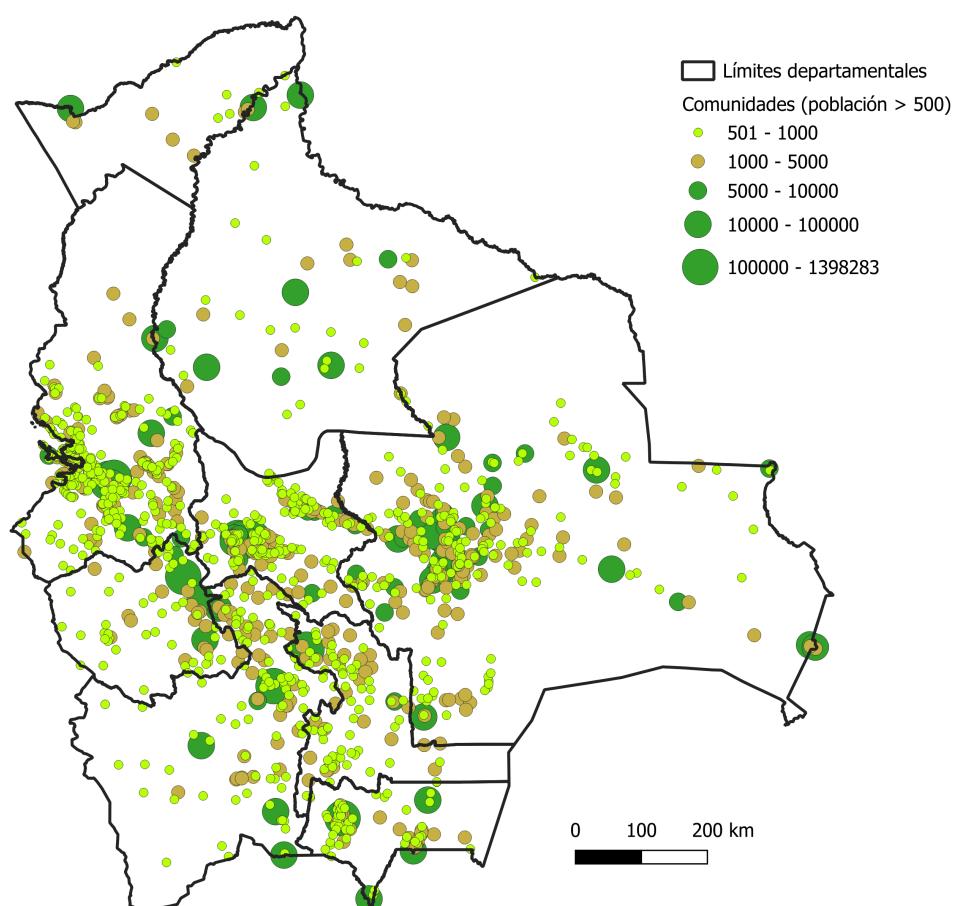
1. Se obtuvo un archivo vectorial con la localización geo-referenciada en puntos de las comunidades —registradas en el CNPV 2012— en el territorio nacional (Figura

<sup>2</sup>El conteo de las comunidades e información socioeconómica para la gestión 2012 se obtiene de bases de datos publicadas por el Instituto Nacional de Estadística.

2), elaborado por el Instituto Nacional de Estadística (INE) y consensuado con la sección de cartografía del Instituto Geográfico Militar (IGM).<sup>3</sup> De esta manera, se conoce la latitud y longitud referencial de las comunidades. Además, cada registro de comunidad tiene un código geográfico, útil para el emparejamiento con otras bases de datos.

2. El alcance de esta investigación se restringe a comunidades con una población mayor a 500 habitantes (Figura 3). Los hogares en comunidades con una población menor tienden a estar dispersos, lo que dificulta no solo el establecimiento de la potencial extensión de la comunidad, sino también la construcción de indicadores sobre sus características. De esta manera, la estimación de la incidencia de pobreza y comparación respecto a la situación de 2012 se realizará para 953 comunidades de estudio.

Figura 3: Geo-referencia en puntos de las unidades de observación



Fuente: Elaboración propia con datos del INE e IGM.

3. Se crea un archivo vectorial con una grilla de celdas de 500 metros por 500 metros, para toda la extensión del territorio de Bolivia.

---

<sup>3</sup>La base de datos de este archivo contiene la localización de 23.891 comunidades, que se asume incluyen aquellas identificadas tanto en el CNPV 2012 como en el Censo Nacional Agropecuario 2013. Para la presente investigación se filtraron solo las comunidades que corresponden al CNPV 2012. Esta información se encuentra disponible en el portal GeoBolivia.

4. Se obtiene una capa vectorial con la delimitación, en polígonos, de las comunidades en Bolivia para el año 2001. Este archivo es una referencia adicional sobre la potencial extensión de estas unidades geográficas.<sup>4</sup>
5. En el archivo vectorial de grilla del paso (3), se eliminan las celdas que no cumplen con los requisitos de:
  - a. Estar dentro de uno de los municipios a los que pertenecen las 953 comunidades seleccionadas.
  - b. Estar dentro de uno de los polígonos del archivo vectorial de las comunidades de 2001, exclusivamente en los que corresponden a las 953 comunidades seleccionadas.
6. Para mapear de manera más precisa la posible extensión o concentración espacial de la población en las 953 comunidades seleccionadas, se descargan capas raster —con información de imágenes satelitales— que son útiles para el mapeo de zonas construidas y conglomerados poblacionales. Los archivos raster son los siguientes:
  - a. Luminosidad nocturna: Existe evidencia robusta sobre la sólida correlación entre las luces nocturnas (luminosidad), captadas por imágenes satelitales, y la actividad económica en varios niveles, incluidos los nacionales, estatales y regionales, así como a una resolución más granular ([Chen y Nordhaus, 2011](#); [Ghosh et al., 2010](#); [Henderson et al., 2012](#)). Por lo tanto, la luminosidad puede servir como un indicador fiable de la actividad económica (ingreso, pobreza y otros) en zonas donde los datos son escasos, o los sistemas estadísticos son de baja calidad, o donde no se dispone de censos recientes. En este marco, se asume que los lugares con mayor intensidad de luminosidad muestran la concentración de población, infraestructura y actividad económica. En consecuencia, se procesó un archivo raster con los valores promedio de luminosidad en píxeles de 500 metros, para los años 2012 y 2022.<sup>5</sup> Para lograr esto, se trabaja con la colección de imágenes “*VIIRS Lunar Gap Filled BRDF Nighttime Lights Daily L3 Global 500m*”, que son producidas por el Land Processes Distributed Active Archive Center (LP DAAC) de la NASA. Este producto proporciona imágenes de luminosidad corregidas por la luz de la luna y la atmósfera.
  - b. Zonas urbanas y construidas: La clasificación de zonas urbanas y/o construidas implica identificar y mapear áreas de tierra con desarrollo humano de alta densidad, como edificios e infraestructura. Las técnicas de teledetección pueden proporcionar información valiosa sobre la dinámica espacial y temporal de las áreas urbanizadas ([Liu et al., 2021](#); [Zhou et al., 2021](#)). Se pueden utilizar las clasificaciones de uso de suelos, con énfasis en las áreas urbanas y de construcción, para estimar el crecimiento económico, identificar áreas de actividad económica y monitorear la expansión urbana. Para identificar potenciales zonas urbanas y construidas en Bolivia, se obtuvieron imágenes del producto “*MODIS Land Cover Type Yearly Global 500m*”, que proporciona mapas globales con la cobertura de uso de suelos en frecuencia anual y resolución espacial de 500 metros. Se adopta la leyenda MCD12Q1 del Programa Internacional de la

<sup>4</sup>Este archivo vectorial se encuentra disponible en el portal GeoBolivia.

<sup>5</sup>Estos archivos raster tienen frecuencia mensual. Por esta razón, se generan imágenes anuales al promediar los niveles de luminosidad mensuales.

Geosfera-Biosfera (IGBP) para definir 17 categorías de uso de suelos, para la gestión 2022, incluidos bosques, matorrales, sabanas, pastizales, cultivos, áreas urbanas y construidas, cuerpos de agua y zonas estériles. Cada píxel tiene una cubierta terrestre dominante asignada.<sup>6</sup>

- c. Capa Global de Asentamientos Humanos: El Global Human Settlement Layer (GHSL) es una capa raster ampliamente reconocida que ofrece cobertura mundial de zonas urbanizadas; este conjunto de datos de alta resolución fue desarrollado por la Comisión Europea y proporciona información detallada sobre la distribución espacial de los asentamientos humanos en todo el mundo (Meli-chiorri et al., 2018). El GHSL se genera utilizando imágenes satelitales, datos censales y otras fuentes de datos, y proporciona información sobre áreas urbanizadas, densidad de población y otras características urbanas. Para este estudio, se cuenta con una imagen raster del GHSL correspondiente a la gestión 2015 —última actualización—, con la clasificación de áreas inhabitadas, rurales y, clústeres urbanos de baja y alta densidad, en una resolución espacial de 1.000 metros.

Por ejemplo, en la Figura 4 se observa cómo algunos píxeles de las imágenes raster de luminosidad (4-b), uso de suelos clasificados como zona urbana/construida (4-c, en color purpura) y asentamientos humanos (4-d) se sobreponen a las áreas que ocuparían 2 comunidades con poblaciones entre 1.000 y 5.000 habitantes.

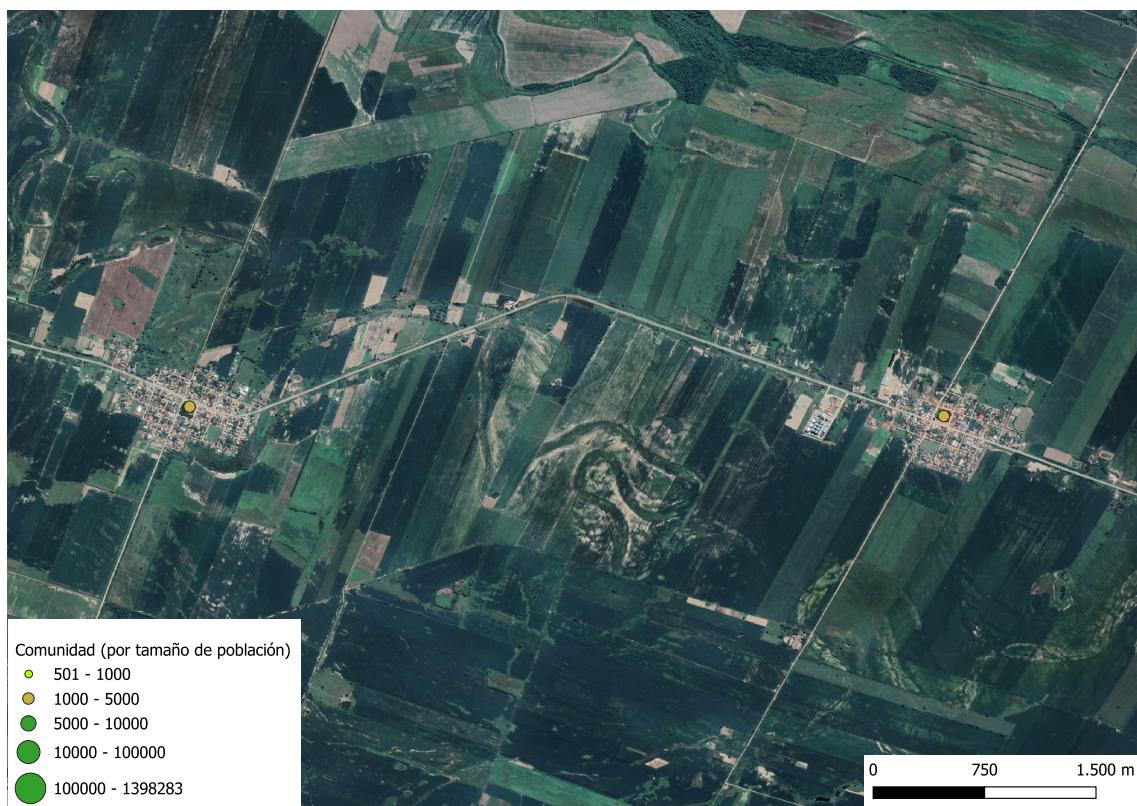
- 7. En el archivo vectorial de grilla definido en el paso (5), se eliminan las celdas que no cumplen al menos dos de los siguientes tres requisitos:
  - a. Tener una intensidad de luminosidad de al menos 0,5.
  - b. Tener la clasificación de “áreas urbanas y construidas” en la capa raster “MODIS Land Cover Type Yearly Global 500m”.
  - c. Tener la clasificación de “clústeres urbanos de baja o alta densidad” en la capa raster “Global Human Settlement Layer”.
- 8. A cada celda restante se le asigna un código geográfico de comunidad según el municipio en el que se posiciona, así como, según su cercanía a los puntos georeferenciados de las comunidades del CNPV 2012 y a los polígonos de comunidades de 2001 que integran.
- 9. Finalmente, para una comunidad  $j$ , su extensión es el área que cubren los píxeles (celdas) que tienen el código geográfico de dicha comunidad. Por ejemplo, en la Figura 5 se observa cómo queda definida la extensión para la comunidad Corani Pampa, que pertenece al municipio de Colomi en Cochabamba. Esta comunidad tenía una población de 940 habitantes en 2012. La imagen satelital muestra que algunas casas e infraestructuras en esta comunidad están relativamente dispersas; no obstante, se evidencia que la metodología implementada logra capturar esos aspectos.

---

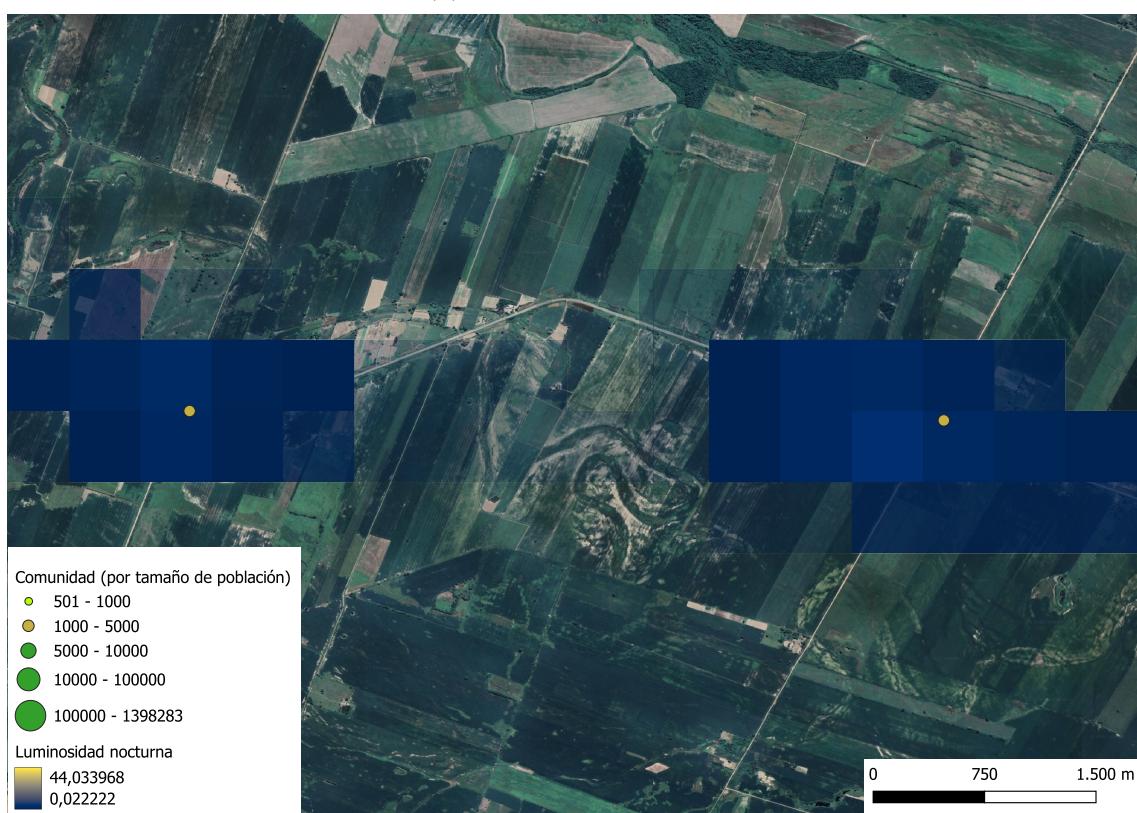
<sup>6</sup>Se utiliza la capa de 2022 porque de esa manera se puede capturar la mayor expansión de las comunidades en el tiempo; por ejemplo, si se utilizaba la capa de 2012, se podría incurrir en una subestimación de la extensión de las comunidades.

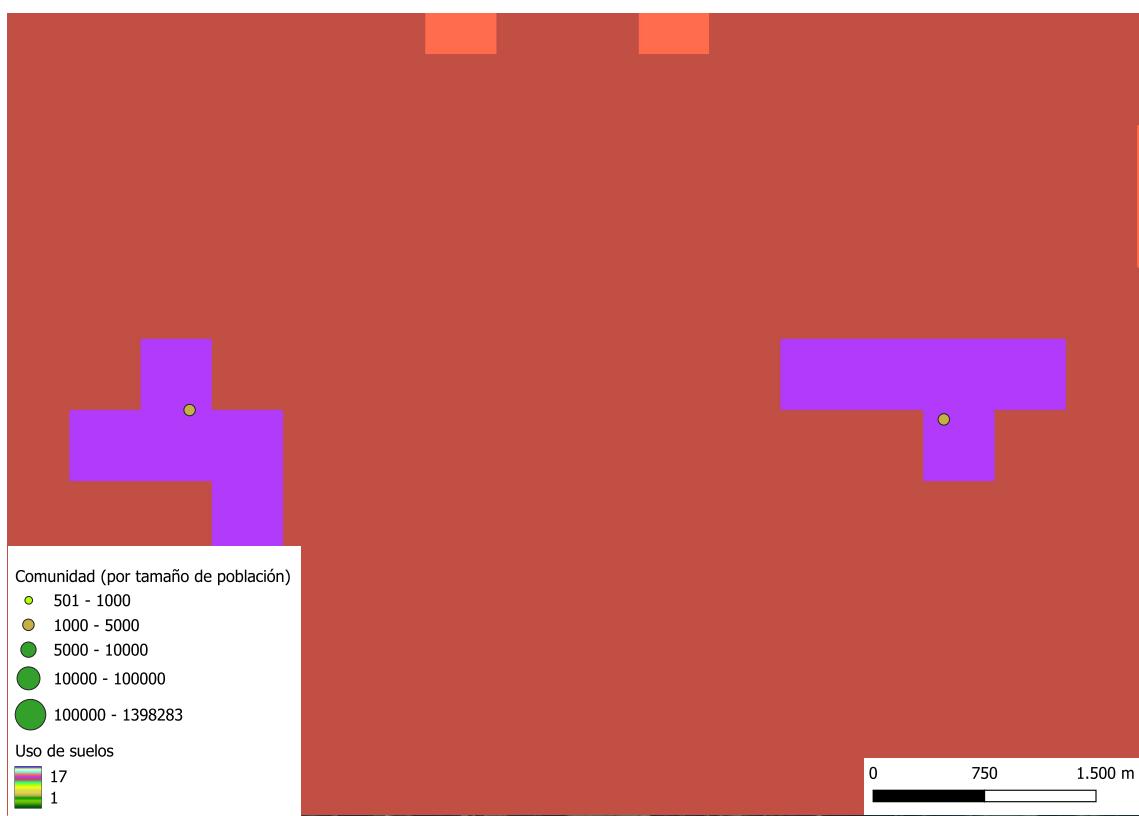
Figura 4: Capas raster para definir la extensión de comunidades

(a) Imagen satelital

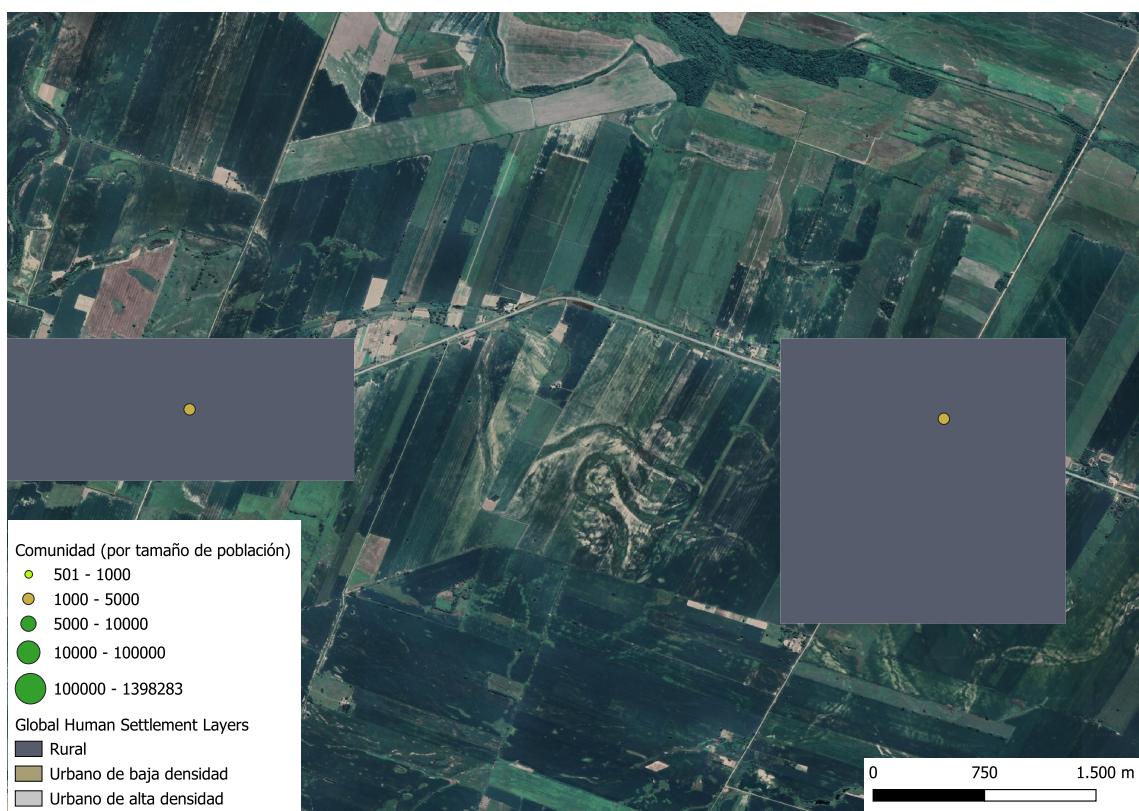


(b) Luminosidad nocturna





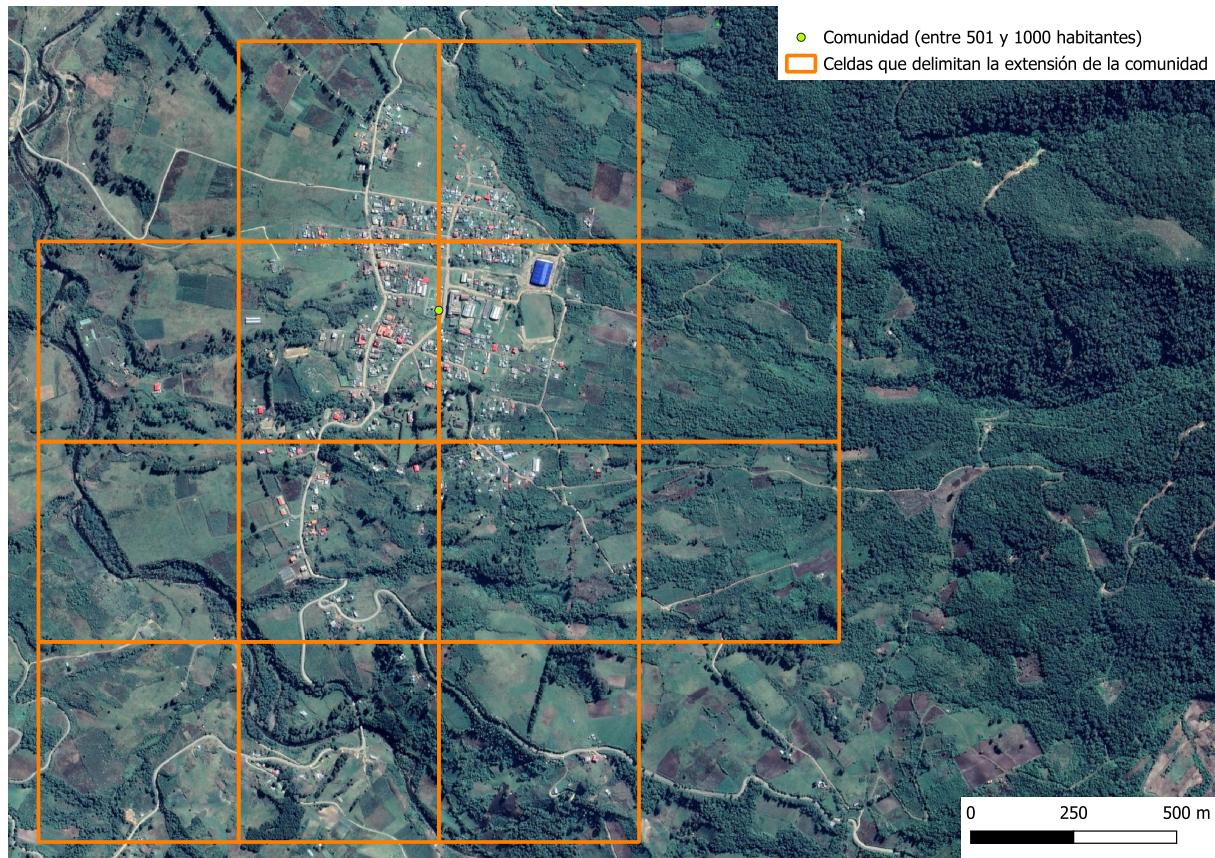
(c) Uso de suelos



(d) Capa Global de Asentamientos Humanos

Fuente: Elaboración propia con datos de Google, NASA, MODIS, y European Commission.

Figura 5: Extensión de la comunidad Corani Pampa



Fuente: Elaboración propia.

Es importante señalar que la metodología asumida para delimitar la extensión de las 953 comunidades de estudio tiene la virtud de capturar la concentración de la población, infraestructura y actividad económica en estas unidades geográficas, lo que es de mucha utilidad para la generación de las variables de caracterización de las comunidades, que son explicadas en el siguiente subtítulo.

Cabe enfatizar que la definición de las extensiones en las comunidades de estudio no pretende, en lo más mínimo, proporcionar referencias sobre los límites legales en las comunidades de Bolivia.

### 2.1.3. Potenciales predictores de la pobreza

Si bien con los datos del CNPV 2012 se calculó la incidencia de pobreza por NBI para las unidades de observación en la gestión 2012, es necesario compilar y procesar información de imágenes satelitales con el objetivo de generar variables sobre características de las comunidades, que sea útiles para el pronóstico de la pobreza. En los siguientes subtítulos se explican las variables de caracterización de las comunidades de estudio.

#### Luminosidad nocturna

En la sección 2.1.2 se explica el uso de la colección de imágenes satelitales “VIIRS Lunar Gap Filled BRDF Nighttime Lights Daily L3 Global 500m” como insumo para delimitar la extensión de las comunidades de estudio. Estas imágenes sobre luminosidad también son utilizadas para construir potenciales predictores de la pobreza en las unidades

de observación, toda vez que las variaciones de la luminosidad han demostrado ser proxies adecuados para explicar las diferencias a nivel de sección cruzada y temporal en los niveles de ingreso, por ende, en los grados de pobreza.

En específico, se descargan imágenes de luminosidad para las gestiones 2012 y 2022, que cubren la extensión de Bolivia. Luego, para una comunidad  $j$  en el año  $t$  ( $t = 2012, 2022$ ) se construye el indicador de intensidad de luminosidad promedio ( $L_{j,t}^{mean}$ ), que es el promedio de los valores de luminosidad en los píxeles ( $l_{i,t}; \forall i = 1, \dots, N$ ) ubicados dentro los límites de la comunidad.

$$L_{j,t}^{mean} = \frac{1}{N} \sum_{i=1}^N l_{i,t} \quad (2)$$

También, como es convencional en la literatura vinculada al uso de imágenes de luminosidad, con esta información se genera la variable de suma de intensidad de luminosidad nocturna en la comunidad ( $L_{j,t}^{sum}$ ), que es la suma de los valores de luminosidad en los píxeles ( $l_{i,t}; \forall i = 1, \dots, N$ ) dentro la extensión de la comunidad.

$$L_{j,t}^{sum} = \sum_{i=1}^N l_{i,t} \quad (3)$$

### Cobertura de uso de suelos

Las imágenes satelitales son una herramienta valiosa para monitorear la cobertura de uso de suelo y su cambio a lo largo del tiempo. Esta información puede ser utilizada como proxy de la actividad económica y la pobreza, ya que el tipo de cobertura de uso de suelo está estrechamente relacionado con el nivel de desarrollo económico de una región. Por ejemplo, las áreas con una alta densidad de población suelen tener una mayor proporción de áreas urbanas, que suelen ser más ricas que las áreas rurales, por lo que el uso de imágenes satelitales para identificar las áreas urbanas puede ser un método para diferenciar áreas según sus niveles de ingreso.

Asimismo, las imágenes satelitales también pueden ser utilizadas para identificar los cambios en la cobertura de uso de suelo a lo largo del tiempo. Estos cambios pueden ser un indicador de cambios en la actividad económica. Por ejemplo, si una zona que anteriormente era agrícola se vuelve urbana, esto puede indicar que la zona está experimentando un crecimiento económico (Liu et al., 2021; Zhou et al., 2021).

En este marco, para los años 2012 y 2022,<sup>7</sup> se descargaron imágenes del producto MODIS sobre Cobertura de Uso de Suelos (MCD12Q1), que proporcionan mapas globales de cobertura de uso de suelos con frecuencia anual y 500 metros de resolución espacial.<sup>8</sup> En el marco de esta información, se cuenta con 17 coberturas de uso de suelo que incluyen distintos tipos de bosques, matorrales, sabana, pastizales, cultivos, zonas urbanas, cuerpos de agua, etc. Por lo tanto, cada píxel tiene asignado una cobertura de uso de suelo dominante.

---

<sup>7</sup>En realidad no existen datos disponibles para el año 2022, por lo que se emplearon las clasificaciones de la gestión 2021. Se considera que esta aproximación es válida porque la cobertura de uso de suelos es una característica poco sensible a cambios significativos en el corto plazo.

<sup>8</sup>Este producto es desarrollado por la NASA e incluye 5 esquemas de clasificación de cobertura de uso de suelos. Para la presente investigación, se trabajó con el esquema de clasificación del Programa Internacional Geosfera-Biosfera (IGBP, por sus siglas en inglés) que identifica 17 tipos de uso de suelos.

Dado que se cuenta con múltiples coberturas de uso de suelos, se generan indicadores sobre el área (en kilómetros cuadrados) de la extensión en las comunidades que corresponde a las siguientes coberturas de uso de suelos:

- Zonas urbanas
- Cultivos grandes
- Cultivos pequeños
- Bosques
- Matorrales
- Sabana
- Pastizales
- Cuerpos de agua

Por ejemplo, en la comunidad  $j$  durante el año  $t$ , el área de cultivos grandes ( $A_{j,t}^{cul_g}$ ) es definido como el número de píxeles categorizados como cultivos grandes dentro la extensión de la comunidad ( $M_{i,t}^{cul_g}$ ) multiplicado por 0,25 (cada píxel de 500 metros cubre un área de 0,25km<sup>2</sup>).

$$A_{j,t}^{cul_g} = M_{i,t}^{cul_g} \times 0,25 \quad (4)$$

### Asentamientos urbanos

La clasificación de asentamientos urbanos implica identificar y mapear áreas de tierra con desarrollo humano de alta densidad, como edificios e infraestructura. Estas áreas son fuertes indicadores de la actividad económica, ya que generalmente corresponden a áreas de alta densidad de población y productividad económica. En este ámbito, las técnicas de teledetección son útiles para aproximar la dinámica espacial y temporal de las áreas con estas características.

En la sección 2.1.2, se explica la aplicación de la capa raster “*Global Human Settlement Layer (GHSL)*” como insumo para la delimitación de la extensión de las comunidades de estudio. Por sus características, la capa GHSL también puede ser empleada para generar predictores de la pobreza en las comunidades. La capa GHSL solo está disponible para 2015; sin embargo, para el cumplimiento del objetivo de esta investigación se requiere información de esta capa para los años 2012 y 2022.

Para lidiar con este problema, se predicen las clasificaciones de asentamientos urbanos para 2012 y 2002 con base en el entrenamiento de un algoritmo de Random Forest (RF), utilizando imágenes GHSL de 2015 para clasificar píxeles de 1 km como asentamientos urbanos, con datos de las bandas azul, verde, roja, infrarroja cercana e infrarroja de onda corta 1 y 2 del satélite Landsat-8 e imágenes de luminosidad nocturna a nivel de píxel. El modelo de RF se elige debido a su efectividad y uso generalizado en varios dominios y problemas (Duro et al., 2012).

Las imágenes de GHSL clasifican las áreas según su grado de urbanización, como grupos deshabitados, rurales y, urbanos de baja y alta densidad. Sin embargo, ya se mencionó que solo se realizará una clasificación binaria de asentamientos urbanos, por lo

que los grupos urbanos de baja y alta densidad se definen como asentamientos urbanos para el entrenamiento del algoritmo, mientras que las áreas deshabitadas y rurales se definen como zonas sin asentamientos urbanos. Las imágenes utilizadas en la etapa de entrenamiento son del 2015, que es la última actualización de GHSL. Los píxeles dentro de las imágenes se separan aleatoriamente en un set de entrenamiento (70 %) y un set de validación (30 %).

Para validar el algoritmo entrenado, se utilizan como métricas la precisión (ACC, por sus siglas en inglés) y el coeficiente de correlación de Matthews (MCC, por sus siglas en inglés). El ACC mide la proporción de predicciones correctas hechas por el clasificador, mientras que el MCC mide la correlación entre las etiquetas predichas y reales, teniendo en cuenta las tasas positivas y negativas verdaderas. El rendimiento del algoritmo en la muestra de entrenamiento suele ser mayor que el de la muestra de validación, porque el algoritmo ha aprendido de la muestra de entrenamiento y ha optimizado sus parámetros para ajustarse a los datos de entrenamiento. Por lo tanto, el desempeño del algoritmo es evaluado con las métricas ACC y el MCC de la muestra de validación.<sup>9</sup>

En la muestra de entrenamiento, los valores de ACC y MCC son considerablemente altos, con 0,996 y 0,927, respectivamente; Estos resultados indican un desempeño excepcional en términos de clasificación dentro de este subconjunto específico. En cuanto al rendimiento de la muestra de validación, el ACC sigue siendo considerablemente alto (0,988); sin embargo, el MCC es relativamente menor (0,721) en comparación con el observado en la muestra de entrenamiento. Esto indica que el algoritmo puede haberse sobreajustado a los datos de entrenamiento y no se está generalizando bien a los nuevos datos. No obstante, en general, una puntuación MCC de 0,5 o superior se considera un buen rendimiento, mientras que una puntuación de 0 indica un clasificador completamente aleatorio.

Este algoritmo entrenado y validado se utiliza para generar capas raster con la clasificación de asentamientos urbanos en toda la extensión de Bolivia, a una resolución espacial de 500 metros, para los años 2012 y 2022.

Finalmente, para el año  $t$  en la comunidad  $j$ , el área de asentamientos urbanos ( $A_{j,t}^{au}$ ) es definido como el número de píxeles clasificados como asentamientos urbanos dentro la extensión de la comunidad ( $M_{i,t}^{au}$ ) multiplicado por 0,25.

$$A_{j,t}^{au} = M_{i,t}^{au} \times 0,25 \quad (5)$$

### Datos de Open Street Map

La utilización de variables de datos de Open Street Map (OSM) como predictores de ingreso y pobreza ofrece una forma novedosa de abordar problemas económicos y sociales en regiones donde la disponibilidad de datos tradicionales puede ser limitada —es el caso de Bolivia— (Feldmeyer et al., 2020). OSM es una plataforma colaborativa que proporciona información geoespacial detallada sobre características geográficas, infraestructura y servicios en diferentes áreas geográficas. Al aprovechar la riqueza de información geoespacial disponible en OSM, los investigadores pueden obtener una comprensión más completa de

---

<sup>9</sup>El MCC es más apropiado para clasificar zonas de asentamientos urbanos ya que la mayoría de los píxeles GHSL en Bolivia son áreas no urbanizadas. La región de interés para la clasificación abarca zonas alrededor de las principales áreas urbanas de Bolivia, con una extensión suficiente para garantizar la inclusión de áreas representativas urbanas y no urbanas de diferentes regiones del país y características geográficas variadas. La región de interés contiene un total de 5722 píxeles de 1 km (es decir, 5722 observaciones; 4005 en el conjunto de entrenamiento y 1717 en el conjunto de validación).

los determinantes del desarrollo socioeconómico a nivel regional y, a su vez, contribuir a la formulación de políticas más efectivas para abordar la pobreza y promover el crecimiento inclusivo.

Las variables derivadas de OSM, como la presencia de escuelas, bancos, hospitales, mercados y la densidad de caminos, son adecuadas para predecir la pobreza a nivel de comunidades debido a que proporcionan una valiosa información sobre la infraestructura y los servicios disponibles en una determinada área geográfica. Estos indicadores reflejan el acceso a servicios básicos y oportunidades económicas, que son fundamentales para el bienestar y desarrollo socioeconómico de las comunidades.

Por lo tanto, se aprovechan los datos de OSM para generar las siguientes variables en las comunidades de estudio.

- Número de cajeros automáticos
- Número de bancos
- Número de escuelas
- Número de clínicas
- Número de hospitales
- Número de mercados públicos
- Densidad de vías secundarias
- Densidad de vías terciarias

Para los casos de cajeros automáticos, bancos, escuelas, clínicas, hospitales y mercados públicos, se dispone de capas vectoriales con la geolocalización en puntos de estos servicios. Así, para una comunidad  $j$ , en el año  $t$  y para el servicio  $s$ , se realiza el conteo de los puntos del servicio  $s$  que están dentro la extensión de la comunidad. Por ejemplo, la siguiente formulación corresponde al servicio de hospitales.

$$S_{j,t,hospital} = \sum hospital \quad (6)$$

Por otra parte, se descargaron capas vectoriales de líneas sobre las vías secundarias y terciarias para el territorio de Bolivia. Con esta información, para una comunidad  $j$  en el año  $t$ , se construye el indicador de densidad de vías secundarias ( $V_{j,t}^{sec}$ ) como el ratio entre la longitud total (en km) de estas vías dentro la extensión de la comunidad ( $\sum_{i=1}^N v_{i,t}^{sec}$ ) respecto al área total de la comunidad ( $A_j$ ). Un procedimiento similar se aplica para el indicador de densidad de vías terciarias ( $V_{j,t}^{ter}$ )

$$V_{j,t}^{sec} = \frac{\sum_{i=1}^N v_{i,t}^{sec}}{A_j} \quad (7)$$

### Índices de vegetación

Las regiones rurales y más pobres tienden a depender en gran medida de la agricultura (Diao et al., 2010), por lo que mejores condiciones de rendimiento y calidad de las tierras cultivadas estarían asociadas con mayor actividad económica, por ende, menores niveles

de pobreza. En este contexto, entre los predictores de la pobreza a nivel de comunidad se construyen indicadores sobre la calidad de la vegetación, procesados con información de imágenes satelitales.

Los índices de calidad de la vegetación son formulaciones matemáticas que cuantifican el estado y la salud de la vegetación utilizando datos satelitales. Al analizar los índices de vegetación, se pueden estimar los rendimientos de los cultivos, identificar áreas potenciales de estrés de los cultivos y optimizar las estrategias de manejo de los cultivos.

En específico, se utilizan las capas raster: “*Normalized Difference Vegetation Index (NDVI)*”; y “*Enhanced Vegetation Index (EVI)*”.<sup>10</sup> El NDVI es uno de los índices de vegetación más convencionales, con series temporales extensas y continuas, utilizando las bandas roja e infrarroja cercana (NIR).<sup>11</sup> El EVI es un índice de vegetación ligeramente diferente que es más sensible a la cubierta del dosel arbóreo, mientras que el NDVI es más sensible a la clorofila.

Con esta información, para una comunidad  $j$ , en el año  $t$  y el índice de vegetación  $v$  ( $v = NDVI, EVI$ ) se construye el indicador de calidad de la vegetación promedio ( $C_{j,t,v}$ ), que es el promedio de los valores del índice de vegetación  $v$  en los píxeles ( $c_{i,t,v}; \forall i = 1, \dots, N$ ) sobrepuertos a la extensión de la comunidad.

$$C_{j,t,v} = \frac{1}{N} \sum_{i=1}^N c_{i,t,v} \quad (8)$$

### Condiciones climáticas

El uso de variables de condiciones climáticas como predictores de los niveles de ingreso y pobreza a nivel regional ha ganado relevancia en la investigación económica. Diversos estudios han demostrado que factores climáticos, como la precipitación y la temperatura, pueden tener un impacto significativo en el desarrollo socioeconómico de las comunidades. Por ejemplo, (Burke et al., 2015; Dell et al., 2012; Gallup et al., 1999; Nordhaus, 2006) observan que las temperaturas más altas resultan en una reducción significativa del crecimiento económico. Similarmente, variaciones en la precipitación pueden afectar negativamente la productividad agrícola y, en consecuencia, disminuir los ingresos de los hogares en zonas rurales y aumentar la pobreza (Lambert, 2014; Mueller y Osgood, 2009). También, Cevik y Jalles (2023b) encuentran que un aumento en la vulnerabilidad al cambio climático se asocia positivamente con una creciente desigualdad de ingresos, especialmente en los países en desarrollo debido en gran medida a una capacidad más débil para la adaptación y mitigación del cambio climático. Sequías y tormentas a su vez tendrían efectos negativos sobre el crecimiento económico Cevik y Jalles (2023a).

Estos hallazgos resaltan la importancia de incorporar variables climáticas en el análisis de la pobreza y el ingreso, ya que proporcionan una perspectiva integral para entender los desafíos socioeconómicos que enfrentan las comunidades vulnerables en diferentes regiones.

---

<sup>10</sup>El producto del que sea extrae estas capas es “*The Suomi National Polar-Orbiting Partnership (S-NPP) NASA Visible Infrared Imaging Radiometer Suite (VIIRS) Vegetation Indices (VNP13A1)*”.

<sup>11</sup>Por ejemplo, para el cálculo del NDVI se utiliza información que se encuentra en las bandas roja e infrarroja del espectro electromagnético. Específicamente, se calcula con base en la siguiente formula:

$$NDVI = \frac{(NIR - VIS)}{(NIR + VIS)}$$

Donde  $NIR$  es la banda del infrarrojo cercano y  $VIS$  es la banda visible roja.

De esta manera, para las comunidades de estudio se emplea la base de datos TerraClimate<sup>12</sup> como insumo para la construcción de los siguientes indicadores:

- Evapotranspiración promedio de los últimos 5 años
- Temperatura mínima promedio de los últimos 5 años
- Temperatura máxima promedio de los últimos 5 años
- Precipitación acumulada promedio de los últimos 5 años
- Humedad del suelo promedio de los últimos 5 años
- Velocidad del viento (a 10 metros) promedio de los últimos 5 años
- Índice Palmer de Severidad de Sequia promedio de los últimos 5 años

Es importante resaltar que en las variables de condiciones climáticas se consideran promedios de los últimos 5 años porque los efectos del clima no solo tienen un impacto contemporáneo sobre la producción y la actividad económica, sino también efectos prolongados en el tiempo.

Para ilustrar, en una comunidad  $j$  y el año  $t$ , el indicador de precipitación acumulada promedio ( $TC_{j,t}^{pre}$ ) es la media de los valores de precipitación en los píxeles ( $tc_{i,t}; \forall i = 1, \dots, N$ ) coincidentes con la extensión de la comunidad.

$$TC_{j,t}^{pre} = \frac{1}{N} \sum_{i=1}^N tc_{i,t} \quad (9)$$

### Energía eléctrica

El acceso a energía eléctrica es un factor crucial en el desarrollo económico y la reducción de la pobreza a nivel regional. Diversos estudios han destacado la estrecha relación entre el acceso a energía y el bienestar socioeconómico de las comunidades. Por ejemplo, [Foster y Rosenzweig \(2010\)](#) examinaron el impacto del acceso a la electricidad en el ingreso y la pobreza en áreas rurales de la India y sus hallazgos indicaron que el acceso a energía eléctrica contribuye positivamente al desarrollo productivo y, en última instancia, al aumento de los ingresos de los hogares rurales. [Dinkelman \(2011\)](#) reveló que la electrificación rural en Sudáfrica generó impactos significativos en la creación de empleo y mejoró las condiciones económicas de las comunidades previamente excluidas. Estas investigaciones subrayan la importancia de considerar variables sobre acceso a energía eléctrica al analizar los niveles de ingreso y pobreza a nivel regional, ya que el suministro de energía confiable puede ser un impulsor fundamental del progreso económico y social.

En esta línea, se obtuvieron capas vectoriales sobre la red eléctrica de media tensión en Bolivia para 2012 y 2022. La densidad de la red de electricidad de media tensión por comunidad puede considerarse un buen proxy de acceso a energía eléctrica debido a que refleja la infraestructura y la cobertura de la red eléctrica en una determinada área. Una

---

<sup>12</sup>TerraClimate es un conjunto de datos del clima mensual, en formato raster con resolución espacial de 4638,3 metros, para las superficies terrestres globales. Utiliza interpolación asistida por clima, combinando normales climatológicas de alta resolución espacial del conjunto de datos WorldClim, con una resolución espacial más gruesa, pero datos variables en el tiempo de CRU Ts4.0 y el Japanese 55-year Reanalysis (JRA55).

mayor densidad de la red de media tensión sugiere que la comunidad cuenta con una infraestructura eléctrica más extensa y, por lo tanto, es más probable que los hogares y las empresas tengan acceso a servicios de electricidad confiables. En contraste, las comunidades con baja densidad de la red de media tensión pueden enfrentar dificultades en el acceso a la electricidad, lo que puede limitar las oportunidades económicas y sociales.

Con esta información, para una comunidad  $j$  en el año  $t$ , se construye el indicador de densidad de la red eléctrica de media tensión ( $E_{j,t}$ ) como el ratio entre la longitud total (en km) de esta red dentro la extensión de la comunidad ( $\sum_{i=1}^N e_{i,t}$ ) respecto al área total de la comunidad ( $A_j$ ).

$$E_{j,t} = \frac{\sum_{i=1}^N e_{i,t}}{A_j} \quad (10)$$

### Red Vial Fundamental

El efecto de las carreteras y vías principales sobre el ingreso y pobreza ha sido ampliamente estudiado en la literatura por su estrecha relación con el desarrollo económico y el acceso a oportunidades (Banerjee et al., 2020; Bolívar, 2020,<sup>2</sup>; Bolívar y Ugarte, 2020). Una red de carreteras bien desarrollada facilita el transporte de bienes y servicios, conecta áreas rurales con centros urbanos y mejora la movilidad de las personas, lo que puede tener un impacto significativo en el crecimiento económico y la reducción de la pobreza. Con capas vectoriales de la Red Vial Fundamental para 2012 y 2022,<sup>13</sup> se genera la variable de densidad de vías primarias ( $V_{j,t}^{pri}$ ) como el ratio entre la longitud total de estas vías dentro la comunidad ( $\sum_{i=1}^N v_{i,t}^{pri}$ ) respecto al área total de la comunidad ( $A_j$ ).

$$V_{j,t}^{pri} = \frac{\sum_{i=1}^N v_{i,t}^{pri}}{A_j} \quad (11)$$

### Características fijas en el tiempo

Adicionalmente, se generan tres características fijas en el tiempo sobre las comunidades de estudio que son el área ( $A_j$ ) de la extensión delimitada para las comunidades, así como, el número de píxeles que integran dicha extensión ( $N_j$ ) y la elevación sobre el nivel del mar promedio en estos píxeles ( $E_j$ ). El uso de estas variables como predictores de los niveles de pobreza —o ingreso— a nivel regional se fundamenta en la idea de que las características geográficas y espaciales pueden proporcionar información valiosa sobre la organización y desarrollo de las comunidades; estas características pueden ser indicativos de la densidad poblacional, la urbanización y la disponibilidad de tierras para actividades productivas.

En resumen, el Cuadro 1 incluye el listado de las variables que son utilizadas como predictores de la pobreza por comunidad.

---

<sup>13</sup>Estas capas son desarrolladas por el Ministerio de Obras Públicas y están disponibles en el portal GeoBolivia.

Cuadro 1: Predictores de la pobreza por comunidad

Variable	Unidad
Intensidad de luminosidad promedio ( $L_{j,t}^{mean}$ )	Radiancia
Suma de intensidad de luminosidad ( $L_{j,t}^{sum}$ )	Radiancia
Área de zonas urbanas/construidas ( $A_{j,t}^{zu}$ )	Km <sup>2</sup>
Área de cultivos grandes ( $A_{j,t}^{cul_g}$ )	Km <sup>2</sup>
Área de cultivos pequeños ( $A_{j,t}^{cul_p}$ )	Km <sup>2</sup>
Área de bosques ( $A_{j,t}^{bos}$ )	Km <sup>2</sup>
Área de matorrales ( $A_{j,t}^{mat}$ )	Km <sup>2</sup>
Área de sabana ( $A_{j,t}^{sab}$ )	Km <sup>2</sup>
Área de pastizales ( $A_{j,t}^{pas}$ )	Km <sup>2</sup>
Área de cuerpos de agua ( $A_{j,t}^{agua}$ )	Km <sup>2</sup>
Área de asentamientos urbanos ( $A_{j,t}^{au}$ )	Km <sup>2</sup>
Número de cajeros automáticos ( $S_{j,t,cajero}$ )	Número de puntos
Número de bancos ( $S_{j,t,banco}$ )	Número de puntos
Número de escuelas ( $S_{j,t,escuela}$ )	Número de puntos
Número de clínicas ( $S_{j,t,clinica}$ )	Número de puntos
Número de hospitales ( $S_{j,t,hospital}$ )	Número de puntos
Número de mercados públicos ( $S_{j,t,mercado}$ )	Número de puntos
Densidad de vías primarias ( $V_{j,t}^{pri}$ )	Km/ Km <sup>2</sup>
Densidad de vías secundarias ( $V_{j,t}^{sec}$ )	Km/ Km <sup>2</sup>
Densidad de vías terciarias ( $V_{j,t}^{ter}$ )	Km/ Km <sup>2</sup>
NDVI promedio ( $C_{j,t,NDVI}$ )	Índice
EVI promedio ( $C_{j,t,EVI}$ )	Índice
Evapotranspiración promedio ( $TC_{j,t}^{et}$ )	mm
Temperatura mínima promedio ( $TC_{j,t}^{tmin}$ )	Grados C°
Temperatura máxima promedio ( $TC_{j,t}^{tmax}$ )	Grados C°
Precipitación acumulada promedio ( $TC_{j,t}^{pre}$ )	mm
Humedad del suelo promedio ( $TC_{j,t}^{sue}$ )	mm
Velocidad del viento (a 10 metros) promedio ( $TC_{j,t}^{vv}$ )	m/s
Índice Palmer de Severidad de Sequía promedio ( $TC_{j,t}^{palmer}$ )	Índice
Densidad de la red eléctrica de media tensión ( $E_{j,t}$ )	Km/ Km <sup>2</sup>
Área de la comunidad ( $A_j$ )	Km <sup>2</sup>
Número de píxeles en la comunidad ( $N_j$ )	Unidades
Elevación promedio ( $E_j$ )	msnm

#### 2.1.4. Sets de entrenamiento, validación y producción

En el Cuadro 1 se listan 33 variables —generadas con datos de imágenes satelitales— que son empleadas como potenciales predictores de la pobreza a nivel de comunidad; estas variables están disponibles para las 953 comunidades de estudio en los años 2012 y 2022. Asimismo, se dispone de la variable de incidencia de pobreza NBI para las 953 unidades de observación, pero solo para el año 2012. Es así que el objetivo de la investigación es pronosticar la incidencia de pobreza a nivel de comunidad en Bolivia para el año 2022, con base en la aplicación de algoritmos de machine learning y teledetección, y evaluar la evolución respecto a la situación observada en 2012.

Bajo estas condiciones, los datos correspondientes a la gestión 2012 —tanto la variable

de pobreza como las variables de características de las comunidades— son los insumos para establecer los sets de entrenamiento y validación. En este sentido, el 70 % de las observaciones con datos compilados para el año 2012 son asignados aleatoriamente al set de entrenamiento (667 observaciones) y el 30 % al set de validación (286 observaciones).

Con relación al set de producción —periodo de pronóstico—, está conformado por los datos de la gestión 2022 correspondientes a las características de las 953 comunidades de estudio. Con esta información se pronostica la incidencia de pobreza NBI por comunidad para 2022, que es algo inédito para el caso de Bolivia.

Finalmente, para garantizar la comparabilidad y evitar el sesgo, todas las variables de los sets de entrenamiento, validación y producción se someten a una normalización z-score. En específico, las variables se ajustan según la siguiente formula.

$$\tilde{x}_j^{(i)} = \frac{x_j^{(i)} - \mu_j}{\sigma_j} \quad (12)$$

Donde  $j$  representa la variable o columna seleccionada en la matriz de predictores de la pobreza ( $X$ ).  $\mu_j$  y  $\sigma_j$  representan la media y la desviación estándar, respectivamente, de los valores del set de entrenamiento para la variable  $j$  seleccionada. El mismo razonamiento se aplica a la normalización z-score de  $y$ ; es decir, la variable de incidencia de pobreza NBI.

### 2.1.5. Entrenamiento de algoritmos

Dada la disponibilidad de los sets de entrenamiento, validación y producción, el siguiente paso es entrenar los algoritmos para predecir la incidencia de pobreza NBI en 2022. Esta sección proporciona detalles metodológicos sobre los algoritmos seleccionados para lograr el objetivo de investigación.

Estos algoritmos se explican a continuación, y cabe señalar que sus criterios de selección se basan en su uso común en la literatura de pronósticos, así como en el hecho de que algunos de ellos se especializan en modelizar relaciones lineales, mientras que otros tienen capacidades más enfocadas en la identificación de patrones no lineales.

#### Ridge, Lasso and ElasticNet

Ridge, Lasso y ElasticNet son tres técnicas populares de regularización utilizadas en modelos de regresión lineal para prevenir el sobreajuste. Estas técnicas agregan un término de penalización a la función objetivo, lo que controla la complejidad del modelo y reduce el impacto de las características irrelevantes.

*Regresión Ridge*, también conocida como regularización L2, agrega un término de penalización a la función objetivo de la suma de errores cuadrados (SSE). El término de penalización es proporcional al cuadrado de la norma L2 del vector de coeficientes. La función objetivo para la regresión Ridge se define como:

$$\text{minimize } J(\beta) = SSE + \lambda \sum_{j=1}^p \beta_j^2 \quad (13)$$

donde  $\beta$  es el vector de coeficientes,  $p$  es el número de características y  $\lambda$  es el parámetro de regularización que controla la fuerza del término de penalización.

*Regresión Lasso*, también conocida como regularización L1, agrega un término de penalización a la función objetivo SSE. El término de penalización es proporcional a la

norma L1 del vector de coeficientes. La función objetivo para la regresión Lasso se define como:

$$\text{minimize } J(\beta) = SSE + \lambda \sum_{j=1}^p |\beta_j| \quad (14)$$

*ElasticNet* es una combinación de las técnicas de regresión Ridge y Lasso. Agrega términos de penalización tanto L1 como L2 a la función objetivo SSE. La función objetivo para la regresión ElasticNet se define como:

$$\text{minimize } J(\beta) = SSE + \lambda \left( \alpha \sum_{j=1}^p |\beta_j| + (1 - \alpha) \sum_{j=1}^p \beta_j^2 \right) \quad (15)$$

El hiperparámetro  $\lambda$  controla la fuerza de la regularización, con valores más grandes de  $\lambda$  que conducen a una regularización más fuerte. El hiperparámetro  $\alpha$  controla el parámetro de mezcla entre las regularizaciones L1 y L2, con valores entre 0 y 1. Un valor de 1 corresponde a la regularización L1, mientras que un valor de 0 corresponde a la regularización L2. Valores intermedios corresponden a una combinación de ambas regularizaciones. En resumen, la regresión Ridge reduce los coeficientes hacia cero, la regresión Lasso establece algunos coeficientes en cero y ElasticNet combina ambas técnicas para superar sus limitaciones.

### Decision Tree Regressor

El algoritmo Decision Tree Regressor funciona dividiendo recursivamente el espacio de características en regiones cada vez más pequeñas basadas en los valores de las características de entrada. Sea  $X$  la matriz de características de entrada de tamaño  $n \times m$ , donde  $n$  es el número de observaciones y  $m$  es el número de características. Sea  $y$  el vector correspondiente de la variable objetivo de tamaño  $n$ . El algoritmo funciona de la siguiente manera::

1. Seleccionar una característica  $j$  y un valor umbral  $t$  que divida mejor los datos en dos subconjuntos  $R_1$  y  $R_2$  basados en la función de pérdida de error cuadrático medio (MSE, por sus siglas en inglés):

$$MSE(R) = \frac{1}{|R|} \sum_{i \in R} (y_i - \bar{y}_R)^2 \quad (16)$$

donde  $|R|$  es el número de observaciones en la región  $R$  y  $\bar{y}_R$  es el valor medio de la variable objetivo en la región  $R$ .

2. Repetir el paso 1 recursivamente en cada subconjunto  $R_1$  y  $R_2$  hasta que se cumpla un criterio de detención, como una profundidad máxima del árbol ( $d$ ) o un número mínimo de observaciones en un nodo hoja ( $msl$ ).
3. Asignar el valor medio de la variable objetivo de las observaciones de entrenamiento en cada nodo hoja como el valor predicho para nuevas observaciones que caigan dentro de esa región.

El algoritmo se puede representar como un árbol binario, donde cada nodo interno representa una división en una característica y un valor umbral, y cada nodo hoja representa un valor objetivo predicho. El árbol se puede entrenar utilizando un algoritmo iterativo como CART (Árboles de Clasificación y Regresión).

## AdaBoost Regressor

El AdaBoost Regressor es un algoritmo de refuerzo utilizado para tareas de regresión. Entrena una serie de modelos débiles en versiones ponderadas de los datos de entrenamiento, con las ponderaciones actualizadas en cada iteración para centrarse en los puntos de datos que fueron mal pronosticados en iteraciones anteriores. El modelo final es un conjunto de modelos débiles, ponderados por su rendimiento.

Sea  $D = (x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$  los datos de entrenamiento, donde  $x_i$  es un vector de características de entrada y  $y_i$  es la etiqueta de salida correspondiente. Sea  $h(x)$  un modelo débil que toma una entrada  $x$  y emite una predicción  $\hat{y}$ .

El algoritmo procede de la siguiente manera:

1. Inicializar las ponderaciones de muestra  $w_i = 1/n$  para  $i = 1, 2, \dots, n$ .
2. Para  $t = 1, 2, \dots, T$  hacer:
  - a. Entrenar un modelo débil  $h_t(x)$  en los datos de entrenamiento  $D$  con ponderaciones  $w_i$ .
  - b. Calcular el error ponderado  $\epsilon_t$  del modelo débil:

$$\epsilon_t = \frac{\sum_{i=1}^n w_i |y_i - h_t(x_i)|}{\sum_{i=1}^n w_i} \quad (17)$$

- c. Calcular la tasa de aprendizaje  $\alpha_t$ :

$$\alpha_t = \frac{1}{2} \ln \left( \frac{1 - \epsilon_t}{\epsilon_t} \right) \quad (18)$$

- d. Actualizar las ponderaciones de muestra  $w_i$ :

$$w_i \leftarrow w_i \cdot \exp(-\alpha_t (y_i - h_t(x_i))) \quad (19)$$

- e. Normalizar las ponderaciones:

$$w_i \leftarrow \frac{w_i}{\sum_{j=1}^n w_j} \quad (20)$$

3. Generar el modelo final:

$$f(x) = \sum_{t=1}^T \alpha_t h_t(x) \quad (21)$$

En este contexto,  $T$  denota el número de modelos débiles, también conocidos como estimadores base, mientras que  $\epsilon_t$  mide el error del modelo débil  $h_t(x)$  en los datos de entrenamiento. La tasa de aprendizaje  $\alpha_t$  gobierna la contribución de cada modelo débil al modelo de conjunto final, con un valor pequeño elegido en el caso de tasas de error altas y un valor grande elegido cuando la tasa de error es baja. La función de pérdida utilizada en el regresor AdaBoost suele ser la función de pérdida exponencial, que enfatiza más los puntos de datos difíciles de predecir.

## Gradient Boosting Regressor

El Gradient Boosting Regressor (GBR) es un método de ensamble que combina múltiples modelos débiles para crear un predictor sólido. Sea  $y_i$  el valor real de la variable

objetivo para la  $i$ -ésima observación, y sea  $\hat{y}_i$  el valor predicho de la variable objetivo. Entonces, el MSE entre los valores predichos y reales está dado por:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (22)$$

El algoritmo GBR funciona agregando secuencialmente nuevos árboles de regresión al conjunto, donde cada árbol intenta corregir los errores de los árboles anteriores. Sea  $f_m(x)$  la predicción del  $m$ -ésimo árbol para el vector de entrada  $x$ . Entonces, la predicción del conjunto después de  $M$  árboles está dada por:

$$\hat{y}_i^{(M)} = \sum_{m=1}^M \gamma_m f_m(x_i) \quad (23)$$

donde  $\gamma_m$  es la tasa de aprendizaje para el  $m$ -ésimo árbol, que controla la contribución de cada árbol a la predicción final. La tasa de aprendizaje suele establecerse en un valor pequeño, como 0,1, para prevenir el sobreajuste.

Para entrenar el GBR, se comienza con una predicción inicial  $\hat{y}_i^{(0)}$ , que generalmente se establece en el valor promedio de la variable objetivo. Luego, se agregan iterativamente nuevos árboles al conjunto minimizando los errores residuales de los árboles anteriores. Específicamente, en cada iteración  $m$ , se ajusta un nuevo árbol de regresión  $f_m(x)$  a los gradientes negativos de la función de pérdida del MSE:

$$r_{im} = -\frac{\partial}{\partial \hat{y}_i^{(m-1)}} L(y_i, \hat{y}_i^{(m-1)}) \quad (24)$$

donde  $L(y_i, \hat{y}_i^{(m-1)})$  es la función de pérdida utilizada para medir el error entre los valores predichos y reales. Los gradientes negativos se utilizan como valores objetivo para el nuevo árbol, y la tasa de aprendizaje se aplica para controlar la contribución del nuevo árbol al conjunto. La predicción final del GBR se obtiene sumando las predicciones de todos los árboles en el conjunto:

$$\hat{y}_i = \sum_{m=1}^M \gamma_m f_m(x_i) \quad (25)$$

### Random Forest Regression

Random Forest Regression es un método de ensamble que combina múltiples árboles de decisión para realizar una predicción más precisa. En este algoritmo, se selecciona un subconjunto aleatorio de características en cada nodo del árbol de decisión, y se realiza la mejor división basada en las características seleccionadas. La predicción final se realiza promediando las predicciones de todos los árboles de decisión en el conjunto.

Sea  $X$  el conjunto de datos de entrada con  $n$  muestras y  $m$  características, y  $y$  la variable objetivo. El algoritmo Random Forest Regression se puede describir de la siguiente manera:

1. Inicializar el número de árboles de decisión  $T$ , el número de características a seleccionar en cada nodo  $m'$  y la profundidad máxima de cada árbol  $d$ .
2. Para  $t = 1$  hasta  $T$ :

- a. Seleccionar aleatoriamente  $m'$  características de las  $m$  características.
- b. Construir un árbol de decisión utilizando las características seleccionadas con una profundidad máxima de  $d$ .
3. Para una nueva entrada  $x'$ , predecir la variable objetivo  $y'$  de la siguiente manera:

$$y' = \frac{1}{T} \sum_{t=1}^T f_t(x') \quad (26)$$

donde  $f_t(x')$  es la predicción del  $t$ -ésimo árbol de decisión.

### Extra Trees Regressor

El algoritmo Extra Trees Regressor es similar al algoritmo de Random Forest, pero con algunas diferencias clave en la forma en que se construyen los árboles. Sea  $X$  las características de entrada y  $y$  la variable objetivo. El algoritmo Extra Trees Regressor funciona de la siguiente manera:

1. Selecciona aleatoriamente un subconjunto de las características de entrada para que cada árbol las utilice.
2. Para cada árbol, selecciona aleatoriamente un subconjunto de los datos de entrenamiento para su entrenamiento.
3. Para cada división en cada árbol, selecciona aleatoriamente un subconjunto de características para determinar la mejor división.
4. Divide los datos basados en la característica seleccionada y el valor umbral que minimiza el MSE.
5. Repite los pasos 3-4 hasta que el árbol alcance una profundidad máxima o el número de muestras en un nodo hoja esté por debajo de un umbral determinado.

El valor de salida predicho para una nueva muestra de entrada  $x$  se obtiene promediando los valores de salida de todos los árboles en el conjunto:

$$\hat{y} = \frac{1}{N} \sum_{i=1}^N f_i(x) \quad (27)$$

donde  $N$  es el número de árboles en el conjunto y  $f_i(x)$  es el valor de salida del  $i$ -ésimo árbol para la muestra de entrada  $x$ .

### Fine-tuning

Adicional a lo explicado previamente, el proceso de ajuste de hiperparámetros (i.e., fine-tuning) es un paso crucial para lograr un rendimiento óptimo para un modelo de machine learning. Implica la selección de valores que controlan el comportamiento del algoritmo, conocidos como hiperparámetros. El procedimiento implica la identificación de un rango de valores para estos hiperparámetros, seguido de una selección iterativa de un subconjunto de ellos para optimizar el rendimiento del modelo.

En este marco, los algoritmos mencionados anteriormente serán sometidos a un proceso riguroso de fine-tuning, basado principalmente en un método de validación cruzada (i.e.,  $k$ -fold cross-validation). El proceso de  $k$ -fold cross-validation es una técnica utilizada en machine learning para evaluar el rendimiento y la capacidad de generalización de un modelo. Consiste en dividir el conjunto de datos en  $k$  subconjuntos o pliegues de tamaño igual. El modelo se entrena y evalúa  $k$  veces, utilizando cada vez un pliegue diferente como conjunto de validación y los pliegues restantes como conjunto de entrenamiento.

La ventaja principal de la validación cruzada de  $k$ -fold es que utiliza todo el conjunto de datos tanto para el entrenamiento como para la validación, lo que puede conducir a una estimación más confiable e imparcial del rendimiento del modelo. También ayuda a detectar el sobreajuste al proporcionar una evaluación más realista de cuán bien puede generalizar el modelo.

#### 2.1.6. Pronóstico de la incidencia de pobreza para 2022

Por último, después de entrenar los algoritmos, para el set de validación se calculan el Error Cuadrático Medio (MSE, por sus siglas en inglés), el Error Absoluto Medio (MAE, por sus siglas en inglés) y el Coeficiente de Determinación ( $R^2$ ). Con base en estas métricas de evaluación del error y de bondad de ajuste, se identifican los algoritmos con mejor rendimiento en la predicción de la incidencia de pobreza.

En este marco, para predecir la incidencia de pobreza NBI por comunidad en la gestión 2022, se realiza el siguiente procedimiento:

1. Para cada uno de los algoritmos ( $i, \forall i = 1, \dots, 8$ ) entrenados y validados, se obtienen pronósticos sobre la incidencia de pobreza NBI tanto para el año 2012 ( $\hat{y}_{i,2012}$ ) como para 2022 ( $\hat{y}_{i,2022}$ ); en el caso del pronóstico de 2022 se emplea los datos del set de producción.
2. De manera independiente para los años 2012 y 2022 ( $t = 2012, 2022$ ), se computa la media geométrica ponderada de los pronósticos obtenidos por los algoritmos de mejor desempeño ( $B$  es el número de algoritmos con la mejor capacidad predictiva); los pesos corresponden a la inversa de los valores de MSE ( $\alpha_i = \frac{1}{MSE_i}$ ). El promedio de pronósticos individuales es una estrategia efectiva respaldada por la literatura para mejorar la calidad y la confiabilidad de las predicciones en problemas de regresión (Breiman, 1996; Dietterich, 2000; Wolpert, 1992).<sup>14</sup>

$$\bar{\hat{y}}_{i,t} = \left( \prod_{i=1}^B \hat{y}_{i,t}^{\alpha_i} \right)^{\frac{1}{\sum_i \alpha_i}} \quad (28)$$

3. Se calcula la diferencia ( $\Delta$ ) en puntos porcentuales entre los pronósticos (medias geométricas ponderadas) de 2022 y 2012 para cada comunidad.

$$\Delta_i = \bar{\hat{y}}_{i,2022} - \bar{\hat{y}}_{i,2012} \quad (29)$$

4. El pronóstico final de la incidencia de pobreza NBI en 2022 ( $\Upsilon_{i,2022}$ ) es determinado al aplicar la diferencia calculada en el paso (3) a los datos observados de pobreza en 2012 ( $y_{i,2012}$ ). Se asume esta aproximación para garantizar una mejor comparabilidad entre los niveles de incidencia de pobreza NBI de los años 2012 y 2022.

$$\Upsilon_{i,2022} = y_{i,2012} + \Delta_i \quad (30)$$

---

<sup>14</sup>Se calcula la media geométrica porque es menos sensible a valores atípicos, en comparación con la media aritmética.

### 3. Resultados

#### 3.1. Fine-tuning hiperparámetros

El proceso de ajuste de hiperparámetros (i.e., fine-tuning) es un paso crucial para lograr un rendimiento óptimo en un modelo de machine learning. Implica la selección de valores que controlan el comportamiento del algoritmo, conocidos como hiperparámetros. El procedimiento conlleva la identificación de un rango de valores para estos hiperparámetros, seguido de una selección iterativa de un subconjunto de ellos para optimizar el rendimiento del modelo.

En esta sección se explica el proceso de fine-tuning, basado en un método de validación cruzada con 10 pliegues, aplicado a los algoritmos mencionados en el acápite 2.1.5.

1. **Ridge** es una herramienta poderosa para equilibrar el ajuste de un modelo a los datos de entrenamiento con la necesidad de mantener los coeficientes del modelo pequeños para evitar el sobreajuste. Para lograr este equilibrio, se debe ajustar cuidadosamente el parámetro de regularización  $\lambda$ . Un enfoque común para ajustar este hiperparámetro es usar  $k$ -fold cross-validation para evaluar el rendimiento del modelo en un rango de valores de  $\lambda$ . Para buscar un rango apropiado de valores de  $\lambda$ , a menudo es útil explorar una amplia gama de valores, desde muy pequeños hasta muy grandes, abarcando varios órdenes de magnitud. En este estudio, se realizó un proceso de validación cruzada de 10 pliegues (i.e.,  $k = 10$ ), utilizando un vector de 1.000 valores de  $\lambda$ , distribuidos uniformemente en una escala logarítmica desde  $10^{-5}$  hasta  $10^5$ , ya que el impacto de  $\lambda$  en el modelo tiende a ser multiplicativo. El valor óptimo de  $\lambda$  es el que minimiza el MSE.
2. El algoritmo **Lasso** tiene el mismo hiperparámetro que la regresión Ridge y su método de ajuste también es similar. Específicamente, se emplea un 10-fold cross-validation para evaluar la eficacia del modelo en un espectro de 1.000 valores de  $\lambda$ , distribuidos uniformemente en una escala logarítmica que va desde  $10^{-5}$  hasta  $10^5$ . El valor óptimo es definido como el que minimiza el MSE.
3. La regresión **ElasticNet** cuenta con dos hiperparámetros que desempeñan un papel crítico en el proceso de regularización. El primer hiperparámetro, denotado como  $\lambda$ , controla la fuerza de la regularización, mientras que el segundo hiperparámetro, denominado  $\alpha$ , controla el parámetro de mezcla entre la regularización L1 y L2. Para optimizar estos hiperparámetros, se realiza una validación cruzada de 10 pliegues utilizando un rango de 1.000 valores de  $\lambda$ , similar al enfoque adoptado en la regresión Ridge y Lasso. Además, se consideran valores para  $\alpha$  en el rango de 0,05 a 0,95 en incrementos de 0,01 para garantizar un abanico amplio de posibles valores. Los valores óptimos se seleccionan en función de los que minimizan el MSE.
4. Los hiperparámetros del **Decision Tree Regressor** incluyen la profundidad máxima del árbol ( $d$ ), el número mínimo de muestras requeridas para dividir un nodo interno ( $mss$ ) y el número mínimo de muestras requeridas en un nodo hoja ( $msl$ ). En este estudio, se ejecutó un 10-fold cross-validation sobre un rango de valores para cada uno de los hiperparámetros, que se seleccionaron en función de investigaciones previas y prácticas convencionales en machine learning (Mantovani et al., 2018).

5. Los hiperparámetros del **AdaBoost Regressor** abarcan una variedad de factores, como la profundidad máxima del árbol ( $d$ ), el número máximo de estimadores utilizados durante el boosting ( $T$ ), la tasa de aprendizaje ( $\alpha_t$ ) y la función de pérdida empleada para actualizar los pesos después de cada iteración de boosting. La selección de los rangos de hiperparámetros para el ajuste depende de varias consideraciones, como la complejidad del modelo y los recursos de entrenamiento disponibles. Para determinar el valor óptimo de  $\alpha_t$ , generalmente se evalúa un amplio rango de valores para encontrar un equilibrio entre la velocidad de convergencia y el riesgo de sobreajuste; se utilizó un rango inicial de 0,01 a 3 con un incremento de 0,01 para el ajuste. Para  $T$ , el rango se elige en función del equilibrio entre la complejidad del modelo y el rendimiento, con un gran número de estimadores que potencialmente pueden conducir al sobreajuste y un número pequeño que resulta en un subajuste; por lo tanto, se probó un rango de 50 a 200 con un incremento de 1. Además, se evaluaron funciones de pérdida lineal, cuadrada y exponencial.  $d$  se evaluó en un rango de 3 a 10. Los valores óptimos son los que minimizan el MSE a través de la validación cruzada de 10 pliegues.
6. Los hiperparámetros utilizados en el **Gradient Boosting Regressor** son la tasa de aprendizaje ( $\gamma_m$ ), la profundidad máxima del árbol ( $d$ ), el número máximo de estimadores en los que se detiene el boosting ( $T$ ) y el número mínimo de muestras requeridas para dividir un nodo interno ( $mss$ ). Para determinar los valores óptimos de cada uno de estos hiperparámetros, se realiza una 10-fold cross-validation sobre un rango de valores. Para el hiperparámetro  $T$ , se elige un rango de 100 a 500 con un incremento de 5; este rango se considera razonable ya que abarca una amplia gama de valores e incluye algunos con precedentes en la literatura respecto a un funcionamiento adecuado en la práctica. De manera similar, para el hiperparámetro  $d$ , se elige un rango de 3 a 10 con un incremento de 1, ya que cubre una serie de profundidades que se sabe que funcionan bien en la práctica, mientras que exceder una profundidad de 10 puede resultar en sobreajuste. En el contexto del hiperparámetro  $mss$ , vale la pena señalar que el rango de valores admisibles abarca de 2 a 20, con aumentos de 1. Si este hiperparámetro es demasiado alto, el modelo puede tender a sobreajuste, es decir, el modelo se volverá demasiado complejo y comenzará a aprender detalles específicos de los datos de entrenamiento, que no se generalizarán bien a nuevos datos; en cambio, si es demasiado bajo, el modelo puede sufrir de subajuste porque no tendrá suficiente información para aprender patrones complejos en los datos de entrenamiento. Para el hiperparámetro  $\gamma_m$ , se elige un rango de 0,01 a 2 con incrementos de 0,01. Los valores óptimos se seleccionan en función de los que minimizan el MSE.
7. Los hiperparámetros elegidos para el ajuste en el modelo de **Random Forest** se seleccionaron en función del conocimiento previo y la práctica común en la literatura. El número de estimadores ( $T$ ) se probó en el rango de 100 a 300 con incrementos de 1, ya que un mayor número de árboles puede mejorar el rendimiento del modelo, pero en cierto punto, la mejora puede ser insignificante. El criterio para dividir nodos (*Criterion*) se estableció para probar tanto el MSE como el MAE, así como, el MSE con la puntuación de mejora de Friedman para posibles divisiones, ya que estas funciones de pérdida son comunes en problemas de regresión. El número mínimo de muestras requeridas para dividir un nodo interno ( $mss$ ) se probó en el rango de 2 a 10 con incrementos de 1; este rango se seleccionó para evitar el sobreajuste,

ya que tener muy pocas muestras requeridas para dividir un nodo puede llevar a árboles sobrecomplejos, mientras que tener demasiadas puede llevar a un subajuste. Además, se testea la opción de *out-of-bag samples* que calcula el error de validación del modelo sin utilizar ningún conjunto de datos de validación externo, esto lo hace utilizando los datos que no se emplearon para entrenar el modelo, conocidos como datos “*out-of-bag*”. Se realiza un proceso de validación cruzada de 10 pliegues para distinguir los hiperparámetros óptimos que minimizan el MSE.

8. Para ajustar los hiperparámetros en el modelo de **Extra Tree Regressor**, se evaluaron una amplia gama de valores para identificar la combinación que produce el mejor rendimiento. Por ejemplo, se evaluó un rango de valores de 100 a 500, con aumentos de 5, para el número de árboles en el conjunto ( $T$ ). Además de ajustar otros parámetros comunes como  $d$ ,  $mss$  y  $msl$ , el algoritmo se ejecutó con la opción *out-of-bag samples*. Los hiperparámetros finales se seleccionan en función de los que minimizan el MSE en una estrategia de validación cruzada de 10 pliegues.

Finalmente, se ejecutan los algoritmos —entrenados— con los datos del set de validación y se calculan el MSE y MAE y  $R^2$ . MSE es un indicador de evaluación comúnmente utilizado para problemas de regresión, preferido cuando se necesita penalizar errores más grandes de manera más severa. Por otro lado, MAE es una métrica que trata todos los errores por igual, independientemente de su magnitud. El coeficiente de determinación  $R^2$  es una métrica para evaluar la calidad del ajuste de un modelo de regresión, varía desde menos infinito hasta 1, y valores más altos indican un mejor ajuste; si  $R^2$  es negativo, significa que el modelo tiene un rendimiento peor que una línea horizontal.<sup>15</sup>

El Cuadro 2 muestra el desempeño de los algoritmos de machine learning seleccionados en la predicción de la incidencia de pobreza por comunidad. La primera columna muestra el nombre de cada algoritmo, mientras que las columnas segunda a cuarta informan sobre el MSE, MAE y  $R^2$  calculados para el algoritmo sin ajuste de hiperparámetros. Las columnas quinta a octava muestran los mismos indicadores obtenidos después del ajuste de hiperparámetros a través de una estrategia de validación cruzada de 10 pliegues. Todas estas métricas son calculadas para el set de validación.

En términos generales, con respecto a los resultados del entrenamiento de los algoritmos sin ajuste y con ajuste de hiperparámetros, se observa que los algoritmos que modelizan relaciones lineales entre la incidencia de pobreza y sus predictores (Ridge, Lasso y ElasticNet) tienen un poder predictivo débil, en comparación con los algoritmos que modelizan relaciones no lineales (Decision Tree, AdaBoost, Gradient Boosting, Random Forest y Extra Trees).

Asimismo, se constata que el proceso de validación cruzada, de 10 pliegues, mejora el desempeño de los algoritmos de predicción de la pobreza para las comunidades de Bolivia. En otras palabras, este proceso coadyuva a evitar el sobreajuste y mejora la capacidad de generalización de los modelos.

Entre los algoritmos que modelizan relaciones no lineales, son AdaBoost y Gradient Boosting los de mejor desempeño después del proceso de 10-fold cross-validation; es decir, que reportan los valores más bajos de MSE (0,123 y 0,125, respectivamente) y MAE (0,288 en ambos casos), y  $R^2$  más alto (0,893 y 0,891, respectivamente) cuando son aplicados a los datos del set de validación. No obstante, la ventaja de aplicar los anteriores algoritmos por

---

<sup>15</sup>Los valores negativos de  $R^2$  pueden ocurrir si las predicciones del modelo están consistentemente alejadas o si los datos no siguen una tendencia lineal. En tales casos, es importante volver a evaluar las suposiciones del modelo y considerar enfoques alternativos para mejorar su rendimiento.

Cuadro 2: Indicadores de error de pronóstico y bondad de ajuste para el set de validación, y fine-tuned hiperparámetros según algoritmo

Algoritmo	Sin tuning			Con tuning (10-fold cross-validation)		
	MSE	MAE	R <sup>2</sup>	MSE	MAE	R <sup>2</sup>
Ridge	2,256	0,556	-0,981	1,335	0,525	-0,172
Lasso	12,156	0,741	-9,671	1,140	0,911	-0,000
ElasticNet	1,689	0,833	-0,482	1,633	0,534	-0,434
Decision Tree	0,266	0,398	0,768	0,131	0,303	0,886
AdaBoost	0,146	0,321	0,872	0,123	0,288	0,893
Gradient Boosting	0,129	0,290	0,888	0,125	0,288	0,891
Random Forest	0,134	0,292	0,884	0,128	0,289	0,889
Extra Trees	0,139	0,300	0,879	0,128	0,291	0,889

Ridge	2,256	0,556	-0,981	1,335	0,525	-0,172	$\lambda = 20,541$	hiperparámetros
Lasso	12,156	0,741	-9,671	1,140	0,911	-0,000	$\lambda = 0,05$	
ElasticNet	1,689	0,833	-0,482	1,633	0,534	-0,434	$\lambda = 0,05$	
							$\alpha = 0,05$	
Decision Tree	0,266	0,398	0,768	0,131	0,303	0,886	$mss = 13$	
							$msl = 4$	
AdaBoost	0,146	0,321	0,872	0,123	0,288	0,893	$d = 7$	
							$\alpha_t = 2,6$	
Gradient Boosting	0,129	0,290	0,888	0,125	0,288	0,891	$T = 185$	
							$\gamma_m = 0,07$	
Random Forest	0,134	0,292	0,884	0,128	0,289	0,889	$T = 225$	
							$mss = 10$	
Extra Trees	0,139	0,300	0,879	0,128	0,291	0,889	$d = 14$	
							$out-of-bag samples = True$	

Note: En el proceso de entrenamiento y validación de los algoritmos, se utilizó la librería scikit-learn. Cabe destacar que no todos los hiperparámetros descritos en los párrafos precedentes son incluidos en este cuadro; la razón por la que no son mostrados explícitamente es porque fueron asignados valores predeterminados de las funciones de scikit-learn, que resultaron ser los más adecuados.

encima de Random Forest o Extra Trees es mínima, toda vez que estos otros algoritmos también vislumbran una capacidad predictiva adecuada y cercana al de los algoritmos de mejor desempeño. En el caso de Decission Tree, si bien la capacidad de predicción de la incidencia de pobreza mejora considerablemente posterior al ajuste de hiperparámetros, el desempeño en la predicción es levemente menor al de Random Forest y Extra Trees.

AdaBoost y Gradient Boosting se benefician en escenarios donde el problema en cuestión presenta una estructura compleja y relaciones no lineales entre variables. Estos algoritmos son especialmente adecuados cuando existen características débiles pero relevantes en los datos, ya que tienen la habilidad de identificar y asignar mayor peso a estas características en iteraciones sucesivas, lo que incrementa gradualmente la calidad del modelo. La técnica de boosting utilizada por ambos algoritmos se enfoca en corregir los errores cometidos por modelos anteriores, permitiendo que el algoritmo se centre en las observaciones que han sido mal predichas, lo que puede llevar a una convergencia más precisa y una mayor generalización a datos no vistos.

En contraste, Random Forest, Extra Trees y Decision Tree pueden tener limitaciones en la gestión de relaciones complejas en los datos y en la corrección de sesgos. Decision Tree, aunque es simple y fácilmente interpretable, tiende a sobreajustarse en problemas con múltiples características interdependientes, lo que puede reducir su capacidad de predicción en nuevos datos. Random Forest y Extra Trees abordan en cierta medida el sobreajuste al promediar múltiples árboles, pero pueden no capturar las sutilezas en los datos de manera eficiente como lo hacen los algoritmos de boosting.

En este marco, los resultados observados en el entrenamiento de los algoritmos y en el fine-tuning de los hiperparámetros, pueden estar relacionados con el hecho que AdaBoost y Gradient Boosting tienden a destacar en situaciones donde la complejidad del problema y las relaciones no lineales entre variables requieren un enfoque más sofisticado y adaptativo. Su habilidad para mejorar iterativamente la precisión de las predicciones, así como para identificar características subyacentes y débiles, los convierte en opciones sólidas para casos en los que Random Forest, Extra Trees y Decision Tree podrían no capturar adecuadamente la complejidad y la sutileza de los patrones presentes en los datos.

### **3.2. Importancia de las variables generadas con teledetección**

Posterior al entrenamiento y fine-tuning de los hiperparámetros, con base en los modelos finales se procedió a construir del Cuadro 3 que muestra la importancia —o pesos— que asigna cada uno de los algoritmos a las variables de características de las comunidades; cabe recordar son variables generadas a partir de información de imágenes satelitales.

Dentro del enfoque metodológico de la presente investigación, los factores predictores preeminentes en cuanto a la incidencia de la pobreza en las comunidades de Bolivia se refieren al conteo de instituciones bancarias y centros educativos localizados dentro el área de las unidades de observación. La identificación de la cantidad de bancos y escuelas como predictores significativos de la incidencia de pobreza en las comunidades de Bolivia concuerda con las teorías económicas y las dinámicas sociales que caracterizan los contextos en desarrollo. Desde un punto de vista económico, la presencia de entidades financieras, especialmente los bancos, podría reflejar la accesibilidad de la comunidad a servicios de crédito y financiamiento, los cuales tienen una relevancia crucial para el surgimiento y el desenvolvimiento de las empresas locales. Un mayor número de bancos podría denotar una atmósfera empresarial más activa y una mayor diversificación de oportunidades

económicas, aspectos que podrían estar vinculados con una menor incidencia de pobreza.

Cuadro 3: Importancia de los predictores según algoritmo

Variable	Ridge(1)	Lasso(1)	EN(1)	DT	ADA	GBR	RF	ET	Promedio
Número de bancos	47,6	41,3	46,3	82,4	69,2	74,2	71,6	41,6	66,6
Número de escuelas	58,2	56,3	56,8	16,9	8,0	17,3	14,7	37,8	20,9
Área de asentamientos urbanos	23,9	17,6	20,8	0,0	0,4	0,2	0,2	0,4	1,4
Luminosidad promedio	10,2	0,0	9,1	0,0	1,3	0,5	1,0	2,2	1,3
Luminosidad suma	7,8	0,6	8,9	0,5	1,0	0,6	0,9	0,5	0,9
Área de zonas urbanas/construidas	9,2	8,7	10,0	0,0	0,8	0,4	0,6	0,5	0,9
Área de pastizales	6,8	0,0	3,5	0,0	1,9	0,4	0,7	0,6	0,9
Índice Palmer Sequía promedio	4,2	1,7	4,2	0,0	1,5	0,1	0,9	0,8	0,8
Número de hospitales	1,7	0,0	2,0	0,0	0,7	0,3	0,2	2,7	0,8
Velocidad del viento promedio	2,3	0,0	1,2	0,0	1,6	0,6	0,8	0,8	0,8
Temperatura máx. promedio	3,3	2,0	3,1	0,0	1,2	0,3	0,8	0,8	0,7
Elevación promedio	0,9	0,0	0,7	0,0	1,1	0,6	0,8	1,2	0,7
Número de clínicas	13,5	7,8	12,5	0,0	0,1	0,1	0,1	0,3	0,7
NDVI promedio	6,2	0,0	2,1	0,2	1,2	0,5	0,5	0,5	0,7
Evapotranspiración promedio	0,9	0,0	0,0	0,0	0,9	0,8	0,7	0,8	0,6
EVI promedio	4,7	0,0	0,0	0,0	1,2	0,4	0,5	0,7	0,6
Temperatura min. promedio	2,4	0,0	2,2	0,0	0,8	0,7	0,6	0,7	0,6
Humedad del suelo promedio	3,5	0,0	1,7	0,0	1,0	0,2	0,7	0,6	0,6
Densidad vías terciarias	2,8	0,0	2,5	0,0	1,0	0,3	0,6	0,5	0,5
Precipitación acumulada promedio	3,1	0,0	0,9	0,0	0,7	0,5	0,6	0,7	0,5
Área bosques	7,8	3,0	7,7	0,0	0,2	0,0	0,2	0,3	0,5
Área matorrales	6,6	0,3	6,3	0,0	0,3	0,0	0,2	0,7	0,4
Área sabana	2,9	0,0	0,5	0,0	1,0	0,2	0,3	0,4	0,4
Área comunidad	2,4	0,0	0,0	0,0	0,6	0,0	0,3	1,1	0,4
Densidad vías secundarias	3,6	0,0	3,2	0,0	0,5	0,2	0,3	0,5	0,4
Número píxeles	2,4	0,0	0,0	0,0	0,5	0,1	0,3	0,7	0,3
Densidad red eléctrica	0,0	0,0	0,0	0,0	0,5	0,3	0,3	0,4	0,3
Densidad vías primarias	1,3	0,0	0,9	0,0	0,3	0,1	0,2	0,4	0,2
Área cultivos grandes	0,6	0,0	0,1	0,0	0,4	0,1	0,2	0,3	0,2
Área cuerpos de agua	6,0	0,0	5,5	0,0	0,0	0,0	0,0	0,0	0,2
Número de mercados	3,6	0,0	3,1	0,0	0,0	0,0	0,0	0,3	0,2
Área cultivos pequeños	1,1	0,0	0,8	0,0	0,0	0,0	0,0	0,1	0,1
Número de cajeros automáticos	0,5	0,0	0,5	0,0	0,0	0,0	0,0	0,1	0,1

(1): Para estos algoritmos se presentan los valores de los coeficientes estimados, que pueden ser de valor positivo o negativo; no obstante, para propósitos de visualización, en esta tabla se incluyen los valores absolutos de los coeficientes.

Nota: Las variables son ordenadas de mayor a menor según el promedio ponderado de su importancia en todos los algoritmos; en la media ponderada los pesos corresponden a la inversa de los valores de MSE.

Por otro lado, la correlación entre la existencia de instituciones educativas y la incidencia de la pobreza resulta plausible debido a la importancia que detenta el capital humano en el desarrollo socioeconómico. La presencia de escuelas en el tejido comunitario podría indicar un acceso más amplio a la educación, elemento que podría potenciar las opciones laborales, incrementar la capacidad productiva y reducir las tasas de pobreza. Adicionalmente, cabe destacar que la educación ejerce un papel esencial en la movilidad social y el empoderamiento individual, dinámicas que podrían incidir en la disminución sostenida de la pobreza a largo plazo. La identificación de estos predictores en el ámbito de las unidades de observación, utilizando información geoespacial de Open Street Map, refuerza la pertinencia de abordar el fenómeno de la pobreza desde un enfoque multidimensional que tome en consideración tanto los aspectos económicos como los sociales en el análisis.

Asimismo, los indicadores sobre el área de asentamientos urbanos y de zonas urbanas/construidas resultan ser importantes al momento de predecir los niveles de pobreza

en las comunidades de Bolivia. En general, las zonas urbanas suelen ser epicentros de interacción económica, acceso a servicios, empleo y oportunidades de negocio. Una mayor extensión de áreas urbanas y construidas puede indicar un entorno propicio para la generación de empleo y el desarrollo de actividades productivas, lo que potencialmente contribuye a la reducción de la pobreza al aumentar las oportunidades de ingresos y mejorar el acceso a servicios básicos. Además, las zonas urbanas suelen estar mejor conectadas a infraestructuras como carreteras y servicios públicos, lo que puede influir en un mayor acceso a educación y atención médica. Desde una perspectiva social, la concentración de población en áreas urbanas puede también permitir una mayor cohesión comunitaria y el intercambio de conocimientos, lo que puede tener un impacto positivo en la movilidad social y la calidad de vida en general. En conjunto, la identificación de estas áreas mediante técnicas de teledetección a partir de imágenes satelitales proporciona un enfoque cuantitativo y espacialmente explícito para comprender cómo las características de la urbanización están relacionadas con los niveles de pobreza en las comunidades de Bolivia, contribuyendo así a una perspectiva más completa de las dinámicas socioeconómicas en juego.

También, la identificación de las variables que computan los niveles promedio de luminosidad y su suma dentro de la extensión de las comunidades como predictores relevantes de la incidencia de pobreza en las comunidades de Bolivia se alinea con las investigaciones previas que han resaltado la relación entre desarrollo económico y los niveles de luminosidad. Estas variables, derivadas de técnicas de teledetección aplicadas a imágenes satelitales, proporcionan una medida objetiva de la actividad económica y la infraestructura en un área determinada. Los niveles promedio de luminosidad pueden considerarse un indicador indirecto de la actividad económica y la presencia de servicios básicos como iluminación eléctrica y energía. Una mayor luminosidad promedio puede reflejar la disponibilidad de recursos energéticos y el grado de desarrollo de una comunidad, lo que puede estar correlacionado con una mayor diversidad de oportunidades económicas y acceso a empleo. La suma de estos niveles a lo largo de la extensión de la comunidad podría indicar la concentración de actividades económicas y de servicios en una misma área, sugiriendo una mayor urbanización o densidad poblacional. Además, un mayor acceso a servicios básicos puede influir positivamente en la calidad de vida y el bienestar de la población, reduciendo las tasas de pobreza. En resumen, la inclusión de estas variables basadas en luminosidad y su distribución en las comunidades de Bolivia en el análisis de la pobreza refleja su potencial para capturar aspectos clave del desarrollo económico y la infraestructura, brindando una perspectiva integral de cómo estos factores están relacionados con la incidencia de la pobreza.

Adicionalmente, si se agregan los aportes de las variables de condiciones climáticas, se evidencia que éstas serían relevantes al momento de predecir la incidencia de pobreza NBI en las comunidades de estudio; las variables que resaltan en mayor grado son los indicadores de sequía, velocidad del viento y temperatura. Las condiciones climáticas pueden tener un impacto significativo en la agricultura, la seguridad alimentaria y otros aspectos económicos de las comunidades. La identificación de indicadores de sequía como variables relevantes puede estar relacionada con el efecto negativo de la escasez de agua en la producción agrícola y la subsistencia de la población, lo que a su vez puede llevar a la inseguridad alimentaria y a la falta de oportunidades económicas. La velocidad del viento y la temperatura también pueden jugar un papel crucial en la capacidad de las comunidades para llevar a cabo actividades productivas. Un viento excesivo podría afectar la agricultura y otras industrias, mientras que temperaturas extremas pueden influir en la productividad

laboral y aumentar la vulnerabilidad de los hogares más pobres a condiciones de vida adversas. Además, la relación entre factores climáticos y pobreza puede ser mediada por la disponibilidad de infraestructura de mitigación de desastres y el acceso a servicios de apoyo en caso de condiciones climáticas extremas. Dado que Bolivia es un país caracterizado por su diversidad geográfica y climática, la inclusión de variables climáticas en el análisis de la pobreza proporciona una perspectiva importante sobre cómo los factores ambientales pueden interactuar con las condiciones socioeconómicas para influir en la vulnerabilidad de las comunidades a la pobreza.

En última instancia, resulta imperativo destacar que la mayoría de las variables, derivadas de la manipulación de datos geoespaciales y satelitales, aportan en diversas magnitudes a la predicción de la incidencia de la pobreza en términos de NBI por comunidad. Como resultado, la aproximación innovadora adoptada en esta investigación para la creación de información inédita acerca de las características comunitarias en el contexto boliviano ha demostrado ser tanto valiosa como sólida.

### 3.3. Pobreza por comunidad en 2022

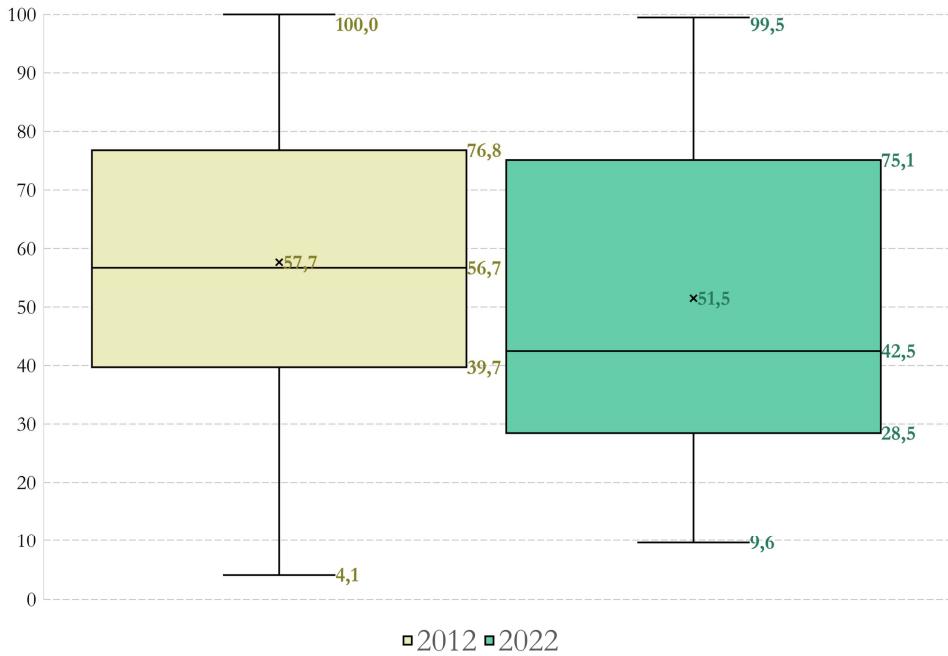
Antes de adentrarse en un análisis más detallado sobre los resultados concernientes a los pronósticos de la incidencia de pobreza para el año 2022 y su contraste con los registros de la gestión 2012, es crucial recordar que el presente estudio se enfoca en un subconjunto de 953 comunidades, seleccionadas de una población total de más de 19,000 comunidades. Estas 953 comunidades fueron elegidas debido a que, en el año 2012, contaban con poblaciones superiores a 500 individuos, lo que facilita su delimitación geográfica (ver sección 2.1.2). Por tanto, se debe reconocer que las conclusiones extraídas de este análisis no necesariamente son extrapolables a las circunstancias de las comunidades más reducidas en tamaño (i.e, 500 habitantes o menos en 2012) en el contexto boliviano.

En la sección 3.1, se han presentado los indicadores de evaluación del error de pronóstico y de bondad de ajuste, lo que lleva a la conclusión de que los algoritmos que modelan relaciones no lineales entre la incidencia de pobreza y sus variables predictoras exhiben el mejor rendimiento en términos de pronóstico. Estos algoritmos incluyen Decission Tree, AdaBoost, Gradient Boosting, Random Forest y Extra Trees.

Para obtener un pronóstico acerca de la incidencia de pobreza en las comunidades de Bolivia para el año 2022, se aplica el procedimiento delineado en la sección 2.1.6, utilizando únicamente los algoritmos de mayor rendimiento que son alimentados con los datos del conjunto de producción.

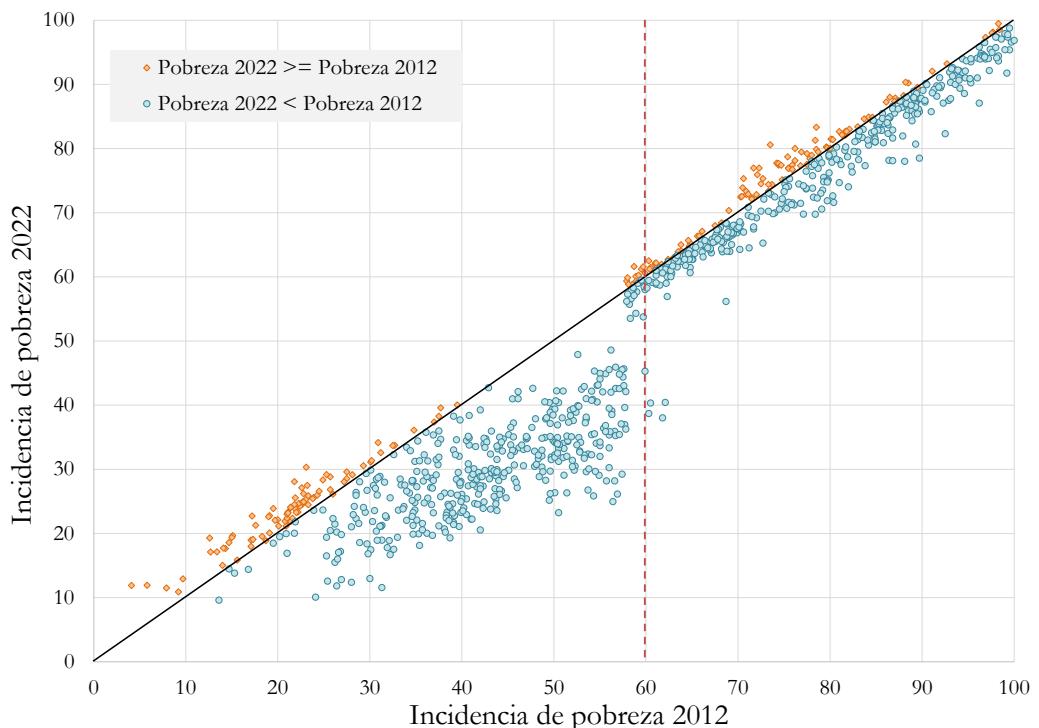
La Figura 6 ilustra diagramas de caja que representan la distribución de la variable de incidencia de pobreza en términos de Necesidades Básicas Insatisfechas, utilizando datos observados para la gestión 2012 (ver subtítulo 2.1.1) y pronósticos para el año 2022. Los resultados revelan un desplazamiento en la distribución de la incidencia de pobreza entre los años 2012 y 2022. En promedio, se esperaría una disminución de la cantidad de personas en situación de pobreza en las comunidades de estudio en comparación con la situación en 2012. Es de mayor relevancia que el 50 % de las comunidades tendrían una incidencia de pobreza NBI inferior al 42,5 % en el año 2022, lo que implica una mejora de 14,2 puntos porcentuales (pp) con respecto a lo registrado en la gestión 2012, siendo la mediana de la incidencia de pobreza con los datos de 2012 de un 56,7 %. En el rango intercuartílico de la distribución de la incidencia de pobreza comunal para 2022, se observa que principalmente el primer cuartil denota una reducción significativa en comparación con lo calculado para la distribución correspondiente a la gestión 2012.

Figura 6: Distribución de la variable incidencia de pobreza NBI, 2012 y 2022



Por otro lado, en la Figura 7, se visualiza que una gran mayoría de las comunidades de estudio presentarían una incidencia de pobreza NBI inferior a la observada en el año 2012. De manera específica, los pronósticos para el año 2022 indican que el 80 % (762 comunidades) de las unidades de observación habrían reducido sus niveles de incidencia de pobreza, mientras que el 20 % (191 comunidades) habrían incrementado o mantenido sus niveles de pobreza en comparación con lo observado en 2012.

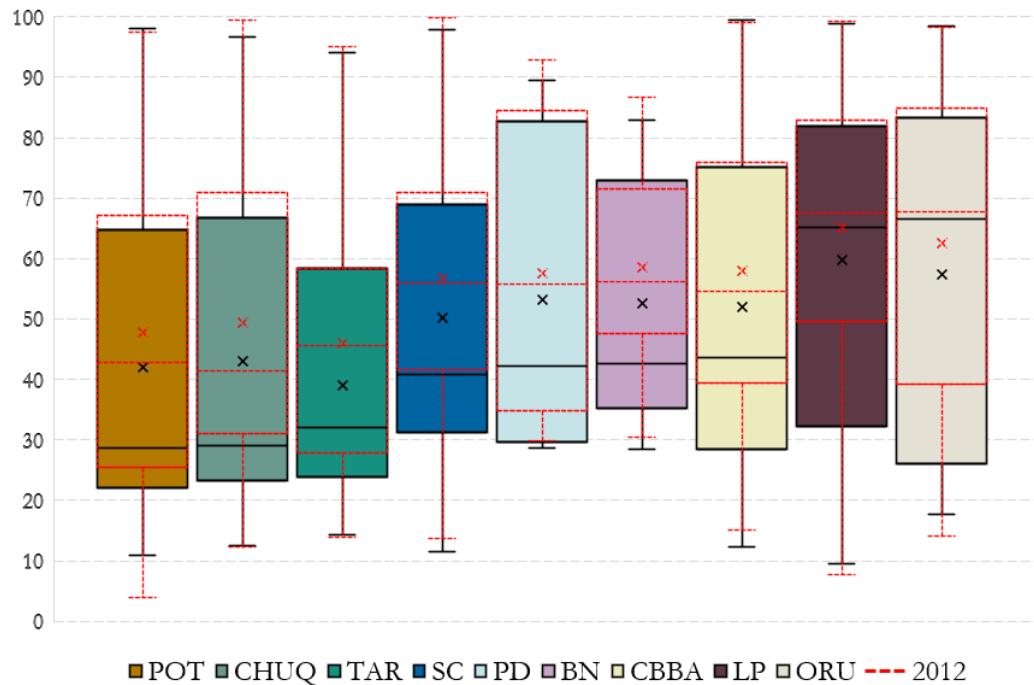
Figura 7: Gráfico de dispersión entre la incidencia de pobreza NBI de 2012 y 2022



La evidencia más significativa derivada de la Figura 7 es que, para las comunidades que lograron reducir la pobreza entre 2022 y 2012, las mayores disminuciones en la incidencia de pobreza —expresadas en puntos porcentuales— se concentran en aquellas que en la gestión 2012 contaban con poblaciones donde menos del 60 % se encontraba en situación de pobreza. Por el contrario, las comunidades más desfavorecidas en 2012, es decir, aquellas con una incidencia de pobreza superior al 60 % en dicho año, mostraron una reducción más moderada en sus niveles de pobreza.

La Figura 8 presenta diagramas de caja superpuestos que ilustran la distribución de la variable correspondiente a la incidencia de pobreza pronosticada para el año 2022, junto con la incidencia observada en 2012 (representada por una línea roja punteada), para cada uno de los departamentos de Bolivia. En primer lugar, se observa que para el año 2022, en todos los departamentos, tanto el valor promedio como la mediana de la incidencia de pobreza NBI en las comunidades estudiadas son inferiores en comparación con las distribuciones correspondientes a los datos de 2012.

Figura 8: Distribución de la variable incidencia de pobreza NBI segun departamento, 2012 y 2022



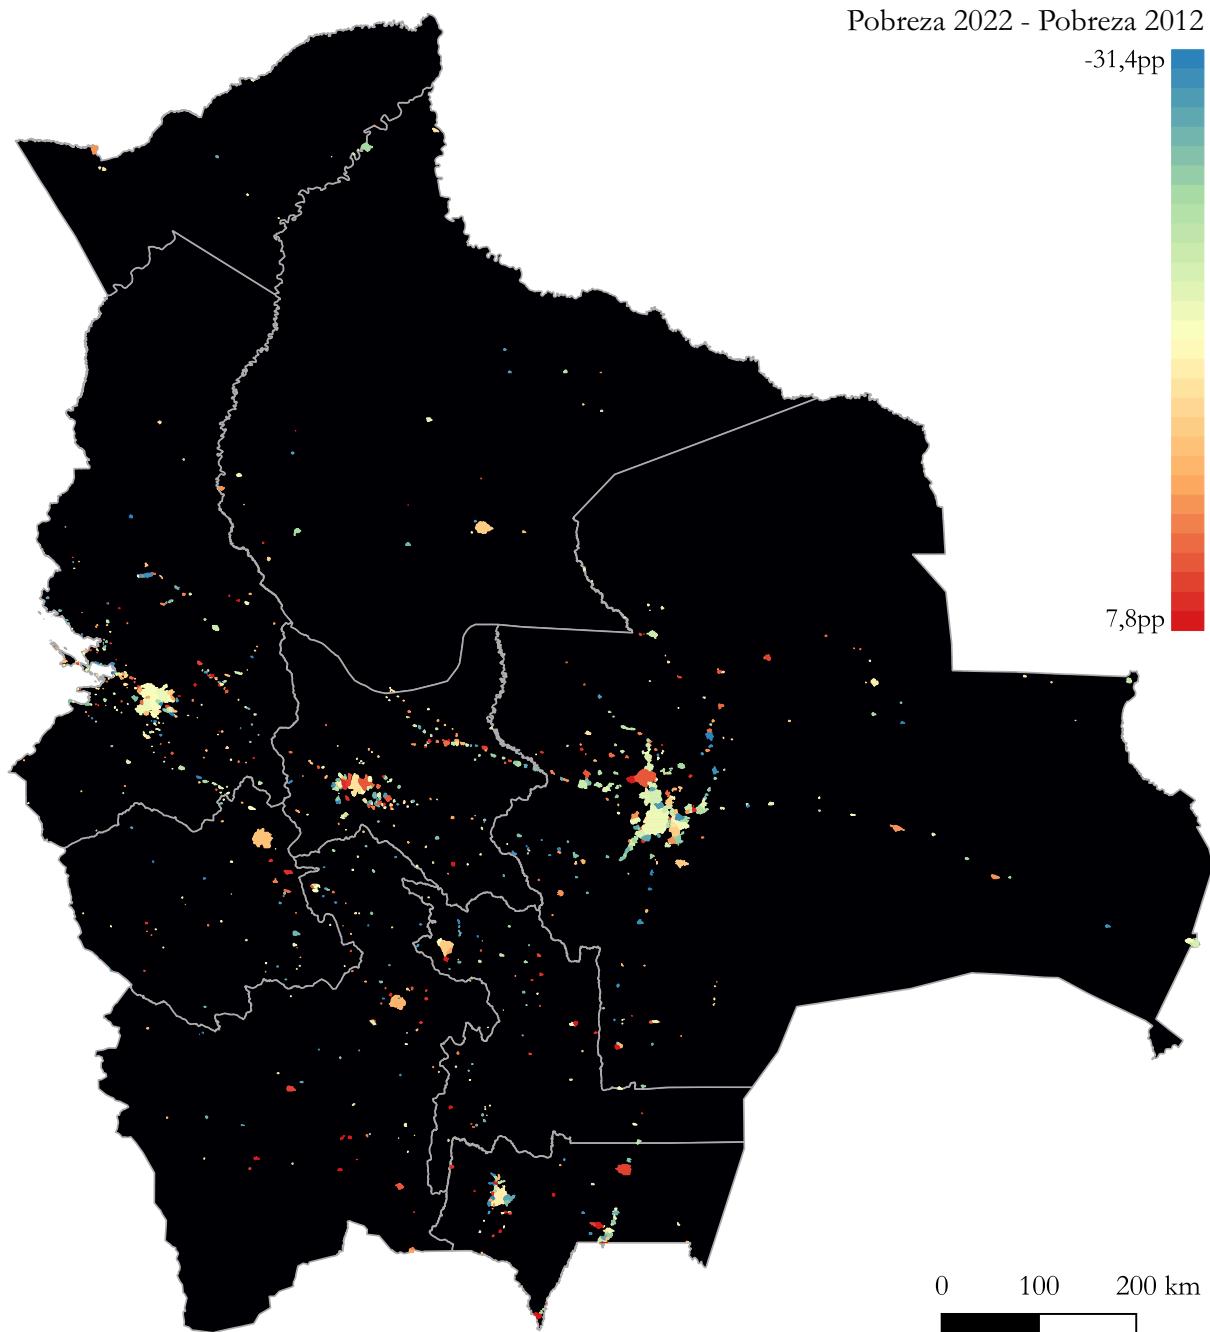
En segundo lugar, si se considera la mediana de la incidencia de pobreza en las comunidades, se aprecia que el departamento de Santa Cruz exhibe la mayor disminución en este indicador entre los años 2012 y 2022, con un descenso de -15,3pp. De hecho, la mediana en el año 2022 sería incluso inferior al percentil 25 registrado en 2012. En contraste, los departamentos de Oruro y La Paz experimentarían reducciones más moderadas en la mediana de la incidencia de pobreza, con disminuciones de -1,3pp y -2.6pp respectivamente, en comparación con las distribuciones en los demás departamentos.

Tercero, es importante notar un desplazamiento de los rangos intercuartílicos hacia una concentración más elevada de comunidades con niveles de pobreza inferiores a los registrados en 2012, en todos los departamentos.

En el Apéndice A se presentan estadísticas que describen características de la distribución de la variable de incidencia de pobreza comunal, desagregado por departamento y

año. Cabe aclarar que estas estadísticas no son comparables con métricas convencionales en las que se calcula el porcentaje de la población total del departamento en situación de pobreza.

Figura 9: Mapa sobre diferencia entre la pobreza de 2022 y 2012



Nota: Las áreas de color negro en el mapa representan zonas donde no se delimitaron comunidades para este estudio. Pueden ser lugares inhabitados o donde hay presencia de comunidades que el año 2012 tenían poblaciones de 500 individuos o menos.

La Figura 9 proporciona una representación visual de las 953 comunidades delimitadas en este estudio, ubicadas en el territorio de Bolivia. Estas comunidades están cartografiadas utilizando una paleta de colores que denota el cambio en términos de puntos porcentuales en sus niveles de pobreza entre los años 2022 y 2012. En particular, si se enfoca la

atención en las comunidades vinculadas a las ciudades capitales y a El Alto, se observa que aquellas que experimentaron las mayores reducciones en sus niveles de pobreza desde 2012 fueron Santa Cruz (-4,1pp), La Paz (-4,0pp) y El Alto (-3,6pp). Por otro lado, Tarija (-2,4pp), Cochabamba (-2,1pp) y Trinidad (-1,5pp) mostraron avances más moderados, mientras que Oruro (-1,2pp), Potosí (0,9pp) y Cobija (-0,2pp) presentaron cambios más conservadores. No obstante, los resultados también revelan que para el año 2022, más del 45 % de las comunidades estudiadas registraron reducciones en la incidencia de pobreza NBI más pronunciadas a las observadas en las comunidades de Santa Cruz, La Paz y El Alto.

Un ejemplo destacado es la comunidad "Tahua", situada en el departamento de Potosí y perteneciente al municipio homónimo. Esta comunidad logró una significativa reducción de -31,4pp en la incidencia de pobreza NBI, disminuyendo de un 56,4 % de su población en situación de pobreza en 2012 a un 24,9 % en 2022. Contrariamente, la comunidad "San Vicente", ubicada en el municipio de Atocha en el departamento de Potosí, experimentó un aumento notable en sus niveles de pobreza (7,8pp) en comparación con 2012.

Por otra parte, el mapa resalta que las comunidades colindantes a las ciudades capitales o próximas a centros económicos tienden a mostrar avances más significativos en la reducción de la pobreza. En el caso de Santa Cruz y La Paz, muchas de las comunidades en áreas urbanas y periurbanas presentaron un desempeño por encima del promedio en la disminución de la pobreza comunitaria.

En lo que respecta al resto de las comunidades, la distribución espacial del cambio en la pobreza NBI muestra cierta heterogeneidad entre regiones y dentro de cada departamento. Para obtener una lista detallada de las comunidades estudiadas —con los departamentos y municipios a los que pertenecen— y los cambios en sus niveles de pobreza NBI en los 10 años transcurridos entre 2012 y 2022, se puede consultar el Apéndice B.

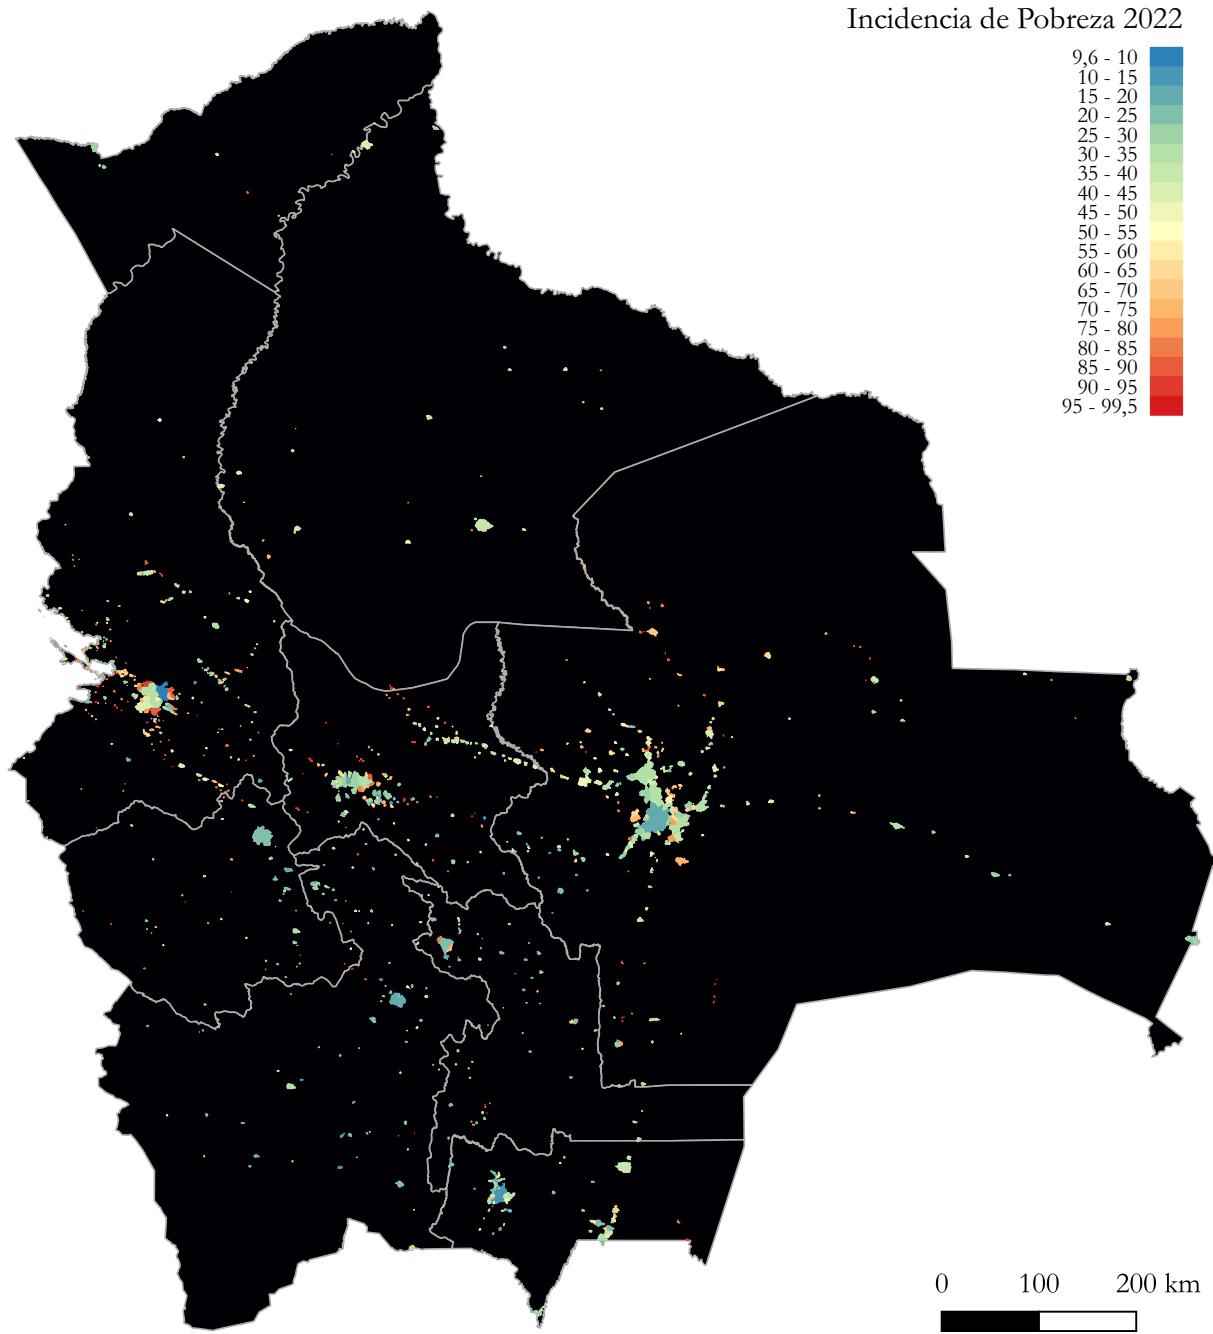
En última instancia, la Figura 10 representa de manera espacial la incidencia de pobreza en las comunidades de estudio para el año 2022. Este análisis geoespacial revela patrones significativos en la distribución de la pobreza a nivel comunitario en Bolivia. Se observa claramente que las comunidades con las tasas más bajas de pobreza se concentran en su mayoría en las áreas urbanas, específicamente en las ciudades capitales y sus zonas circundantes. Ejemplos notables incluyen La Paz (9,6 %), Tarija (14,4 %) y Santa Cruz de la Sierra (16,9 %), que se destacan como las tres ciudades capitales con menor incidencia de pobreza en el país para el año 2022. Además, comunidades como Porongo, que colinda con Santa Cruz de la Sierra, muestran una tasa de pobreza (15,0 %) inferior a la de la propia ciudad capital.

En marcado contraste, las comunidades más empobrecidas se encuentran predominantemente en áreas rurales dispersas, especialmente en las regiones del altiplano, como La Paz, Oruro y Potosí, así como en Cochabamba. Se identifican hasta 68 comunidades donde más del 90 % de su población vive en situación de pobreza, y sorprendentemente, 55 de estas comunidades están ubicadas en los departamentos de La Paz, Oruro, Potosí y Cochabamba.

En el año 2022, las cinco comunidades más afectadas por la pobreza en Bolivia serían Cahuayo (Potosí), Coaque (La Paz), San José de Kala (Oruro), Mutuhuaya (La Paz) e Incacasani (Cochabamba), todas con una incidencia de pobreza NBI superior al 98 %. Estos hallazgos subrayan la marcada disparidad económica y de desarrollo que persiste en el país, con comunidades urbanas disfrutando de tasas de pobreza significativamente más bajas en comparación con sus contrapartes rurales. Estos resultados tienen implicaciones importantes para la formulación de políticas, destacando la necesidad de estrategias es-

pecíficas que aborden las desigualdades regionales y fomenten un desarrollo más equitativo en Bolivia.

Figura 10: Mapa de incidencia de pobreza de 2022



Nota: Las áreas de color negro en el mapa representan zonas donde no se delimitaron comunidades para este estudio. Pueden ser lugares inhabitados o donde hay presencia de comunidades que el año 2012 tenían poblaciones de 500 individuos o menos.

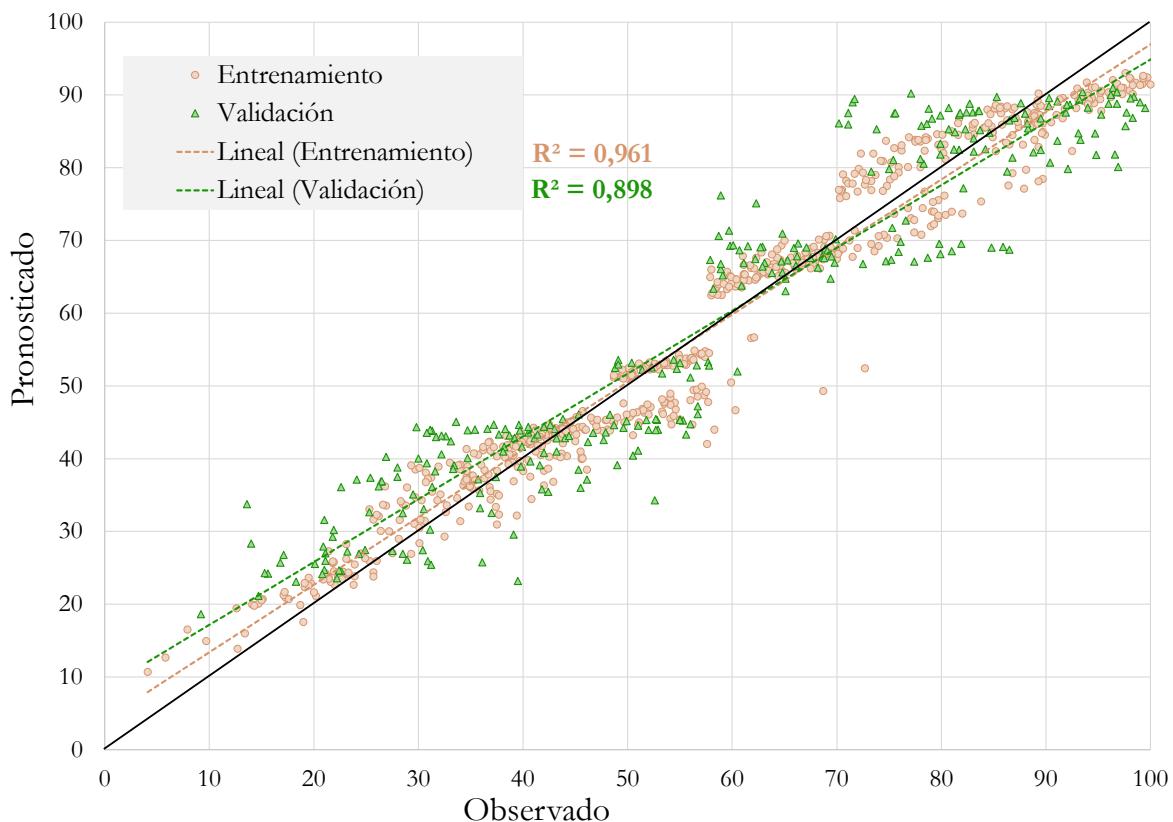
### 3.4. Eficacia en la predicción

En la sección previa se llevaron a cabo análisis de los resultados en el contexto de los pronósticos de incidencia de pobreza NBI para las comunidades de Bolivia. Ahora es esencial profundizar en la evaluación de la precisión de estas predicciones.

En primer lugar, la Figura 11 ilustra el nivel de ajuste entre los datos observados de incidencia de pobreza comunal en el año 2012 y el indicador representado por el valor promedio de los pronósticos generados por los mejores modelos entrenados en el presente estudio. Siguiendo las convenciones habituales en la literatura de pronósticos, se evidencia un ajuste sobresaliente en el caso de los pronósticos realizados para el conjunto de entrenamiento ( $R^2 = 0,961$ ). Cabe destacar que este alto nivel de ajuste es esperado, ya que los modelos se han entrenado precisamente con estos datos. Sin embargo, resulta igualmente significativo el nivel de ajuste obtenido en el conjunto de validación ( $R^2 = 0,898$ ), ya que no se observa una discrepancia sustancial en comparación con el ajuste logrado en los datos de entrenamiento.

Adicionalmente, es relevante señalar que la Figura 11 permite identificar un patrón interesante en los pronósticos. En términos generales, se observa que, para las comunidades con tasas de pobreza relativamente bajas, los pronósticos tienden a ser ligeramente sobreestimados, lo que se refleja en las líneas de regresión —para los sets de entrenamiento y validación— que se sitúan por encima de la línea diagonal de  $45^\circ$  en el gráfico. Por otro lado, en el caso de las comunidades con niveles más elevados de pobreza, los pronósticos tienden a ser ligeramente subestimados, como lo indica la posición de las líneas de regresión por debajo de la línea diagonal de  $45^\circ$  en esta parte del gráfico.

Figura 11: Datos observados vs. pronosticados, según set de entrenamiento y validación



Nota: Las líneas segmentadas corresponden a regresiones lineales estimadas entre los datos observados de la incidencia de pobreza comunal en 2012 y los pronósticos.

Por otra parte, con el propósito de fortalecer la imparcialidad del análisis sobre la

adecuación de las predicciones en este estudio, se ha llevado a cabo una comparación en el Cuadro 4 entre el coeficiente de determinación  $R^2$  de las predicciones de pobreza generadas en esta investigación y el rendimiento de predicciones de pobreza, así como de variables proxy relacionadas, que siguen enfoques metodológicos similares y que se encuentran documentadas en revistas de investigación de reconocido prestigio o en informes de organismos internacionales. Es importante señalar que todos los valores de  $R^2$  analizados en este contexto corresponden a pronósticos fuera de muestra, lo que significa que no incorporan los datos empleados para el entrenamiento de los modelos.

En este contexto, se destaca la notable capacidad predictiva observada en el presente estudio en comparación con la mayoría de las investigaciones con las que se ha realizado la comparativa. Estos resultados sugieren la eficacia de la metodología empleada. Los modelos desarrollados en este trabajo, basados en algoritmos de machine learning y respaldados por datos de imágenes satelitales, Open Street Map y otras fuentes geoespaciales, se han revelado como indicadores significativos en la medición de la pobreza en las comunidades de Bolivia. Específicamente, para los algoritmos que modelan relaciones no lineales, se ha conseguido obtener un coeficiente de determinación ( $R^2$ ) de 0,898 cuando se realiza el promedio —geométrico y ponderado— de sus predicciones de la incidencia de pobreza.<sup>16</sup>

Este desempeño adquiere aún más relevancia al considerar que las comparaciones se llevaron a cabo con investigaciones previas que han sido publicadas en revistas de alto renombre, como Science. Por ejemplo, el trabajo de Jean et al. (2016), que empleó técnicas de deep learning con datos de imágenes satelitales para predecir la riqueza de activos —proxy de la inversa de pobreza—, obtuvo coeficientes  $R^2$  que variaron entre 0,55 y 0,75. Del mismo modo, investigaciones como la de Blumenstock et al. (2015), también publicada en Science, lograron un coeficiente  $R^2$  de 0,916 al predecir el índice de riqueza mediante el uso de algoritmos de machine learning en conjunción con metadatos de telefonía móvil. Aunque esta última investigación arroja un ajuste ligeramente superior en comparación con los resultados obtenidos en este estudio, la disparidad es mínima.

Las razones detrás de este rendimiento pueden estar asociadas a diversos factores. En primer lugar, la metodología empleada en este estudio, que incorpora datos de imágenes satelitales, Open Street Map y otras fuentes geoespaciales, es probable que haya proporcionado una mayor cantidad y calidad de información —para el caso de las comunidades de estudio—, lo que se tradujo en modelos más precisos y sólidos. Además, el empleo de algoritmos de aprendizaje automático, conocidos por su capacidad para identificar patrones complejos en conjuntos de datos extensos, podría haber facilitado la extracción de características significativas que otros enfoques más tradicionales no pudieron capturar, como se evidencia en el estudio de Engstrom et al. (2017).

En segundo lugar, el enfoque cuasi-multidimensional adoptado en este estudio, que considera una amplia gama de variables geoespaciales, condiciones climáticas y geográficas, entre otras, es plausible que haya proporcionado una perspectiva más completa y precisa de los factores determinantes de la pobreza en las comunidades de Bolivia. Este enfoque integral podría haber contribuido a mejorar la capacidad predictiva de los algoritmos utilizados.

---

<sup>16</sup>Es importante resaltar que este rendimiento predictivo no se puede extrapolar necesariamente a comunidades en otros países ni a aquellas en Bolivia que no han sido abordadas en este estudio.

Cuadro 4:  $R^2$  en la predicción de la variable (o proxies) de pobreza

Autores	$R^2$	Journal/Institución	Variable a predecir	Metodología
Presente estudio	0,898		Incidencia de pobreza	Machine learning con datos de imágenes satelitales, Open Street Maps y otros geoespaciales
Chi et al. (2022)	[0,54 - 0,96]	Proceedings of the National Academy of Sciences	Índice de riqueza	Machine learning con datos de imágenes satelitales, telefónicos y Facebook
Yeh et al. (2020)	[0,75 - 0,83]	Nature communications	Riqueza de activos	Deep learning con datos de imágenes satelitales
Hersh et al. (2020)	[0,13 - 0,36]	Inter-American Development Bank	Incidencia de pobreza	Machine learning con datos de imágenes satelitales
Martinez Jr (2020)	[0,42 - 0,53]	Asian Development Bank	Incidencia de pobreza	Machine learning y Deep learning con datos de imágenes satelitales
Steele et al. (2017)	[0,64 - 0,78]	Journal of The Royal Society Interface	Índice de riqueza	Hierarchical Bayesian geostatistical models con datos de imágenes satelitales y telefonía móvil
Engstrom et al. (2017)	[0,60 - 0,61]	World Bank	Incidencia de pobreza	Regresión lineal con datos de imágenes satelitales
Jean et al. (2016)	[0,55 - 0,75]	Science	Riqueza de activos	Deep learning con datos de imágenes satelitales
Blumenshtock et al. (2015)	0,916	Science	Índice de riqueza	Machine learning con metadatos de teléfono móvil

## 4. Conclusiones y recomendaciones

En esta investigación, se ha perseguido el objetivo de pronosticar la incidencia de pobreza a nivel de comunidad en Bolivia para el año 2022 mediante la implementación de algoritmos de machine learning y teledetección. Al mismo tiempo, se ha llevado a cabo una evaluación comparativa con respecto a la situación observada en 2012.

La metodología desarrollada implicó: i) el procesamiento de datos del Censo de 2012 para construir un indicador de pobreza basado en Necesidades Básicas Insatisfechas (NBI) a nivel comunitario; ii) la selección de 953 comunidades con poblaciones superiores a 500 habitantes como unidades de observación; iii) la generación de variables mediante teledetección, incluyendo luminosidad nocturna, áreas urbanas y construidas, densidad de carreteras y red eléctrica, así como el número de bancos, escuelas y hospitales, entre otros; iv) el entrenamiento y validación de algoritmos de machine learning para prever la incidencia de pobreza NBI en 2012, utilizando un 70 % de datos para entrenamiento y un 30 % para validación, además de ajustar hiperparámetros; y v) finalmente, la aplicación de algoritmos entrenados y validados para pronosticar la incidencia de pobreza NBI a nivel de comunidad en 2022. Al combinar el poder predictivo de los algoritmos de machine learning y el potencial de la teledetección, este estudio ofrece una perspectiva innovadora y esclarecedora sobre la evolución de la pobreza a nivel comunitario en Bolivia, que es algo sin precedentes.

Uno de los primeros resultados obtenidos se enfocó en el proceso de ajuste de hiperparámetros para los ocho algoritmos de machine learning empleados en la predicción de la incidencia de pobreza por comunidad en Bolivia. Este proceso de ajuste se basó en una validación cruzada de 10 pliegues, en la cual los algoritmos se entrenaron y evaluaron múltiples veces con diferentes subconjuntos de datos para validar y encontrar los valores óptimos de los hiperparámetros que minimizan el error cuadrático medio. Dentro de este análisis, se evidenció que aquellos algoritmos que modelizan relaciones no lineales entre la variable de incidencia de pobreza y sus predictores, como AdaBoost, Gradient Boosting, Random Forest y Extra Trees, demuestran un rendimiento superior en comparación con aquellos que consideran relaciones lineales, como Ridge, Lasso y ElasticNet. Asimismo, se constató que el proceso de ajuste de hiperparámetros contribuye a mejorar la capacidad de predicción y generalización de los modelos.

Adicionalmente, se procedió a un análisis detallado de la relevancia de las variables generadas mediante teledetección en la predicción de la incidencia de pobreza por comunidad en Bolivia. Los resultados obtenidos destacan que las variables más influyentes en la predicción de la pobreza son el número de bancos y el número de escuelas en cada comunidad. Estas variables fueron seguidas por indicadores tales como el área de asentamientos urbanos, zonas construidas y luminosidad. La importancia de estas variables reside en su capacidad para reflejar el acceso a servicios financieros, educativos e infraestructura básica, así como, la actividad económica y la concentración poblacional, factores que ejercen un papel determinante en el bienestar socioeconómico de las comunidades.

En específico sobre la pobreza a nivel de comunidad, los hallazgos de este estudio ponen de manifiesto un cambio notable en la distribución de la incidencia de pobreza entre los años 2012 y 2022. En términos generales, se constata una tendencia a la disminución de la población en condiciones de pobreza en las comunidades analizadas en relación con el estado en 2012. Sin embargo, resulta especialmente destacable que alrededor del 50 % de estas comunidades presentarían una incidencia de pobreza NBI por debajo del umbral del 42,5 % para el año 2022, lo que supone una mejora sustancial de 14,2 puntos

porcentuales con respecto a los registros de 2012, considerando que la mediana de la incidencia de pobreza comunal basada en los datos de 2012 era del 56,7 %. Al examinar el rango intercuartílico de la distribución de la incidencia de pobreza proyectada para 2022, se evidencia particularmente en el primer cuartil una reducción significativa en comparación con las cifras calculadas para la distribución correspondiente a 2012. Estos resultados apuntan a un cambio positivo en las condiciones socioeconómicas de estas comunidades en el periodo de estudio.

Otro aspecto de notorio interés que emerge de los resultados es el patrón de reducción diferencial en la incidencia de pobreza entre las comunidades estudiadas, basado en sus niveles iniciales de pobreza en 2012. Se observa una mayor disminución en la incidencia de pobreza en las comunidades que ya mantenían niveles más bajos de pobreza en 2012 (con una incidencia por debajo del 60 %), en contraposición a aquellas que partían de situaciones más desfavorecidas (con una incidencia del 60 % o superior). Esta tendencia podría ser explicada por un fenómeno de umbral, donde las comunidades con niveles iniciales de pobreza por debajo del 60 % podrían haber alcanzado un grado de desarrollo que facilitó la reducción de la pobreza mediante oportunidades económicas y una infraestructura previamente establecida. En este sentido, las políticas de desarrollo implementadas entre 2012 y 2022 podrían haber tenido un efecto más impactante en la reducción de la pobreza en estas comunidades, aprovechando los recursos y activos ya existentes.

Por otro lado, las comunidades con niveles iniciales de pobreza superiores al 60 % experimentaron reducciones más moderadas en sus tasas de incidencia de pobreza. Esto podría relacionarse con desafíos estructurales más arraigados que requieren intervenciones más profundas y prolongadas. Para estas comunidades, la mejora en la infraestructura, el acceso a servicios esenciales y la creación de oportunidades económicas podrían necesitar esfuerzos concertados a largo plazo y una combinación de políticas y programas para abordar factores complejos y multifacéticos.

Las recomendaciones para mejorar la situación de las comunidades con avances más limitados en la reducción de la pobreza apuntan a enfoques integrales que aborden tanto los aspectos económicos como los sociales. Inversiones en infraestructura, educación y acceso a servicios de salud se destacan como fundamentales para sentar las bases de un desarrollo sostenible. Los programas de capacitación y empoderamiento que fortalezcan las habilidades y la productividad local pueden aumentar las oportunidades económicas y reducir la vulnerabilidad. La promoción del empleo y la inversión local también pueden ser esenciales para estimular la reactivación económica y la reducción sostenida de la pobreza. En última instancia, la implementación de políticas específicas, adaptadas a las particularidades únicas de cada comunidad, se erige como un pilar crucial para abordar los desafíos individuales que pueden estar frenando la reducción de la pobreza.

Además, un análisis a nivel departamental también puso de relieve disparidades en las tasas de reducción de la incidencia de pobreza entre diferentes regiones. Resulta notable que el departamento de Santa Cruz experimentó la mayor disminución en la mediana de la incidencia de pobreza en sus comunidades, posiblemente vinculado a sus características económicas y estructura productiva diversificada, que han fortalecido las bases para el desarrollo y la disminución de la pobreza. Por el contrario, departamentos como Oruro y La Paz mostraron reducciones más moderadas, lo que podría señalar desafíos estructurales que requieren abordajes específicos y políticas adaptadas. Para las comunidades en estas áreas rezagadas, se sugiere un enfoque personalizado que tome en cuenta las particularidades económicas, geográficas y culturales. La colaboración entre entidades gubernamentales, ONGs y la comunidad local es fundamental para diseñar e implemen-

tar estrategias integrales que respondan a las necesidades y aspiraciones únicas de cada departamento, promoviendo así un desarrollo más equitativo y sostenible.

El análisis geoespacial de la incidencia de pobreza en las comunidades de estudio para el año 2022 evidencia una concentración de tasas bajas de pobreza en áreas urbanas, particularmente en ciudades capitales y sus cercanías, donde destacan La Paz (9,6 %), Tarija (14,4 %) y Santa Cruz de la Sierra (16,9 %) como las ciudades capitales con menor pobreza en el país. Por otro lado, las tasas más elevadas de pobreza prevalecen en áreas rurales, específicamente en las regiones del altiplano y Cochabamba. Sorprendentemente, se identifican 68 comunidades donde más del 90 % de su población vive en situación de pobreza, siendo 55 de estas comunidades parte de los departamentos de La Paz, Oruro, Potosí y Cochabamba. Destacando la marcada disparidad económica y de desarrollo, estos resultados subrayan la necesidad de políticas específicas que aborden las desigualdades regionales y promuevan un desarrollo más equitativo en Bolivia.

Adicionalmente, esta investigación aporta un listado y un mapa que ofrecen una visión detallada de las tendencias de reducción de la pobreza en las 953 comunidades estudiadas entre 2012 y 2022. Se observa una concentración de comunidades con notables avances en la reducción de la pobreza en áreas cercanas a las ciudades capitales y centros económicos. Este fenómeno puede ser atribuido a la proximidad a centros urbanos, que suelen brindar mayores oportunidades de empleo y acceso a servicios esenciales, influyendo en la mejora de las condiciones de vida y la reducción de la pobreza. Las áreas urbanas son a menudo núcleos de actividad económica, educación y atención médica, y las comunidades adyacentes pueden beneficiarse de estas infraestructuras existentes. Sin embargo, las diferencias en los resultados también podrían reflejar desigualdades en los recursos locales, la inversión en infraestructura y la calidad de vida previa. Comunidades con bases económicas más sólidas y acceso previo a servicios esenciales podrían haber tenido ventajas iniciales para lograr reducciones significativas en la pobreza. Estas diferencias subrayan la necesidad de estrategias de desarrollo equitativas y adaptadas, enfocándose en la inversión en infraestructura, educación y servicios básicos en áreas rurales y comunidades menos favorecidas. En este contexto, la descentralización de recursos ([Ugarte y Bolívar, 2018](#)) y la atención específica a áreas rurales remotas son elementos esenciales para fomentar un desarrollo inclusivo y sostenible en todo el país.

Finalmente, se evidenció que el poder predictivo de los algoritmos entrenados y validados para predecir la incidencia de pobreza en las comunidades de Bolivia es equivalente —superior en algunos casos— al observado en investigaciones previas altamente rigurosas y publicadas en revistas de renombre. Esto resalta la eficacia de la metodología empleada y sugiere que la inclusión de datos geoespaciales y el uso de algoritmos de machine learning pueden ser enfoques poderosos para abordar la predicción de la pobreza a nivel comunitario.

## Referencias

- Alkire, S. y Foster, J. (2011a). Counting and multidimensional poverty measurement. *Journal of public economics*, 95(7-8):476–487.
- Alkire, S. y Foster, J. (2011b). Understandings and misunderstandings of multidimensional poverty measurement. *The Journal of Economic Inequality*, 9:289–314.
- Atkinson, A. B. (1987). On the measurement of poverty. *Econometrica: Journal of the Econometric Society*, pages 749–764.
- Banerjee, A., Duflo, E., y Qian, N. (2020). On the road: Access to transportation infrastructure and economic growth in china. *Journal of Development Economics*, 145:102442.
- Battiston, D., Cruces, G., Lopez-Calva, L. F., Lugo, M. A., y Santos, M. E. (2013). Income and beyond: Multidimensional poverty in six latin american countries. *Social indicators research*, 112:291–314.
- Blumenstock, Cadamuro, G., y On, R. (2015). Predicting poverty and wealth from mobile phone metadata. *Science*, 350(6264):1073–1076.
- Blumenstock, J. E. (2016). Fighting poverty with data. *Science*, 353(6301):753–754.
- Bolívar, O. (2020). Evaluación de impacto de la infraestructura vial en el crecimiento económico: Una aproximación con base en información satelital de luminosidad para bolivia. In Bolívar, O., editor, *Evaluación de impacto de la infraestructura vial en Bolivia*, pages 11–70. CAF-UDAPE, La Paz, Bolivia.
- Bolívar, O. (2022). Roads illuminate development: Using nightlight luminosity to assess the impact of transport infrastructure. *Development Bank of Latin America and the Caribbean*, Working Paper 2022/10.
- Bolívar, O. y Ugarte, D. (2020). Evaluación de impacto de la infraestructura vial sobre las condiciones socioeconómicas de la población. In Bolívar, O., editor, *Evaluación de impacto de la infraestructura vial en Bolivia*, pages 71–117. CAF-UDAPE, La Paz, Bolivia.
- Bourguignon, F. y Chakravarty, S. R. (1999). A family of multidimensional poverty measures. In *Advances in econometrics, income distribution and scientific methodology: Essays in honor of Camilo Dagum*, pages 331–344. Springer.
- Bourguignon, F. y Chakravarty, S. R. (2003). The measurement of multidimensional poverty. *The Journal of Economic Inequality*, 1:25–49.
- Breiman, L. (1996). Bagging predictors. *Machine learning*, 24:123–140.
- Burke, M., Hsiang, S. M., y Miguel, E. (2015). Global non-linear effect of temperature on economic production. *Nature*, 527(7577):235–239.
- Cevik, S. y Jalles, J. T. (2023a). Eye of the storm: The impact of climate shocks on inflation and growth. *International Monetary Fund*.
- Cevik, S. y Jalles, J. T. (2023b). For whom the bell tolls: Climate change and income inequality. *Energy Policy*, 174:113475.
- Chen, X. y Nordhaus, W. D. (2011). Using luminosity data as a proxy for economic statistics. *Proceedings of the National Academy of Sciences*, 108(21):8589–8594.
- Chi, G., Fang, H., Chatterjee, S., y Blumenstock, J. E. (2022). Microestimates of wealth for all low-and middle-income countries. *Proceedings of the National Academy of Sciences*, 119(3):e2113658119.
- Dell, M., Jones, B. F., y Olken, B. A. (2012). Temperature shocks and economic growth: Evidence from the last half century. *American Economic Journal: Macroeconomics*, 4(3):66–95.

- Deutsch, J. y Silber, J. (2005). Measuring multidimensional poverty: An empirical comparison of various approaches. *Review of Income and wealth*, 51(1):145–174.
- Diao, X., Hazell, P., y Thurlow, J. (2010). The role of agriculture in african development. *World development*, 38(10):1375–1383.
- Dietterich, T. G. (2000). Ensemble methods in machine learning. In *International workshop on multiple classifier systems*, pages 1–15. Springer.
- Dinkelman, T. (2011). The effects of rural electrification on employment: New evidence from south africa. *American Economic Review*, 101(7):3078–3108.
- Duclos, J.-Y., Sahn, D. E., y Younger, S. D. (2006). Robust multidimensional poverty comparisons. *The economic journal*, 116(514):943–968.
- Duro, D. C., Franklin, S. E., y Dubé, M. G. (2012). A comparison of pixel-based and object-based image analysis with selected machine learning algorithms for the classification of agricultural landscapes using spot-5 hrg imagery. *Remote sensing of environment*, 118:259–272.
- Engstrom, R., Hersh, J. S., y Newhouse, D. L. (2017). Poverty from space: using high-resolution satellite imagery for estimating economic well-being. *World Bank Policy Research Working Paper*, (8284).
- Feldmeyer, D., Meisch, C., Sauter, H., y Birkmann, J. (2020). Using openstreetmap data and machine learning to generate socio-economic indicators. *ISPRS International Journal of Geo-Information*, 9(9):498.
- Foster, A. y Rosenzweig, M. (2010). Microeconomics of technology adoption. *Annu. Rev. Econ.*, 2(1):395–424.
- Foster, J., Greer, J., y Thorbecke, E. (1984). A class of decomposable poverty measures. *Econometrica: journal of the econometric society*, pages 761–766.
- Galbraith, J. K. (1998). *The affluent society*. Houghton Mifflin Harcourt.
- Gallup, J. L., Sachs, J. D., y Mellinger, A. D. (1999). Geography and economic development. *International regional science review*, 22(2):179–232.
- Ghosh, T., L Powell, R., D Elvidge, C., E Baugh, K., C Sutton, P., y Anderson, S. (2010). Sheding light on the global distribution of economic activity. *The Open Geography Journal*, 3(1).
- Henderson, J. V., Storeygard, A., y Weil, D. N. (2012). Measuring economic growth from outer space. *American economic review*, 102(2):994–1028.
- Hersh, J., Martín Rivero, L., Engstrom, R., Mann, M., y Mejía, A. (2020). Mapping income poverty in belize using satellite features and machine learning. *Inter-American Development Bank-Felipe Herrera Library2020*.
- INE (2015). Metodología de las necesidades básicas insatisfechas. *Instituto Nacional de Estadística*.
- Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., y Ermon, S. (2016). Combining satellite imagery and machine learning to predict poverty. *Science*, 353(6301):790–794.
- Jenkins, S. P. y Lambert, P. J. (1997). Three ‘i’s of poverty curves, with an analysis of uk poverty trends. *Oxford economic papers*, 49(3):317–327.
- Kanbur, R. (1990). *Poverty and development: The human development report and the world development report, 1990*, volume 103. World Bank Publications.
- Lambert, D. K. (2014). Historical impacts of precipitation and temperature on farm production in kansas. *Journal of Agricultural and Applied Economics*, 46(4):439–456.
- Liu, Y., Zuo, R., y Dong, Y. (2021). Analysis of temporal and spatial characteristics

- of urban expansion in xiaonan district from 1990 to 2020 using time series landsat imagery. *Remote Sensing*, 13(21):4299.
- Mantovani, R. G., Horváth, T., Cerri, R., Junior, S. B., Vanschoren, J., y de Carvalho, A. C. P. d. L. F. (2018). An empirical study on hyperparameter tuning of decision trees. *arXiv preprint arXiv:1812.02207*.
- Martinez Jr, A. M. (2020). Mapping poverty through data integration and artificial intelligence. *UNESCAP: United Nations Economic and Social Commission for Asia and the Pacific*.
- Melchiorri, M., Florczyk, A. J., Freire, S., Schiavina, M., Pesaresi, M., y Kemper, T. (2018). Unveiling 25 years of planetary urbanization with remote sensing: Perspectives from the global human settlement layer. *Remote Sensing*, 10(5):768.
- Min, P. P., Gan, Y. W., Hamzah, S. N. B., Ong, T. S., y Sayeed, M. S. (2022). Poverty prediction using machine learning approach. *Journal of Southwest Jiaotong University*, 57(1).
- Mueller, V. A. y Osgood, D. E. (2009). Long-term consequences of short-term precipitation shocks: evidence from brazilian migrant households. *Agricultural Economics*, 40(5):573–586.
- Nordhaus, W. D. (2006). Geography and macroeconomics: New data and new findings. *Proceedings of the National Academy of Sciences*, 103(10):3510–3517.
- Orshansky, M. (1969). How poverty is measured. *Monthly Lab. Rev.*, 92:37.
- Piaggesi, S., Gauvin, L., Tizzoni, M., Cattuto, C., Adler, N., Verhulst, S., Young, A., Price, R., Ferres, L., y Panisson, A. (2019). Predicting city poverty using satellite imagery. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pages 90–96.
- Ravallion, M. (2011). On multidimensional indices of poverty. *The Journal of Economic Inequality*, 9:235–248.
- Steele, J. E., Sundsøy, P. R., Pezzulo, C., Alegana, V. A., Bird, T. J., Blumenstock, J., Bjelland, J., Engø-Monsen, K., De Montjoye, Y.-A., Iqbal, A. M., et al. (2017). Mapping poverty using mobile phone and satellite data. *Journal of The Royal Society Interface*, 14(127):20160690.
- Tang, B., Sun, Y., Liu, Y., y Matteson, D. S. (2018). Dynamic poverty prediction with vegetation index. *32nd Conference on Neural Information Processing Systems (NIPS 2018)*.
- Thon, D. (1979). On measuring poverty. *Review of Income and Wealth*, 25(4):429–439.
- Tingzon, I., Orden, A., Go, K., Sy, S., Sekara, V., Weber, I., Fatehkia, M., García-Herranz, M., y Kim, D. (2019). Mapping poverty in the philippines using machine learning, satellite imagery, and crowd-sourced geospatial information. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, 42:425–431.
- Tsui, K.-y. (2002). Multidimensional poverty indices. *Social choice and welfare*, 19:69–93.
- Ugarte, D. y Bolivar, O. (2018). Descentralización en bolivia: Eficacia y externalidades. *Instituto de Estudios Avanzados en Desarrollo (INESAD)*.
- Wolpert, D. H. (1992). Stacked generalization. *Neural networks*, 5(2):241–259.
- Yeh, C., Perez, A., Driscoll, A., Azzari, G., Tang, Z., Lobell, D., Ermon, S., y Burke, M. (2020). Using publicly available satellite imagery and deep learning to understand economic well-being in africa. *Nature communications*, 11(1):2583.
- Zhongming, Z. and Linong, L., Xiaona, Y., Wangqiang, Z., y Wei, L. (2021). Mapping the spatial distribution of poverty using satellite imagery in thailand. *Asian Develop-*

*ment Bank.*

- Zhou, M., Lu, L., Guo, H., Weng, Q., Cao, S., Zhang, S., y Li, Q. (2021). Urban sprawl and changes in land-use efficiency in the beijing–tianjin–hebei region, china from 2000 to 2020: A spatiotemporal analysis using earth observation data. *Remote Sensing*, 13(15):2850.

## A. Estadísticas por departamentos

Departamento	Comunidades	2012				2022			
		Media	P25	P50	P75	Media	P25	P50	P75
Potosí	86	48,0	25,9	43,0	67,0	41,9	22,1	28,7	64,4
Chuquisaca	59	49,6	31,6	41,7	70,3	43,0	23,5	29,0	66,6
Tarija	67	46,2	28,2	45,9	58,3	39,1	23,8	32,0	57,8
Santa Cruz	237	56,9	42,0	56,1	70,9	50,2	31,3	40,8	68,4
Pando	11	57,8	35,6	56,0	76,3	53,2	29,8	42,2	74,3
Beni	25	58,7	49,6	56,3	71,1	52,7	35,4	42,7	72,9
Cochabamba	174	58,2	39,8	54,9	75,2	52,0	28,7	43,6	75,0
La Paz	246	65,3	49,9	67,8	83,1	59,7	32,3	65,2	81,9
Oruro	48	62,7	41,0	67,9	84,4	57,4	26,1	66,6	82,9

Nota: Estas estadísticas se derivan de las distribuciones de la variable incidencia de pobreza NBI comunal, con datos observados para 2012 y pronósticos para 2022.

## B. $\Delta$ en la pobreza NBI entre 2022 y 2012

Departamento	Municipio	Comunidad	$\Delta$ pobreza
Chuquisaca	Sucre	SUCRE	-1,8
Chuquisaca	Sucre	KORA KORA	-0,7
Chuquisaca	Sucre	POTOLO	-17,4
Chuquisaca	Sucre	EL CHACO	-16,2
Chuquisaca	Sucre	SURIMA	-25,8
Chuquisaca	Sucre	KUCHU TAMBO	-3,7
Chuquisaca	Sucre	CHUQUI CHUQUI	-17,3
Chuquisaca	Yotala	SAN ISIDRO DE ANFAYA	-16,7
Chuquisaca	Yotala	YOTALA	6,7
Chuquisaca	Poroma	POROMA	-2,4
Chuquisaca	Azurduy	AZURDUY	1,9
Chuquisaca	Tarvita	TARVITA	-15,1
Chuquisaca	Tarvita	PAMPA HUASI	-1,0
Chuquisaca	Tarvita	SAN PEDRO	-11,8
Chuquisaca	Zudañez	ZUDANEZ	-9,3
Chuquisaca	Presto	PRESTO	-24,3
Chuquisaca	Presto	TOMOROCO	0,0
Chuquisaca	Mojocoya	REDENCION PAMPA	-11,7
Chuquisaca	Padilla	PADILLA	3,1
Chuquisaca	Tomina	TOMINA	-12,3
Chuquisaca	Sopachuy	AMANCAYA	-0,2
Chuquisaca	Sopachuy	SOPACHUY	-15,4
Chuquisaca	Villa Alcala	ALCALA	2,1
Chuquisaca	Villa Alcala	LIMA BAMBA CENTRO	-4,4
Chuquisaca	El Villar	EL VILLAR	1,0
Chuquisaca	Monteagudo	CANDUA	-8,5
Chuquisaca	Monteagudo	MONTEAGUDO	3,7
Chuquisaca	Monteagudo	SAN MIGUEL DE LAS PAMPAS	-3,0
Chuquisaca	Monteagudo	SAN MIGUEL DEL BAÑADO	-1,4
Chuquisaca	Huacareta	HUACARETA	-10,0
Chuquisaca	Tarabuco	CORORO	1,2
Chuquisaca	Tarabuco	TARABUCO	-11,3
Chuquisaca	Yamparaez	MOLLE PUNKU	-1,6
Chuquisaca	Yamparaez	YAMPARAEZ	-16,4
Chuquisaca	Yamparaez	SOTOMAYOR	-10,1
Chuquisaca	Camargo	CAMARGO	3,7
Chuquisaca	San Lucas	PADCOYO	-6,7
Chuquisaca	San Lucas	SAN LUCAS	0,1
Chuquisaca	San Lucas	CHIÑIMAYU	-2,9
Chuquisaca	San Lucas	PALACIO TAMBO	-14,0
Chuquisaca	San Lucas	MALLIRI	-15,2
Chuquisaca	Incahuasi	LA BANDA	-1,6
Chuquisaca	Incahuasi	MIRAFLORES	-1,8
Chuquisaca	Incahuasi	INCAHUASI	-17,2
Chuquisaca	Villa Charcas	PALCAPATA	-1,9
Chuquisaca	Villa Charcas	VILLA CHARCAS	-14,7
Chuquisaca	Villa Charcas	SACARI	-3,1
Chuquisaca	Villa Charcas	PUCARA	-2,8
Chuquisaca	Villa Serrano	VILLA SERRANO	1,9
Chuquisaca	Villa Serrano	MENDOZA	-14,8
Chuquisaca	Villa Abecia	VILLA ABECIA	-11,2
Chuquisaca	Culpina	LA BANDA	0,7
Chuquisaca	Culpina	SAJLINA	1,5
Chuquisaca	Culpina	CULPINA	-15,1
Chuquisaca	Las Carreras	LAS CARRERAS	-12,8
Chuquisaca	Muyupampa	MUYUPAMPA	2,1
Chuquisaca	Machareti	MACHARETI	-3,7
Chuquisaca	Machareti	ÑANCORAINZA	3,0
Chuquisaca	Machareti	TIGUIPA	-11,2
La Paz	Nuestra Señora de La Paz	LA PAZ	-4,0
La Paz	Nuestra Señora de La Paz	PANTINI	-1,5
La Paz	Nuestra Señora de La Paz	APAÑA	-3,9
La Paz	Palca	CHOQUECOTA	4,7
La Paz	Palca	UNI	-0,6
La Paz	Palca	PALCA	-17,7
La Paz	Palca	COHONI	-4,9

Departamento	Municipio	Comunidad	$\Delta pobreza$
La Paz	Palca	MUTUHUAYA	-0,7
La Paz	Mecapaca	AVIRCATO	-12,8
La Paz	Mecapaca	EL PALOMAR	-23,9
La Paz	Mecapaca	HUAJCHILLA	1,7
La Paz	Mecapaca	HUARICANA ALTA	-1,6
La Paz	Mecapaca	LAS CARRERAS	-4,7
La Paz	Mecapaca	MECAPACA	-6,9
La Paz	Mecapaca	TAYPICHULO	-9,6
La Paz	Mecapaca	SANTIAGO DE COLLANA	-1,7
La Paz	Achocalla	ACHOCALLA	-12,5
La Paz	Achocalla	UYPACA	-28,4
La Paz	Achocalla	TUNI	-2,0
La Paz	El Alto	EL ALTO	-3,6
La Paz	Achacachi	ACHACACHI	-2,7
La Paz	Achacachi	CHIJIPINA CHICO	-14,1
La Paz	Achacachi	CHIJIPINA GRANDE	-13,3
La Paz	Achacachi	TARAMAYA	-13,7
La Paz	Achacachi	AJLLATA GRANDE	-1,5
La Paz	Achacachi	APURAYA BAJA	-0,8
La Paz	Achacachi	JAPURAYA ALTA	0,8
La Paz	Achacachi	CACHI LIPE	-5,1
La Paz	Achacachi	CHALLUYO	1,4
La Paz	Achacachi	TAHARI	-0,2
La Paz	Achacachi	WARISATA	-13,6
La Paz	Ancoraimes	ANCORAIMES	-20,5
La Paz	Chua Cocani	CHUA COCANI	-23,7
La Paz	Chua Cocani	CHUA VISALAYA	-27,5
La Paz	Huarina	COROMATA BAJA	4,8
La Paz	Huarina	HUARINA	-18,9
La Paz	Santiago de Huata	SANTIAGO DE HUATA	2,3
La Paz	Santiago de Huata	CHUQUÍNAPI	-1,2
La Paz	Santiago de Huata	TAJOCACHI	-3,3
La Paz	Huatajata	SANCA JAHUIRA	-16,2
La Paz	Huatajata	SONCACHI CHICO	-14,0
La Paz	Coro Coro	CORO CORO	-5,9
La Paz	Caquiaviri	CAQUIAVIRI	-13,5
La Paz	Calacoto	ULLOMA	-10,2
La Paz	Calacoto	PAHAZA	-1,6
La Paz	Calacoto	PICHACA	-1,9
La Paz	Charaña	CHARAÑA	-4,2
La Paz	Waldo Ballivian	TUMARAPI	-2,6
La Paz	Santiago de Callapa	GUANA GRANDE	-0,7
La Paz	Puerto Acosta	PUERTO ACOSTA	-17,2
La Paz	Puerto Carabuco	PUERTO CARABUCO	-16,1
La Paz	Puerto Carabuco	QUILIMA	-3,1
La Paz	Puerto Carabuco	CHAGUAYA CENTRO	-12,6
La Paz	Escoma	ESCOMA	-15,7
La Paz	Chuma	CHAJLAYA	0,0
La Paz	Sorata	SORATA	-9,4
La Paz	Sorata	INGENIO	4,7
La Paz	Sorata	ILABAYA	-1,3
La Paz	Sorata	COOCO	0,2
La Paz	Sorata	MILLIPAYA	-2,2
La Paz	Guanay	CANDELARIA	-17,1
La Paz	Guanay	GUANAY	0,4
La Paz	Guanay	CARURA	-15,1
La Paz	Tacacoma	TACACOMA	-16,6
La Paz	Tacacoma	CHUMISA	3,8
La Paz	Combaya	COMBAYA	-0,8
La Paz	Combaya	SOREJAYA	-0,3
La Paz	Tipuani	CANGALLI	-10,5
La Paz	Tipuani	LA RINCONADA	-0,7
La Paz	Tipuani	TIPUANI	-15,6
La Paz	Tipuani	SAN JUAN DE PALTANI	-15,9
La Paz	Tipuani	UNUTULUNI	-0,2
La Paz	Tipuani	MOLLETERIO	0,0
La Paz	Mapiri	ACHIQUIRI	-1,4
La Paz	Mapiri	CHAROPAMPA - DISPERSO	0,5
La Paz	Mapiri	SANTA ROSA DE MAPIRI	-21,3
La Paz	Mapiri	MAPIRI	-19,0
La Paz	Mapiri	SAN ANSELMO	-3,3
La Paz	Mapiri	VENTANILLANI	0,4
La Paz	Teoponte	TEOPONTE	-6,6

Departamento	Municipio	Comunidad	$\Delta pobreza$
La Paz	Apolo	APOLO	-21,8
La Paz	Pelechuco	PELECHUCO	-15,7
La Paz	Viacha	VIACHA	-4,5
La Paz	Viacha	ACHICA BAJA	-1,2
La Paz	Viacha	CHONCHOCORO	0,7
La Paz	Viacha	ACHICA ARRIBA	-3,4
La Paz	Viacha	MAZO CRUZ	-2,6
La Paz	Viacha	VILLA REMEDIOS	-22,3
La Paz	Viacha	ICHURAYA GRANDE	-2,6
La Paz	Guaqui	ANDAMARCA	2,6
La Paz	Guaqui	LACUYO SAN ANTONIO	1,7
La Paz	Guaqui	SULLCATA	-2,8
La Paz	Guaqui	GUQUI	-13,0
La Paz	Guaqui	PUERTO GUAQUI	-13,7
La Paz	Tiawanacu	ACHACA	-0,4
La Paz	Tiawanacu	TIAWANACU	-10,8
La Paz	Tiawanacu	PILLAPI	-2,9
La Paz	Tiawanacu	HUACULLANI	-2,1
La Paz	Tiawanacu	HUAYCUYO	-2,9
La Paz	Desaguadero	AZAFRANAL	-5,2
La Paz	Desaguadero	DESAGUADERO	-14,3
La Paz	Jesus de Machaca	JESUS DE MACHACA	-25,1
La Paz	Jesus de Machaca	CORPA	-0,1
La Paz	Jesus de Machaca	TITICANI TUCARI	0,5
La Paz	Jesus de Machaca	KALLA BAJA	-8,8
La Paz	Taraco	ÑACHOCA	-2,8
La Paz	Taraco	COACOLLO	2,1
La Paz	Luribay	LURIBAY	-1,1
La Paz	Luribay	ANCHALLANI	-0,2
La Paz	Yaco	YACO	-3,0
La Paz	Yaco	TABLACHACA	0,9
La Paz	Malla	MALLA	-2,0
La Paz	Cairoma	CAIROMA	-3,1
La Paz	Cairoma	COLLPANI	7,1
La Paz	Cairoma	VILOCO	-1,0
La Paz	Inquisivi	INQUISIVI	-14,0
La Paz	Quime	QUIME	-13,9
La Paz	Quime	CHOQUETANGA	-27,3
La Paz	Cajuata	CAJUATA	-8,0
La Paz	Cajuata	CAÑAMINA	-2,7
La Paz	Cajuata	CIRCUATA	-17,0
La Paz	Cajuata	MIGUILAS	-2,2
La Paz	Cajuata	VILLA BARRIENTOS	-4,0
La Paz	Colquiri	CAMPAMENTO COLQUIRI	-9,6
La Paz	Ichoca	ICHOMA	3,8
La Paz	Ichoca	FRANZ TAMAYO	-0,4
La Paz	Villa Libertad Licoma	LICOMA	-15,0
La Paz	Chulumani	CHULUMANI	3,9
La Paz	Chulumani	CHIMASI	-2,6
La Paz	Chulumani	VILLA REMEDIOS	-14,6
La Paz	Chulumani	PASTO PATA	-9,6
La Paz	Chulumani	COLPAR	-0,6
La Paz	Chulumani	HUANCANE	-17,4
La Paz	Chulumani	NARANJANI	-1,7
La Paz	Irupana	IRUPANA	1,1
La Paz	Irupana	LAMBATE	-2,5
La Paz	Irupana	BOLSA NEGRA	0,3
La Paz	Irupana	CHICALOMA	0,2
La Paz	Yanacachi	CAMPAMENTO MINERO LA CHOJLLA	3,6
La Paz	Palos Blancos	COVENDO	-0,5
La Paz	Palos Blancos	INICUA	-0,5
La Paz	Palos Blancos	PALOS BLANCOS	-4,8
La Paz	Palos Blancos	SANTA ANA DE MOSETENES	2,9
La Paz	Palos Blancos	SAPECHO	7,2
La Paz	La Asunta	LA ASUNTA	-23,7
La Paz	La Asunta	CHARIA	-2,3
La Paz	La Asunta	LA CALZADA	-6,5
La Paz	La Asunta	SANTA ROSA	-1,8
La Paz	La Asunta	SIGUANI GRANDE	-0,5
La Paz	La Asunta	YANAMAYU	-1,5
La Paz	La Asunta	SANTIAGO TOCORONI	-1,3
La Paz	Pucarani	ANCOCAGUA	-0,3

Departamento	Municipio	Comunidad	$\Delta pobreza$
La Paz	Pucarani	PUCARANI	-2,2
La Paz	Pucarani	COHANA	0,7
La Paz	Pucarani	CHUÑAVI	-1,4
La Paz	Pucarani	PATAMANTA	0,9
La Paz	Pucarani	CHOJASIVI	-0,5
La Paz	Pucarani	PALCOCO	0,5
La Paz	Pucarani	CATAVI	-4,9
La Paz	Pucarani	CORAPATA	-3,4
La Paz	Pucarani	VILLA VILAQUE	2,0
La Paz	Pucarani	VILAQUE PAMPAJASI	-3,8
La Paz	Laja	COPAJIRA	-4,4
La Paz	Laja	LAJA	-13,6
La Paz	Laja	PUCHUCOLLO ALTO	-0,4
La Paz	Laja	TAMBILLO	1,5
La Paz	Laja	CALLAMARCA	-3,2
La Paz	Laja	CANTAPA	-5,1
La Paz	Laja	SACACANI	-1,2
La Paz	Laja	CUCUTA	-0,4
La Paz	Batallas	BATALLAS	-4,8
La Paz	Batallas	CATACORA	1,7
La Paz	Batallas	CHIRAPACA	-0,6
La Paz	Batallas	CULLUCACHI	-0,8
La Paz	Batallas	PARIRI	-8,0
La Paz	Batallas	YAURI CHAMBI	-1,8
La Paz	Batallas	KARHUIZA	-5,9
La Paz	Batallas	CALASAYA	-0,4
La Paz	Batallas	TUQUIA	-1,9
La Paz	Batallas	IGACHI	-5,2
La Paz	Puerto Perez	CACHILAYA	-1,8
La Paz	Puerto Perez	PUERTO PEREZ	-30,8
La Paz	Puerto Perez	ISLA SURIQUI	-2,0
La Paz	Puerto Perez	CUMANA	-5,0
La Paz	Sica sica	SICA SICA	-23,8
La Paz	Sica sica	AYAMAYA	-1,1
La Paz	Sica sica	LAHUACHACA	-11,9
La Paz	Sica sica	BELEN	-7,7
La Paz	Sica sica	CATAVI	-1,9
La Paz	Sica sica	AYZACOLLO	-4,6
La Paz	Sica sica	HUANOCOLLO	0,7
La Paz	Sica sica	KONANI	-5,9
La Paz	Sica sica	CALA CALA	-5,4
La Paz	Sica sica	PANDURO	-3,9
La Paz	Ayo Ayo	AYO AYO	1,1
La Paz	Ayo Ayo	QUILLCOMA LLUJTURI	-1,6
La Paz	Ayo Ayo	ALTO POMANI	-4,1
La Paz	Ayo Ayo	POMANI	0,7
La Paz	Calamarca	CALAMARCA	-19,3
La Paz	Calamarca	CAÑUMA	1,0
La Paz	Calamarca	SAN ANTONIO	-4,1
La Paz	Calamarca	SENKATA ALTA	-1,4
La Paz	Calamarca	VILLA EL CARMEN CALUYO	-1,6
La Paz	Calamarca	CHOCOROSI	-1,9
La Paz	Calamarca	HUAYHUASI	-5,8
La Paz	Calamarca	VILAQUE COPATA	-2,3
La Paz	Patacamaya	PATACAMAYA	-10,1
La Paz	Patacamaya	VILLA PATARANI	-3,6
La Paz	Colquencha	COLQUENCHA	-2,2
La Paz	Colquencha	SANTIAGO DE LLALLAGUA	-5,7
La Paz	Colquencha	MARQUIRIVI	-4,3
La Paz	Colquencha	ESCOHOCO	-8,2
La Paz	Collana	COLLANA	-2,8
La Paz	Collana	UNCALLAMAYA	-4,4
La Paz	Collana	SAN NICOLAS	-7,3
La Paz	Coroico	CARMEN PAMPA	-11,3
La Paz	Coroico	COROICO	1,7
La Paz	Coripata	AUQUISAMAÑA	-11,1
La Paz	Coripata	COSCOMA	-10,7
La Paz	Coripata	CORIPATA	3,4
La Paz	Coripata	SANTA GERTRUDIS	-15,2
La Paz	Coripata	ARAPATA	-15,4
La Paz	Coripata	SAN AGUSTIN	-1,5

Departamento	Municipio	Comunidad	$\Delta pobreza$
La Paz	Coripata	TRINIDAD PAMPA	-17,8
La Paz	Ixiamas	IXIAMAS	-1,9
La Paz	San Buena Ventura	SAN BUENAVENTURA	-12,7
La Paz	San Buena Ventura	TUMUPASA	-12,3
La Paz	Charazani (Gral, Perez)	CHARAZANI	-18,6
La Paz	Charazani (Gral, Perez)	AMARETE	-2,0
La Paz	Charazani (Gral, Perez)	CHULLINA	-1,2
La Paz	Curva	CURVA	1,9
La Paz	Copacabana	COPACABANA	-0,8
La Paz	Copacabana	LOCKA	-2,7
La Paz	Copacabana	YUMANI	-0,6
La Paz	Copacabana	CHALLA ISLA DEL SOL	0,1
La Paz	San Pedro de Tiquina	SAN PEDRO DE TIQUINA	-15,1
La Paz	San Pedro de Tiquina	SAN PABLO DE TIQUINA	-13,5
La Paz	San Pedro de Tiquina	VILLA AMACARI	-3,5
La Paz	Tito Yupanqui	ALTO SIHUALAYA	-1,8
La Paz	Tito Yupanqui	CHIQUIPATA	-2,5
La Paz	Tito Yupanqui	COAQUIPA	0,5
La Paz	Tito Yupanqui	HUATAPAMPA	-2,8
La Paz	Tito Yupanqui	TITO YUPANQUI	1,4
La Paz	Catacora	CATACORA	-0,9
La Paz	Caranavi	CARANAVI	-7,7
La Paz	Caranavi	ALCOCHE	-10,7
Cochabamba	Cochabamba	COCHABAMBA	-2,1
Cochabamba	Aiquile	NOVILLERO	0,3
Cochabamba	Aiquile	AIQUILE	3,4
Cochabamba	Aiquile	VILLA GRANADO	-2,8
Cochabamba	Pasorapa	PASORAPA	-16,6
Cochabamba	Omereque	OMEREQUE	-2,5
Cochabamba	Independencia	INDEPENDENCIA	0,5
Cochabamba	Independencia	KAMI	-19,2
Cochabamba	Independencia	PATIÑO ALTO	-21,6
Cochabamba	Independencia	VILLA HERMOSA	-20,0
Cochabamba	Independencia	CALCHANI	-2,3
Cochabamba	Morochata	MOROCHATA	1,1
Cochabamba	Morochata	SAN ISIDRO	-2,7
Cochabamba	Morochata	CHINCHIRI	-1,1
Cochabamba	Cocapata	INCACASANI	1,2
Cochabamba	Cocapata	ICARI	-1,9
Cochabamba	Tarata	TARATA	1,0
Cochabamba	Tarata	HUAYCULI	0,2
Cochabamba	Anzaldo	ANZALDO	-15,6
Cochabamba	Arbieto	TIATACO	-8,4
Cochabamba	Arbieto	ARBIETO	-15,4
Cochabamba	Arbieto	ARBIETO COCHABAMBA	-2,0
Cochabamba	Arbieto	MAMANACA	-18,3
Cochabamba	Arbieto	SANTA ROSA DE LIMA	-2,3
Cochabamba	Arbieto	LLAVE MAYU	-3,8
Cochabamba	Arbieto	ALTO LITORAL	-1,8
Cochabamba	Sacabamba	SACABAMBA	-1,6
Cochabamba	Arani	ARANI	-6,2
Cochabamba	Arani	POCOATA	-17,4
Cochabamba	Vacas	JUNTU TUYU	-2,2
Cochabamba	Vacas	MISUKANI	-3,9
Cochabamba	Vacas	PAREDONES	-3,9
Cochabamba	Vacas	RODEO	-3,5
Cochabamba	Vacas	VACAS	-15,8
Cochabamba	Capinota	APILLAPAMPA	-2,5
Cochabamba	Capinota	BUEN RETIRO	-8,4
Cochabamba	Capinota	CAPINOTA	-1,5
Cochabamba	Capinota	SARCO BAMBA	-2,6
Cochabamba	Capinota	YATAMOCO	-28,4
Cochabamba	Capinota	IRPA IRPA	-6,2
Cochabamba	Santivañez	SANTIVAÑEZ	2,3
Cochabamba	Sicaya	SICAYA	-0,1
Cochabamba	Cliza	CLIZA	1,0
Cochabamba	Cliza	VILLA FLORIDA	-20,7
Cochabamba	Cliza	VILLA SURUMI	-9,5
Cochabamba	Cliza	CHULLPAS	0,1
Cochabamba	Cliza	HUASACALLE ALTO	-11,1
Cochabamba	Cliza	UCUREÑA	1,8
Cochabamba	Cliza	VILLA EL CARMEN	-18,3

Departamento	Municipio	Comunidad	$\Delta pobreza$
Cochabamba	Toco	TOKO	-15,1
Cochabamba	Tolata	TOLATA	-14,9
Cochabamba	Quillacollo	QUILLACOLLO	2,1
Cochabamba	Quillacollo	EL PASO	-15,8
Cochabamba	Quillacollo	PANDOJA	-13,5
Cochabamba	Quillacollo	EL PASO	-11,8
Cochabamba	Sipesipe	SINDICATO PIRHUAS (OTB)	-2,5
Cochabamba	Sipesipe	SINDICATO SQUI SQUIA	-1,8
Cochabamba	Sipesipe	SIPE SIPE	-4,7
Cochabamba	Sipesipe	SORATA	-1,7
Cochabamba	Sipesipe	SUTICOLLO	-10,1
Cochabamba	Sipesipe	VILLA MONTENEGRO	-11,5
Cochabamba	Sipesipe	VALLE HERMOSO	-11,4
Cochabamba	Sipesipe	COLPAP CENTRO	-1,1
Cochabamba	Sipesipe	ITAPAYA	-16,6
Cochabamba	Sipesipe	PAROTANI	-13,0
Cochabamba	Sipesipe	TAJRA	-23,4
Cochabamba	Sipesipe	COACHACA CHICO	-11,9
Cochabamba	Sipesipe	HUAÑACAHUA	-12,0
Cochabamba	Sipesipe	MALLCO CHAPI	-13,1
Cochabamba	Sipesipe	MALLCO RANCHO	-12,5
Cochabamba	Sipesipe	PAYACOLLO	-15,9
Cochabamba	Sipesipe	VINTO CHICO	-3,7
Cochabamba	Tiquipaya	TIQUIPAYA	1,3
Cochabamba	Tiquipaya	CHAPISIRCA	-2,3
Cochabamba	Vinto	VINTO	-3,0
Cochabamba	Vinto	POTRERO	-5,1
Cochabamba	Vinto	VILOMA GRANDE	-21,1
Cochabamba	Vinto	FALSURI	-0,5
Cochabamba	Vinto	COACHACA GRANDE (SUB CENTRAL VINTO)	-1,8
Cochabamba	Vinto	THIOMOKO	-1,8
Cochabamba	Vinto	VILOMILLA	-17,8
Cochabamba	Vinto	COMBUYO	-15,2
Cochabamba	Vinto	PAIRUMANI	-14,9
Cochabamba	Colcapirhua	COLCAPIRHUA	1,9
Cochabamba	Sacaba	SACABA	1,0
Cochabamba	Sacaba	ICHOCOLLO	-7,4
Cochabamba	Sacaba	SAPANANI ALTO	0,5
Cochabamba	Sacaba	LARATY CENTRO	-3,0
Cochabamba	Sacaba	JATUN CKOCHI	-3,0
Cochabamba	Sacaba	SEGUNDA AGUIRRE	-4,5
Cochabamba	Sacaba	MOLLOCOTA	-4,8
Cochabamba	Sacaba	KORIHUMA II	-6,3
Cochabamba	Sacaba	LAVA LAVA ALTA	-8,6
Cochabamba	Sacaba	LOPEZ RANCHO	0,9
Cochabamba	Sacaba	SUB CENTRAL SANTA RITA RODEO	0,8
Cochabamba	Colomi	COLOMI	-10,8
Cochabamba	Colomi	LIRIUNI	2,6
Cochabamba	Colomi	CHOMOCO	-14,5
Cochabamba	Colomi	TABLAS MONTE	-2,0
Cochabamba	Colomi	CORANI PAMPA	-1,2
Cochabamba	Villa Tunari	SANTA ROSA	-10,5
Cochabamba	Villa Tunari	ISINUTA	-10,7
Cochabamba	Villa Tunari	SINDICATO SINUTA	-1,0
Cochabamba	Villa Tunari	SAN GABRIEL	0,4
Cochabamba	Villa Tunari	40 ARROYOS	-10,3
Cochabamba	Villa Tunari	ETERAZAMA	-17,0
Cochabamba	Villa Tunari	PARACTITO	-10,0
Cochabamba	Villa Tunari	SAMUZABETY	-7,8
Cochabamba	Villa Tunari	SAN RAFAEL	3,5
Cochabamba	Villa Tunari	TOCOPILLA	-1,4
Cochabamba	Villa Tunari	CHIPIRIRI	-9,8
Cochabamba	Villa Tunari	VILLA TUNARI	2,7
Cochabamba	Villa Tunari	INDEPENDENCIA	-2,6
Cochabamba	Villa Tunari	UNCIA	-4,7
Cochabamba	Villa Tunari	VILLA URKUPIÑA	-1,9
Cochabamba	Villa Tunari	MAICA MONTE	-1,3
Cochabamba	Villa Tunari	SAN FRANCISCO	-0,6
Cochabamba	Villa Tunari	VILLA 14 DE SEPTIEMBRE	-10,0
Cochabamba	Villa Tunari	MINERA LLALLAGUA	-3,6
Cochabamba	Villa Tunari	VILLA PORVENIR	-0,2
Cochabamba	Villa Tunari	PRIMERO DE MAYO	-3,8

Departamento	Municipio	Comunidad	$\Delta pobreza$
Cochabamba	Villa Tunari	NUEVA TACOPAYA	-1,3
Cochabamba	Tapacari	CHALLA GRANDE	-3,9
Cochabamba	Tapacari	TALLIJA CONFITAL	-0,7
Cochabamba	Totoro	TOTORA	-0,3
Cochabamba	Pojo	POJO	-14,1
Cochabamba	Pojo	SUB YUTU PAMPA	-1,1
Cochabamba	Pojo	CHALLHUANI	-6,1
Cochabamba	Pojo	SUB PALCA	-1,1
Cochabamba	Pocona	CHULLCHUNGANI	-1,5
Cochabamba	Pocona	HUAYAPACHA	-0,3
Cochabamba	Chimore	PUERTO AURORA	-0,8
Cochabamba	Chimore	SENDA B NUEVA CANAAN	-0,5
Cochabamba	Chimore	SENDA D	-0,3
Cochabamba	Chimore	CHIMORE	-2,1
Cochabamba	Chimore	SENDA 3	-9,7
Cochabamba	Chimore	CESARZAMA	-0,8
Cochabamba	Puerto Villarroel	PUERTO VILLARROEL	-8,1
Cochabamba	Puerto Villarroel	SENDA VI	-17,8
Cochabamba	Puerto Villarroel	IVIRGARZAMA	1,9
Cochabamba	Puerto Villarroel	LIBERTAD	-0,1
Cochabamba	Puerto Villarroel	MARIPOSAS	-7,0
Cochabamba	Puerto Villarroel	PARAISO	-16,6
Cochabamba	Puerto Villarroel	LA FLORIDA - VUELTADERO	-9,4
Cochabamba	Puerto Villarroel	TRANSVERSAL	-10,5
Cochabamba	Puerto Villarroel	VALLE SACTA	-12,9
Cochabamba	Entre Rios	CHANCADORA	1,0
Cochabamba	Entre Rios	ISARZAMA	-9,1
Cochabamba	Entre Rios	RIO BLANCO	-16,2
Cochabamba	Entre Rios	ENTRE RIOS	-10,4
Cochabamba	Entre Rios	MANCO KAPAC	-13,1
Cochabamba	Entre Rios	BULO BULO	-14,2
Cochabamba	Entre Rios	GUALBERTO VILLARROEL 1	1,2
Cochabamba	Mizque	MIZQUE	-14,4
Cochabamba	Mizque	MINA ASIENTOS	-3,9
Cochabamba	Mizque	TIN TIN	-2,0
Cochabamba	Mizque	RAQAY PAMPA	-9,1
Cochabamba	Vila Vila	VILA VILA	-0,5
Cochabamba	Punata	PUNATA	1,0
Cochabamba	Villa Rivero	VILLA RIVERO	-1,5
Cochabamba	Villa Rivero	ARAMASI	-3,7
Cochabamba	Villa Rivero	CALICANTO RINCONADA	-3,0
Cochabamba	Villa Rivero	SUB ARAMASI	2,2
Cochabamba	San Benito	SAN BENITO	-17,6
Cochabamba	San Benito	SAN LORENZO	-7,2
Cochabamba	San Benito	SUNCHU PAMPA	-13,2
Cochabamba	San Benito	PARACAYA LINDE	-17,3
Cochabamba	Tacachi	TACACHI	1,1
Cochabamba	Cuchumuela	CUCHUMUELA	-1,4
Cochabamba	Tiraque	TIRAQUE	-12,7
Cochabamba	Shinaota	SIMON BOLIVAR	3,4
Cochabamba	Shinaota	SHINAHOTA	0,8
Cochabamba	Shinaota	IBUELO	0,4
Cochabamba	Shinaota	SAN LUIS	1,2
Oruro	Oruro	ORURO	-1,2
Oruro	Caracollo	CARACOLLO	-3,3
Oruro	Caracollo	LA JOYA	-0,9
Oruro	Caracollo	KEMALLA	-0,9
Oruro	Paria (Soracachi)	HUAYÑA PASTO GRANDE	-5,4
Oruro	Challapata	CHALLAPATA	-15,4
Oruro	Challapata	KAKA CHACA	-4,1
Oruro	Challapata	CRUCE CULTA	1,4
Oruro	Santuario de Quillacas	SANTUARIO DE QUILLACAS	-19,1
Oruro	Santuario de Quillacas	SEVARUYO	-16,6
Oruro	Corque	CORQUE	-21,3
Oruro	Corque	SAN JOSE DE KALA	0,1
Oruro	Corque	OPOQUERI	-8,7
Oruro	Curahuara de Carangas	CURAHUARA DE CARANGAS	-18,0
Oruro	Turco	TURCO	-25,8
Oruro	Huachacalla	HUACHACALLA	2,4
Oruro	Escarra	ESCARA	-2,1
Oruro	Esmeralda	ROMERO PAMPA	1,2
Oruro	Esmeralda	BELEN	0,8

Departamento	Municipio	Comunidad	$\Delta pobreza$
Oruro	Poopo	POOPO	0,3
Oruro	Pazña	PAZÑA	-18,0
Oruro	Pazña	PEÑAS	0,9
Oruro	Pazña	AVICAYA	1,2
Oruro	Pazña	TOTORAL	-13,8
Oruro	Antequera (Bolívar)	ANTEQUERA	0,5
Oruro	Villa Huanuni	HUANUNI	3,4
Oruro	Machacamarca	MACHACAMARCA	2,6
Oruro	Salinas de Garcí Mendoza	SALINAS DE GARCI MENDOZA	-15,7
Oruro	Pampa Aullagas	PAMPA AULLAGAS	-4,6
Oruro	Pampa Aullagas	BENGAL VINTO	-0,1
Oruro	Sabaya	PISIGA BOLIVAR	-16,3
Oruro	Sabaya	JULO	-2,4
Oruro	Sabaya	NEGRILLOS	-3,3
Oruro	Coipasa	COIPASA	1,7
Oruro	Chipaya	CHIPAYA	-4,6
Oruro	Toledo	TOLEDO	-4,7
Oruro	Toledo	CHALLA CRUZ	-0,6
Oruro	Eucaliptus	EUCALIPTUS	-14,5
Oruro	Eucaliptus	QUELCATA	-2,8
Oruro	Santiago de Andamarca	ANDAMARCA	-3,9
Oruro	Santiago de Andamarca	ORINOCA	-7,8
Oruro	Belen de Andamarca	BELEN DE ANDAMARCA	0,4
Oruro	Santiago de Huari	SANTIAGO DE HUARI	-4,8
Oruro	Santiago de Huari	CONDO C	1,4
Oruro	Santiago de Huari	LAGUNILLAS	-3,7
Oruro	Santiago de Huari	URMIRI	-8,6
Oruro	Santiago de Huari	VICHAJ LUPE	-1,2
Oruro	Santiago de Huari	CASTILLA HUMA	-0,4
Potosí	Potosí	POTOSI	-0,9
Potosí	Potosí	HUARI HUARI	1,1
Potosí	Potosí	CHULLCHUCANI	-1,6
Potosí	Potosí	KARACHIPAMPA	-28,2
Potosí	Tinguiipaya	TINGUIPAYA	-18,8
Potosí	Yocalla	TOTORA PAMPA	1,0
Potosí	Yocalla	YOCALLA	-14,6
Potosí	Yocalla	CAYARA	-24,8
Potosí	Yocalla	CHIRA CORO	0,8
Potosí	Yocalla	EL MOLINO	2,7
Potosí	Urmiri	URMIRI	-0,5
Potosí	Urmiri	CAHUAYO	0,4
Potosí	Uncia	UNCIA	-2,9
Potosí	Uncia	CALA CALA	-26,9
Potosí	Chayanta	AMAYA PAMPA	0,8
Potosí	Chayanta	CHAYANTA	-13,1
Potosí	Chayanta	AYMAYA	-17,7
Potosí	Llallagua	LLALLAGUA	-3,6
Potosí	Llallagua	SIGLO XX	1,1
Potosí	Llallagua	CATAVI	-10,3
Potosí	Chuquihuta	CHUQUIHUTA	-19,4
Potosí	Betanzos	BETANZOS	3,3
Potosí	Betanzos	POCO POCO	-1,3
Potosí	Betanzos	QUIVI QUIVI ALTA	1,4
Potosí	Colquechaca	COLQUECHACA	-14,1
Potosí	Colquechaca	MACHA	-21,8
Potosí	Colquechaca	BOMBORI	-0,8
Potosí	Ravelo	RAVELO	-20,7
Potosí	Pocoata	POCOATA	-2,2
Potosí	Pocoata	JARANA	-5,3
Potosí	Pocoata	VILLA ALCARAPI	0,3
Potosí	Pocoata	SAN MIGUEL DE KHARI	-0,2
Potosí	Ocuri	OCURI	-1,5
Potosí	S, P, de Buena Vista	SAN PEDRO DE BUENA VISTA	-12,6
Potosí	S, P, de Buena Vista	CHIRO KASA	-3,8
Potosí	S, P, de Buena Vista	TORACARI	-2,2
Potosí	Toro Toro	TORO TORO	-19,2
Potosí	Cotagaita	COTAGAITA	-5,3
Potosí	Cotagaita	TOTOROA I	-2,1
Potosí	Cotagaita	TOROPALCA	-20,6
Potosí	Cotagaita	TASNA BUEN RETIRO	1,7
Potosí	Cotagaita	TASNA ROSARIO	-8,8
Potosí	Cotagaita	SAGRARIO	-13,0

Departamento	Municipio	Comunidad	$\Delta pobreza$
Potosí	Cotagaita	RAMADAS	-2,6
Potosí	Cotagaita	COLLPA UNO	-2,0
Potosí	Vitichi	TUSQUIÑA	-1,2
Potosí	Vitichi	YAWISLA	0,4
Potosí	Villa de Sacaca	SACACA	-12,5
Potosí	Caripuyo	CARIPUYO	-18,9
Potosí	Tupiza	TUPIZA	1,1
Potosí	Atocha	TELAMAYU	3,2
Potosí	Atocha	SAN VICENTE	7,8
Potosí	Atocha	TATASI	1,6
Potosí	Atocha	ANIMAS	4,4
Potosí	Atocha	SIETE SUYOS	6,1
Potosí	Atocha	ATOCHA	3,6
Potosí	Atocha	SANTA BARBARA	0,2
Potosí	Colcha K	COLCHA K	-14,7
Potosí	Colcha K	SAN CRISTOBAL	3,7
Potosí	Colcha K	CULPINAS K	1,3
Potosí	Colcha K	RIO GRANDE	-17,7
Potosí	Colcha K	POZO CAVADO	-10,1
Potosí	San Pedro de Quemes	SAN PEDRO DE QUEMES	-0,9
Potosí	Puna	PUNA	2,2
Potosí	Caiza D	TRES CRUCES GARNICA	-1,1
Potosí	Caiza D	CAIZA D	-5,3
Potosí	Caiza D	LA LAVA	-12,7
Potosí	Ckochas	CHECCHI	-2,4
Potosí	Uyuni	UYUNI	1,4
Potosí	Uyuni	COLCHANÍ	-2,3
Potosí	Uyuni	TUSQUI	-0,7
Potosí	Uyuni	COROMA	-4,6
Potosí	Uyuni	PULACAYO	-17,0
Potosí	Tomave	TOMAVE	-20,2
Potosí	Tomave	YURA	-17,5
Potosí	Tomave	TICA TICA	-13,1
Potosí	Porco	AGUA DE CASTILLA	2,2
Potosí	Porco	PORCO	-6,2
Potosí	Arampampa	ARAMPAMPA	-1,4
Potosí	Acasio	ACASIO	-14,2
Potosí	Llica	LLICA	-0,7
Potosí	Tahua	TAHUA	-31,4
Potosí	Villazon	VILLAZON	-0,6
Potosí	Villazon	MATANCILLAS	0,1
Potosí	Villazon	YURUMA	1,9
Potosí	San Agustin	SAN AGUSTIN	-2,5
Tarija	Tarija	TARIJA	-2,4
Tarija	Tarija	PORTILLO	-16,8
Tarija	Tarija	LA PINTADA	-14,1
Tarija	Tarija	SANTA ANA LA NUEVA	-16,1
Tarija	Tarija	CHURQUIS	-0,5
Tarija	Tarija	PAMPA REDONDA	-17,7
Tarija	Tarija	TOLOMOSA GRANDE	-0,3
Tarija	Tarija	GUERRA HUAYCO	-20,8
Tarija	Tarija	SAN ANDRES	-20,6
Tarija	Tarija	TURUMAYO	-21,4
Tarija	Tarija	LAZARETO	-0,7
Tarija	Tarija	SAN MATEO	-16,6
Tarija	Tarija	MONTE SUR	-4,8
Tarija	Padcaya	ABRA DE LA CRUZ	-3,6
Tarija	Padcaya	PADCAYA	3,6
Tarija	Padcaya	CAMACHO	-6,0
Tarija	Padcaya	MECOYA	-1,4
Tarija	Padcaya	CRUCE DE ROCILLAS	1,8
Tarija	Bermejo	BERMEJO	4,3
Tarija	Bermejo	LINARES	-10,6
Tarija	Bermejo	BARREDERO	0,8
Tarija	Yacuiba	YACUIBA	3,7
Tarija	Yacuiba	CAMPO PAJOSO	-12,3
Tarija	Yacuiba	CREVAUX	-5,9
Tarija	Yacuiba	D'ORBIGNY	-1,3
Tarija	Yacuiba	LA GRAMPA	-13,4
Tarija	Yacuiba	SAN ISIDRO	-7,6
Tarija	Yacuiba	CAMPO GRANDE	-17,2
Tarija	Yacuiba	LAPACHAL ALTO	-1,3

Departamento	Municipio	Comunidad	$\Delta pobreza$
Tarija	Yacuiba	YAGUACUA	-15,4
Tarija	Yacuiba	SACHAPERÁ	-4,5
Tarija	Yacuiba	SAN FRANCISCO DEL INTI	-8,1
Tarija	Yacuiba	TIERRAS NUEVAS	-4,3
Tarija	Yacuiba	VILLA EL CARMEN	-13,3
Tarija	Yacuiba	OJO DEL AGUA	-1,9
Tarija	Yacuiba	PALMAR CHICO	-4,1
Tarija	Carapari	CARAPARI	4,4
Tarija	Carapari	SAN ALBERTO	-19,4
Tarija	Carapari	SANTA ROSA	1,7
Tarija	Carapari	ITAU	-19,5
Tarija	Villamontes	VILLAMONTES	1,3
Tarija	Villamontes	CAIGUA	-14,3
Tarija	Villamontes	TIGUIPA ESTACION	-7,8
Tarija	Uriondo	CALAMUCHITA	-10,7
Tarija	Uriondo	MUTURAYO	2,0
Tarija	Uriondo	VALLE DE CONCEPCION	4,6
Tarija	Uriondo	LA COMPAÑIA	-2,4
Tarija	Uriondo	MISCAS CALDERA	-3,1
Tarija	San Lorenzo	SAN LORENZO	4,4
Tarija	San Lorenzo	LAJAS MERCED	-17,3
Tarija	San Lorenzo	BORDO EL MOLLAR	-18,7
Tarija	San Lorenzo	CANASMORO	-10,5
Tarija	San Lorenzo	RANCHO NORTE	-7,6
Tarija	San Lorenzo	RANCHO SUR	-8,6
Tarija	San Lorenzo	CARACHIMAYO	-1,0
Tarija	San Lorenzo	SELLA MENDEZ	-9,7
Tarija	San Lorenzo	BORDO LA CALAMA	-21,6
Tarija	San Lorenzo	COIMATA	-7,1
Tarija	San Lorenzo	TOMATITAS	-10,3
Tarija	San Lorenzo	TOMATAS GRANDE	-19,3
Tarija	San Lorenzo	LA VICTORIA	2,1
Tarija	El Puente	EL PUENTE	2,1
Tarija	El Puente	ISCAYACHI	3,9
Tarija	Entre Rios	ENTRE RIOS	5,5
Tarija	Entre Rios	PALOS BLANCOS	-6,9
Tarija	Entre Rios	POTRERILLOS	-0,7
Tarija	Entre Rios	TIMBOY	-17,9
Santa Cruz	Santa Cruz	SANTA CRUZ DE LA SIERRA	-4,1
Santa Cruz	Santa Cruz	VILLA FLOR	-16,2
Santa Cruz	Santa Cruz	SANTA RITA	-12,9
Santa Cruz	Santa Cruz	ZAFRANILLA	-7,9
Santa Cruz	Santa Cruz	MONTERO HOYO	-8,1
Santa Cruz	Santa Cruz	LAS PEÑAS	0,0
Santa Cruz	Santa Cruz	PAURITO	-1,5
Santa Cruz	Cotoca	COTOMA	0,9
Santa Cruz	Cotoca	CAMPANERO	-1,8
Santa Cruz	Cotoca	CAMPANERO (DISPERSO)	-2,3
Santa Cruz	Cotoca	EL ESPINO	-12,2
Santa Cruz	Cotoca	SANTA ROSA DE PROBOSTE	-13,9
Santa Cruz	Cotoca	DON LORENZO	-4,1
Santa Cruz	Cotoca	LA CRUCEÑA (LAS BARRERAS)	-3,1
Santa Cruz	Cotoca	EL BISITO	-3,2
Santa Cruz	Cotoca	ARROYITO	-2,3
Santa Cruz	Cotoca	LA ENCONADA	-19,2
Santa Cruz	Cotoca	LOS TAJIBOS	-1,3
Santa Cruz	Cotoca	TAJIBOS	-8,8
Santa Cruz	Cotoca	TAROPE	-13,3
Santa Cruz	Cotoca	SAN ANDRES	-10,9
Santa Cruz	Cotoca	PUERTO PAILAS (DISPERSO)	-0,3
Santa Cruz	Cotoca	PUERTO PAILAS	-7,4
Santa Cruz	Porongo	POZO COLORADO	-17,2
Santa Cruz	Porongo	LOS BATOS	-2,5
Santa Cruz	Porongo	PORONGO	1,0
Santa Cruz	Porongo	VILLA GUADALUPE	-13,4
Santa Cruz	Porongo	URUBO	-2,7
Santa Cruz	Porongo	LAS CRUCES	-4,7
Santa Cruz	Porongo	TEREBINTO	-0,3
Santa Cruz	Porongo	SANTA FE DE AMBORO	-3,4
Santa Cruz	La Guardia	LA GUARDIA	-6,6
Santa Cruz	La Guardia	LA GUARDIA (DISPERSO)	-6,7
Santa Cruz	La Guardia	EL CARMEN	2,7

Departamento	Municipio	Comunidad	$\Delta pobreza$
Santa Cruz	La Guardia	PEDRO LORENZO	-15,9
Santa Cruz	La Guardia	BASILIO	-13,2
Santa Cruz	La Guardia	SAN JOSE	-10,7
Santa Cruz	El Torno	EL TORNO	-6,1
Santa Cruz	El Torno	ESPEJOS	0,0
Santa Cruz	El Torno	JUNTA PIRAI	-2,1
Santa Cruz	El Torno	SANTA MARTHA	-12,3
Santa Cruz	El Torno	SANTA RITA	-12,3
Santa Cruz	El Torno	LA ANGOSTURA	-13,9
Santa Cruz	El Torno	JOROCHITO	-15,1
Santa Cruz	El Torno	TARUMA	-11,9
Santa Cruz	El Torno	SAN LUIS	-14,5
Santa Cruz	El Torno	LIMONCITO	-12,5
Santa Cruz	El Torno	TIQUIPAYA	-14,2
Santa Cruz	Warnes	WARNES	-7,0
Santa Cruz	Warnes	VILLA EL CARMEN	-5,2
Santa Cruz	Warnes	LA ESPERANZA	-0,9
Santa Cruz	Warnes	TUROBITO	-2,8
Santa Cruz	Warnes	VILLA BARRIENTOS	-3,7
Santa Cruz	Warnes	AZUSAQUI	-8,4
Santa Cruz	Warnes	LAS BARRERAS	-16,2
Santa Cruz	Warnes	CLARA CHUCHIO	-18,2
Santa Cruz	Warnes	LAS GAMAS	-1,6
Santa Cruz	Warnes	BARRIAL	0,7
Santa Cruz	Warnes	LA FINCA	-0,8
Santa Cruz	Warnes	EL TAJIBO	-11,5
Santa Cruz	Warnes	LA REFORMA	-11,1
Santa Cruz	Warnes	LOS CHACOS	-9,5
Santa Cruz	Okinawa Uno	OKINAWA 1	-12,2
Santa Cruz	Okinawa Uno	NUEVO HORIZONTE	2,2
Santa Cruz	Okinawa Uno	SAN MIGUEL	-1,4
Santa Cruz	San Ignacio de Velasco	SAN IGNACIO DE VELASCO	-2,4
Santa Cruz	San Ignacio de Velasco	CARMEN DE RUIZ	0,9
Santa Cruz	San Ignacio de Velasco	CANDELARIA DE NOZA	-2,3
Santa Cruz	San Ignacio de Velasco	SAN ANTONIO	0,4
Santa Cruz	San Ignacio de Velasco	SAN RAFAELITO DE SUTUNIQUÍÑA	-5,3
Santa Cruz	San Ignacio de Velasco	SAN JAVIERITO	-5,0
Santa Cruz	San Ignacio de Velasco	SANTA ROSA DE ROCA	0,8
Santa Cruz	San Ignacio de Velasco	SANTA ANA	-14,5
Santa Cruz	San Miguel de Velasco	SAN MIGUEL	-12,0
Santa Cruz	San Rafael	SAN RAFAEL	-22,6
Santa Cruz	Buena Vista	LA ARBOLEDA	-9,1
Santa Cruz	Buena Vista	BUENA VISTA	-5,7
Santa Cruz	Buena Vista	CARANDA	-13,3
Santa Cruz	Buena Vista	HUAYTU	0,1
Santa Cruz	Buena Vista	SAN ISIDRO	-10,1
Santa Cruz	Buena Vista	BUENA VISTA (DISPERSO)	-0,9
Santa Cruz	San Carlos	2 DE AGOSTO	1,0
Santa Cruz	San Carlos	BUEN RETIRO	-10,8
Santa Cruz	San Carlos	VILLA ANTOFAGASTA	-0,9
Santa Cruz	San Carlos	SANTA FE DE YAPACANI	-14,5
Santa Cruz	San Carlos	SAN CARLOS	-9,1
Santa Cruz	Yapacani	SAN GERMAN	-16,7
Santa Cruz	Yapacani	SAN JUAN CAMPO VIBORA	3,3
Santa Cruz	Yapacani	LOS YUQUIS	-3,1
Santa Cruz	Yapacani	VILLA EL PALMAR	0,0
Santa Cruz	Yapacani	YAPACANI	-7,6
Santa Cruz	Yapacani	PUERTO AVAROA	0,3
Santa Cruz	Yapacani	VILLA CHORE	-9,5
Santa Cruz	San Juan	AYACUCHO EL CARMEN	-0,1
Santa Cruz	San Juan	LA ENCONADA	2,4
Santa Cruz	San Juan	SAN JUAN DE YAPACANI	1,0
Santa Cruz	San Jose de Chiquitos	QUIMOME	-3,6
Santa Cruz	San Jose de Chiquitos	SAN JOSE DE CHIQUITOS	-0,3
Santa Cruz	San Jose de Chiquitos	SAN JUAN DE TAPERAS	-5,8
Santa Cruz	Pailon	ROSAL CENTRO	0,3
Santa Cruz	Pailon	SINAI	-13,7
Santa Cruz	Pailon	PAILON	-10,2
Santa Cruz	Pailon	PUERTO IBAÑEZ	2,9
Santa Cruz	Pailon	VALLE NUEVO	-6,5
Santa Cruz	Pailon	CUPESI	-5,0
Santa Cruz	Pailon	POZO DEL TIGRE	-5,1

Departamento	Municipio	Comunidad	$\Delta pobreza$
Santa Cruz	Pailon	TRES CRUCES	-21,5
Santa Cruz	Pailon	EL CERRO	-2,9
Santa Cruz	Pailon	TINTO DEL ESTE - MENONITA	-12,0
Santa Cruz	Robore	CHOCHIS	-11,9
Santa Cruz	Robore	ROBORE	-0,2
Santa Cruz	Robore	SANTIAGO DE CHIQUITOS	-12,2
Santa Cruz	Portachuelo	PORTACHUELO	4,5
Santa Cruz	Portachuelo	SAN IGNACIO DEL SARA	-11,6
Santa Cruz	Santa Rosa del Sara	LOMA ALTA	-7,3
Santa Cruz	Santa Rosa del Sara	SANTA ROSA DEL SARA	0,8
Santa Cruz	Santa Rosa del Sara	LOS ANDES	-2,1
Santa Cruz	Santa Rosa del Sara	RINCON DE PALOMETAS	-11,9
Santa Cruz	Santa Rosa del Sara	AZUBI	0,7
Santa Cruz	Colpa Belgica	LA BELGICA	-4,8
Santa Cruz	Lagunillas	LAGUNILLAS	-13,5
Santa Cruz	Lagunillas	IPATI	-20,2
Santa Cruz	Charagua	CHARAGUA	1,2
Santa Cruz	Charagua	CHARAGUA (LA ESTACION)	-5,6
Santa Cruz	Charagua	IBASIRIRI	-2,6
Santa Cruz	Charagua	RANCHO NUEVO	-1,5
Santa Cruz	Charagua	YAPIROA	-1,7
Santa Cruz	Charagua	SAN ANTONIO DE PARAPETI	-16,4
Santa Cruz	Charagua	EL ESPINO	-1,0
Santa Cruz	Charagua	IYOMI	-0,3
Santa Cruz	Charagua	PARAPITIGUASO	0,3
Santa Cruz	Cabezas	CABEZAS	-20,2
Santa Cruz	Cabezas	MENONITA RIVAS PALACIO	-1,5
Santa Cruz	Cabezas	MORA	-22,0
Santa Cruz	Cabezas	RIO SECO	-0,7
Santa Cruz	Cabezas	ZANJA HONDA	-23,0
Santa Cruz	Cabezas	PAMPA EL COSCAL	-1,1
Santa Cruz	Cuevo	CUEVO	-3,0
Santa Cruz	Gutierrez	EITY - DEL GRAN KAIPIPENDI	2,7
Santa Cruz	Gutierrez	IVAMIRAPINTA	-2,8
Santa Cruz	Gutierrez	GUTIERREZ	-19,9
Santa Cruz	Gutierrez	TATARENDA VIEJO	-1,0
Santa Cruz	Gutierrez	EL CRUCE	-4,3
Santa Cruz	Camiri	CAMIRI	6,3
Santa Cruz	Camiri	CHORETI	-13,0
Santa Cruz	Camiri	ITANAMBICUA	-0,8
Santa Cruz	Boyuiibe	BOYUIIBE	-13,1
Santa Cruz	Valle Grande	VALLEGRANDE	-0,1
Santa Cruz	Moro Moro	MORO MORO	0,9
Santa Cruz	Postrer Valle	POSTRERVALLE	-15,5
Santa Cruz	Pucara	PUCARA	-0,2
Santa Cruz	Samaipata	BERMEJO	-14,5
Santa Cruz	Samaipata	SAMAIPATA	-0,8
Santa Cruz	Samaipata	MONTEAGUDO	-1,2
Santa Cruz	Pampa Grande	LOS NEGROS	-21,6
Santa Cruz	Pampa Grande	PAMPA GRANDE	-0,3
Santa Cruz	Pampa Grande	MATARAL	-19,7
Santa Cruz	Mairana	MAIRANA	-14,2
Santa Cruz	Mairana	YERBA BUENA MILITAR	-15,0
Santa Cruz	Quirusillas	QUIRUSILLAS -LOS TAJIBOS	-17,1
Santa Cruz	Montero	MONTERO	1,2
Santa Cruz	Montero	NARANJAL	-5,1
Santa Cruz	Gral, Saavedra	CHANE BEDOYA	5,3
Santa Cruz	Gral, Saavedra	PICO DE MONTE	-2,0
Santa Cruz	Gral, Saavedra	MARISCAL SUCRE	-21,7
Santa Cruz	Gral, Saavedra	GENERAL SAAVEDRA	-5,9
Santa Cruz	Gral, Saavedra	POZA CAIMANES	-2,3
Santa Cruz	Gral, Saavedra	PUENTE CAIMANES	-2,3
Santa Cruz	Gral, Saavedra	12 DE OCTUBRE	-3,8
Santa Cruz	Mineros	MINEROS	-7,2
Santa Cruz	Mineros	ALIANZA	-2,8
Santa Cruz	Mineros	LA PORFIA	0,3
Santa Cruz	Mineros	PUEBLO NUEVO	-6,0
Santa Cruz	Fernandez Alonso	CHANE INDEPENDENCIA	0,7
Santa Cruz	Fernandez Alonso	CHANE MAGALLANES	-12,3
Santa Cruz	Fernandez Alonso	AGUAHII	0,2
Santa Cruz	Fernandez Alonso	FERNANDEZ ALONSO	-8,5
Santa Cruz	San Pedro	SAN JUAN DEL PIRAI	-18,1

Departamento	Municipio	Comunidad	$\Delta pobreza$
Santa Cruz	San Pedro	CANANDOA	1,1
Santa Cruz	San Pedro	HARDEMAN	-10,9
Santa Cruz	San Pedro	LITORAL	-11,7
Santa Cruz	San Pedro	SAGRADO CORAZON	-10,1
Santa Cruz	San Pedro	SAN JOSE DEL NORTE	-9,8
Santa Cruz	San Pedro	SAN PEDRO	-9,1
Santa Cruz	San Pedro	PETA GRANDE	1,1
Santa Cruz	Concepcion	LIMONCITO	0,4
Santa Cruz	Concepcion	CONCEPCION	1,9
Santa Cruz	San Javier	CACHUELA ESPAÑA	-6,0
Santa Cruz	San Javier	SAN JAVIER	1,1
Santa Cruz	San Javier	SAN JAVIER (DISPERSO)	-0,3
Santa Cruz	San Javier	VILLA FATIMA	-1,9
Santa Cruz	San Ramon	SAN RAMON	0,6
Santa Cruz	San Julian	ILLIMANI NUCLEO 29	-3,9
Santa Cruz	San Julian	VILLA VICTORIA	-1,9
Santa Cruz	San Julian	SAN JULIAN	-21,7
Santa Cruz	San Julian	LA ASUNTA	-0,4
Santa Cruz	San Julian	LITORAL	-10,7
Santa Cruz	San Julian	LOS ANGELES	0,6
Santa Cruz	San Julian	BERLIN LOS TRONCOS	-0,1
Santa Cruz	San Julian	16 DE MARZO	-2,5
Santa Cruz	San Julian	VILLA PARAISO	-20,8
Santa Cruz	San Julian	FORTIN LIBERTAD	-20,1
Santa Cruz	San Antonio de Lomerio	SAN ANTONIO DE LOMERIO	-1,5
Santa Cruz	Cuatro Cañadas	SAN MIGUEL FLORIDA	-15,7
Santa Cruz	Cuatro Cañadas	CUATRO CAÑADAS	-20,2
Santa Cruz	Cuatro Cañadas	PUERTO RICO	-12,7
Santa Cruz	Cuatro Cañadas	26 DE AGOSTO	-12,9
Santa Cruz	Cuatro Cañadas	NUEVA ESPERANZA	-11,9
Santa Cruz	San Matias	CRUZ CHICA	-3,2
Santa Cruz	San Matias	SAN JOAQUIN	-1,0
Santa Cruz	San Matias	CANDELARIA	-2,4
Santa Cruz	San Matias	SAN MATIAS	-9,8
Santa Cruz	San Matias	LAS PETAS	-1,6
Santa Cruz	San Matias	ASCENCION	-2,2
Santa Cruz	Comarapa	SAN JUAN DEL POTRERO -LA RAYA	-18,8
Santa Cruz	Comarapa	PULQUINA	-18,7
Santa Cruz	Comarapa	LA PALIZADA	-1,7
Santa Cruz	Comarapa	SAN ISIDRO	-21,5
Santa Cruz	Comarapa	COMARAPA	-14,3
Santa Cruz	Saipina	SAIPINA	-18,9
Santa Cruz	Saipina	SAN RAFAEL	-18,4
Santa Cruz	Saipina	CHILON	-2,7
Santa Cruz	Puerto Suarez	PARADERO	-9,0
Santa Cruz	Puerto Suarez	PUERTO SUAREZ	-3,6
Santa Cruz	Puerto Quijarro	ARROYO CONCEPCION	-6,3
Santa Cruz	Puerto Quijarro	PUERTO QUIJARRO	-6,3
Santa Cruz	Carmen Rivero Torrez	EL CARMEN RIVERO TORREZ	-19,7
Santa Cruz	Ascencion de Guarayos	ASCENCION DE GUARAYOS	-7,4
Santa Cruz	Ascencion de Guarayos	SAN ANTONIO DEL JUNTE	-3,1
Santa Cruz	Ascencion de Guarayos	SANTA MARIA	-6,3
Santa Cruz	Ascencion de Guarayos	SAN PABLO	1,5
Santa Cruz	Ascencion de Guarayos	NUEVA JERUSALEN	-8,5
Santa Cruz	Urubicha	URUBICHA	-2,2
Santa Cruz	Urubicha	YAGUARU	-3,7
Santa Cruz	El Puente	EL CARMEN NUCLEO 53	-11,2
Santa Cruz	El Puente	EL PUENTE	1,3
Santa Cruz	El Puente	YOTAU	-2,0
Beni	Trinidad	TRINIDAD	-1,5
Beni	Trinidad	PUERTO BARADOR	-3,9
Beni	Trinidad	CASARABE	-0,8
Beni	Trinidad	LOMA SUAREZ	-18,2
Beni	San Javier	SAN PEDRO	1,8
Beni	Riberalta	RIBERALTA	-11,9
Beni	Guayaramerin	GUAYARAMERIN	-2,2
Beni	Reyes	REYES	-4,0
Beni	San Borja	SAN BORJA	-12,5
Beni	San Borja	EL PALMAR	2,0
Beni	San Borja	YUCUMO	-1,7
Beni	Santa Rosa de Yacuma	EL TRIUNFO	3,3
Beni	Santa Rosa de Yacuma	SANTA ROSA DE YACUMA	-17,8

Departamento	Municipio	Comunidad	$\Delta pobreza$
Beni	Rurrenabaque	RURRENABAQUE	-0,2
Beni	Rurrenabaque	NUEVOS HORIZONTES	0,0
Beni	Santa Ana de Yacuma	SANTA ANA DEL YACUMA	-5,6
Beni	Santa Ana de Yacuma	ROSARIO DEL APERE	2,2
Beni	San Ignacio	SAN IGNACIO DE MOXOS	-14,6
Beni	San Andres	PUENTE SAN PABLO	-4,9
Beni	San Joaquin	SAN JOAQUIN	-18,7
Beni	San Ramon	SAN RAMON	-17,9
Beni	Magadalena	MAGDALENA	-11,4
Beni	Magadalena	BELLA VISTA	-0,2
Beni	Baures	BAURES	-10,0
Beni	Huacaraje	HUACARAJE	-1,6
Pando	Cobija	COBIJA	-0,2
Pando	Porvenir	PORVENIR	-2,2
Pando	Porvenir	VILLA ROJAS	-6,5
Pando	Bella Flor	MONTEVIDEO PUERTO EVO	-5,4
Pando	Puerto Rico	PUERTO RICO	-16,5
Pando	Gonzalo Moreno	GONZALO MORENO	-8,8
Pando	Gonzalo Moreno	LAS PIEDRAS	-2,1
Pando	Gonzalo Moreno	MIRAFLORES	-2,2
Pando	San Lorenzo	BLANCA FLOR	-1,9
Pando	Sena	EL SENA	-5,3
Pando	Villa Nueva (Loma Alta)	LOMA ALTA	0,0